UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas
Licenciatura en Ciencia de Datos

Métodos Matemáticos Computacionales para Ciencia de Datos

Exploración de datos y reducción de dimensiones con componentes principales

Indicadores demográficos, económicos y geográficos de 227 países

---

Integrantes	De La Cruz Maldonado José Eduardo López Reyes Jorge
Profesora	Nora Isabel Pérez Quezadas
Datos	Countries of the World (Kaggle, fernandol)

Ciudad Universitaria, Ciudad de México
Noviembre de 2026

Resumen

Se realiza un análisis exploratorio de 227 países descritos por 18 variables demográficas, económicas y geográficas (*Countries of the World*, Kaggle) para saber si pueden resumirse en pocas componentes principales. Se depuró la base (variables redundantes descartadas, tres territorios eliminados por exceso de faltantes, imputación con la mediana regional y logaritmo en las variables de asimetría extrema) y se obtuvieron gráficas, medidas descriptivas, valores atípicos y matrices de covarianza y correlación. Luego se aplicó el análisis de componentes principales (PCA) con y sin estandarización, eligiendo el número de componentes con los criterios de Kaiser, Horn y varianza acumulada. Con datos estandarizados, cuatro componentes explican 76.7 % de la varianza y la primera (42.8 %) funciona como un eje de nivel de desarrollo; sin estandarizar, la primera explica 99.98 % pero solo refleja el PIB per cápita por su escala. Por ello, estandarizar es indispensable cuando las variables tienen unidades distintas.

Palabras clave: análisis exploratorio, componentes principales, estandarización, correlación, indicadores de países.

Contenido

1. Introducción **5**

1.1 Objetivo e hipótesis de trabajo 5

1.2 Justificación y antecedentes 5

1.3 Origen y descripción de los datos 5

1.4 Herramientas y métodos 6

1.4.1 Medidas descriptivas y covarianza 7

1.4.2 Correlación de Pearson 7

1.4.3 Valores atípicos: rango intercuartílico 7

1.4.4 Transformación logarítmica y estandarización 7

1.4.5 Componentes principales 7

1.4.6 Cuántas componentes conservar 8

1.4.7 Reconstrucción de la matriz con k componentes 8

2. Análisis experimental **8**

2.1 Valores faltantes 8

2.2 Variables que descartamos y por qué 9

2.3 Países eliminados y valores imputados 10

2.4 Transformación de variables muy asimétricas 10

2.5 Cómo se obtuvo cada resultado 11

3. Resultados **12**

3.1 Gráficas de cada característica 12

3.2 Medidas descriptivas 18

3.3 Datos atípicos 20

3.4 Correlaciones y relación entre variables 21

3.4.1 Covarianza y correlación de Pearson 21

3.4.2 Matriz de correlación 22

3.4.3 Variables independientes y dependientes 24

3.5 Componentes principales (PCA) 25

3.5.1 Qué ventaja ofrece el PCA 25

3.5.2 Cómo se calculan 25

3.5.3 Por qué elegimos cuatro componentes 26

3.5.4 Interpretación de las componentes 27

3.5.5 Los países en el plano de las dos primeras componentes 28
3.5.6 Regresar a la matriz original: reconstrucción con k componentes 29
3.6 Estandarización: con y sin 31
3.6.1 Por qué importa la escala 31
3.6.2 Qué ocurre sin estandarizar y estandarizando 31
3.6.3 Conclusión sobre la estandarización 33
4. Discusión **33**
4.1 Comparación con las hipótesis 33
4.2 Resultados inesperados y limitaciones 33
4.3 Cómo se podría mejorar el análisis 34
5. Conclusiones **34**
6. Bibliografía **35**

1. Introducción

1.1 Objetivo e hipótesis de trabajo

El objetivo de este trabajo es realizar un análisis exploratorio del conjunto de datos *Countries of the World* [1] y, con la base ya depurada, determinar si los indicadores demográficos, económicos y geográficos de los países pueden resumirse en unas pocas componentes principales sin perder demasiada información. El análisis sigue el flujo planteado en clase: datos, exploración (gráficas, preprocesamiento, correlaciones, medidas descriptivas y valores atípicos), corrección de los datos cuando hace falta y reducción de dimensiones con PCA.

Partimos de dos hipótesis de trabajo que se retoman en la Discusión. **H1:** muchas variables miden en el fondo el nivel de desarrollo de un país (salud, ingreso, educación, estructura económica), por lo que estarán fuertemente correlacionadas y unas pocas componentes bastarán para resumir buena parte de la varianza. **H2:** como las variables están en unidades muy distintas, el PCA sin estandarizar quedará dominado por la variable de mayor escala, mientras que con estandarización sí resumirá la estructura de los datos.

1.2 Justificación y antecedentes

Los países se describen con decenas de indicadores y varios de ellos dicen casi lo mismo. Resumirlos en pocas dimensiones permite comparar países, visualizarlos en un plano y usar menos variables en modelos posteriores. Además, este conjunto es un buen caso para entender el PCA, porque la decisión de estandarizar o no cambia por completo el resultado.

El análisis de componentes principales es una técnica clásica para reducir dimensiones [2], y los criterios para decidir cuántas componentes conservar se han estudiado desde hace décadas [3, 4]. Como antecedente de la idea de resumir el desarrollo de un país con pocas dimensiones, el Índice de Desarrollo Humano del PNUD [5] combina salud, educación e ingreso en un solo indicador; a diferencia del PCA, se construye con una fórmula fija y no a partir de la estructura de los datos.

1.3 Origen y descripción de los datos

Los datos vienen del conjunto *Countries of the World*, publicado en Kaggle por el usuario fernandol (https://www.kaggle.com/datasets/fernandol/countries-of-the-world) [1]. Cada fila es un país o territorio y cada columna una característica. Por los valores que contiene (por ejemplo, China aparece con 1,313,973,713 habitantes), la información corresponde a mediados de la década de 2000, así que las conclusiones describen ese periodo y no la situación actual.

El archivo usa coma como separador decimal ("48,0") y los nombres de país y de región traen espacios al final, por lo que al leerlo indicamos *decimal=","* y limpiamos los textos. La Tabla 1 resume las columnas.

```
raw = pd.read_csv(BASE / "datos" / "countries_of_the_world.csv", decimal=",")
raw.columns = [c.strip() for c in raw.columns]
raw["Country"] = raw["Country"].str.strip()
raw["Region"] = raw["Region"].str.strip()
raw = raw.set_index("Country")
print(raw.shape)
print(raw.dtypes)
print(raw.isna().sum())
```

Tabla 1. Variables del conjunto de datos tal como se usan en este trabajo.

Variable	Tipo	Qué mide
País	texto	Nombre del país o territorio (se usa como identificador).
Región	categórica (11 niveles)	Región geográfica definida por la fuente.
Población	numérica	Número de habitantes.
Superficie	numérica	Área en millas cuadradas.
Densidad de población	numérica	Habitantes por milla cuadrada.
Costa / área	numérica	Razón entre la longitud de costa y la superficie.
Migración neta	numérica	Migrantes netos por cada 1000 habitantes.
Mortalidad infantil	numérica	Muertes por cada 1000 nacimientos.
PIB per cápita	numérica	Dólares estadounidenses por habitante.
Alfabetización	numérica	Porcentaje de la población alfabetizada.
Teléfonos	numérica	Líneas telefónicas por cada 1000 habitantes.
Tierra cultivable, cultivos permanentes, otros usos	numéricas	Porcentaje de la superficie en cada uso del suelo.
Clima	categórica ordinal	Tipo de clima codificado de 1 a 4, con algunos valores intermedios (1.5 y 2.5).
Natalidad, mortalidad	numéricas	Nacimientos y muertes por cada 1000 habitantes.
Agricultura, industria, servicios	numéricas	Fracción del PIB que aporta cada sector.

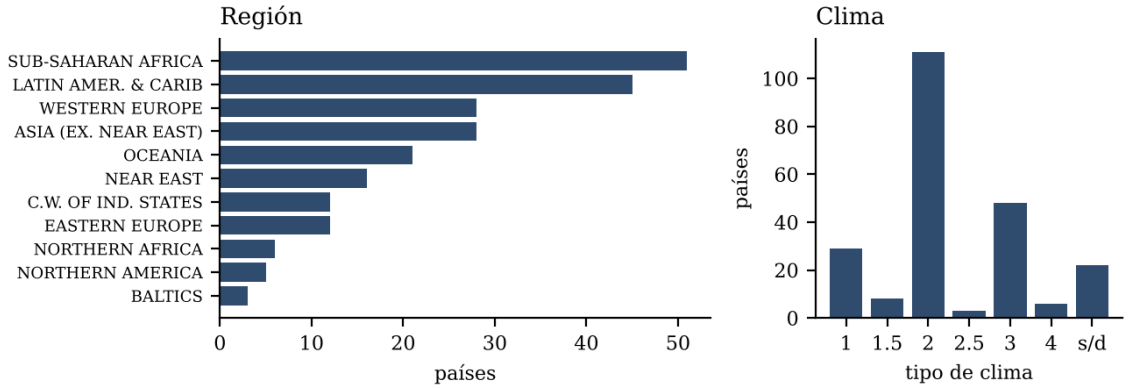


Figura 1. Distribución de las dos variables categóricas. Clima tiene 22 países sin dato (s/d).

La región con más países es África subsahariana (51), seguida de América Latina y el Caribe (45); Países Bálticos (3) es la más pequeña. En clima, el tipo 2 concentra 111 países.

1.4 Herramientas y métodos

Todo el análisis se hizo en Python 3 con estos paquetes: pandas [6] (lectura del CSV con *read_csv*, imputación con *groupby/transform* y *fillna*, y los métodos *mean*, *median*, *var*, *std*, *skew*, *cov* y *corr*); NumPy [7] (matriz de covarianza con *numpy.cov*, valores y vectores propios con *numpy.linalg.eigh* y *log10*); Matplotlib [8] y seaborn [9] (histogramas, diagramas de caja, dispersión y mapas de calor); y scikit-learn [10], cuya clase *PCA* usamos solo para verificar nuestro cálculo. Las herramientas que aparecen en el pizarrón de clase (matrices de covarianza y correlación, PCA y estandarización) se describen a grandes rasgos; las demás (transformación logarítmica, criterio del rango intercuartílico y simulación de Horn) se explican con más detalle.

1.4.1 Medidas descriptivas y covarianza

La media, la varianza y la covarianza de dos variables X e Y medidas en *n* países son:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad\qquad s^2(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

$$\operatorname{Cov}(X, Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

Aquí *n* es el número de países, x_i y y_i son los valores de X y Y en el país *i*, la barra sobre una letra indica su media y cada suma recorre $i = 1, \ldots, n$. La desviación estándar *s* es la raíz cuadrada de la varianza. La mediana es el valor central de los datos ordenados y, a diferencia de la media, no la afectan los valores extremos.

1.4.2 Correlación de Pearson

$$r(X, Y) = \frac{\operatorname{Cov}(X, Y)}{\sigma(X)\,\sigma(Y)}$$

donde σ(X) y σ(Y) son las desviaciones estándar de X y de Y. El coeficiente *r* va de −1 a 1 y no depende de las unidades. La matriz de correlación reúne el valor de *r* de todos los pares de variables; vale 1 en la diagonal y es simétrica.

1.4.3 Valores atípicos: rango intercuartílico

$$x < Q_1 - 1.5\,\mathrm{RIC} \quad \text{o} \quad x > Q_3 + 1.5\,\mathrm{RIC}, \qquad \mathrm{RIC} = Q_3 - Q_1$$

donde Q_1 y Q_3 son el primer y el tercer cuartil de la variable (los valores que dejan por debajo al 25 % y al 75 % de los países) y RIC es el rango intercuartílico. Un valor *x* que cumple alguna de las dos condiciones se considera atípico. Es el criterio que dibuja los círculos de los diagramas de caja.

1.4.4 Transformación logarítmica y estandarización

$$y = \log_{10}(x + 1) \qquad\qquad z_i = \frac{x_i - \bar{x}}{s}$$

donde *x* es el valor original, *y* el valor transformado y z_i el valor estandarizado de la variable en el país *i*, con media 0 y desviación estándar 1. El logaritmo comprime las colas derechas largas y conserva el orden de los países; se suma 1 porque hay valores iguales a cero. La estandarización pone todas las variables en la misma escala.

1.4.5 Componentes principales

$$S\,v_j = \lambda_j\,v_j \qquad\qquad \mathrm{prop}_j = \frac{\lambda_j}{\lambda_1 + \cdots + \lambda_p} \qquad\qquad T = Z\,V$$

Aquí *S* es la matriz de covarianza de los datos (de $p \times p$, con $p = 13$ variables), v_j es el vector propio de la componente *j* (sus coeficientes) y λ_j su valor propio, que es la varianza de esa componente; las componentes se ordenan de mayor a menor λ, y prop_j es la proporción de varianza que explica la componente *j*. *Z* es la matriz de datos estandarizados ($n \times p$), *V* es la matriz cuyas columnas son los vectores propios y *T* contiene

las puntuaciones (*scores*) de cada país. Si S se calcula con datos estandarizados, es la matriz de correlación. La carga de la variable i en la componente j es $v_{ij} \cdot \sqrt{\lambda_j}$, y equivale a la correlación entre ambas cuando se parte de datos estandarizados.

1.4.6 Cuántas componentes conservar

El criterio de Kaiser [3] conserva las componentes con λ mayor que 1 (con datos estandarizados): las que explican más varianza que una variable original. La simulación de Horn [4] genera muchas matrices de datos aleatorios sin estructura, del mismo tamaño que la nuestra, calcula sus valores propios y conserva las componentes cuyo λ supera al del azar; aquí usamos 500 simulaciones y el percentil 95. El criterio de varianza acumulada toma el menor número de componentes que explica al menos 80 %. El gráfico de sedimentación (*scree plot*) ayuda a ver dónde la curva de valores propios deja de bajar con fuerza.

1.4.7 Reconstrucción de la matriz con k componentes

Con solo las primeras k componentes se puede volver a la matriz de datos:

$$\hat{Z}_k = T_k \, V_k^{\top} \qquad\qquad \hat{X}_k = \hat{Z}_k \, D + \mathbf{1} \, \bar{x}^{\top}$$

Aquí T_k y V_k son las primeras k columnas de T y de V, $\hat{Z}_k$ es la matriz estandarizada aproximada, D es la matriz diagonal con las desviaciones estándar s de cada variable, $\mathbf{1}$ es un vector columna de unos y $\bar{x}$ con barra es el vector de medias. Si además se aplicó el logaritmo, se deshace con $x = 10^{y} - 1$. Con $k = p$ la reconstrucción es exacta; con $k < p$ se pierde justo la varianza de las componentes descartadas:

$$\frac{\|Z - \hat{Z}_k\|_F^2}{n-1} = \lambda_{k+1} + \cdots + \lambda_p$$

donde $\|\cdot\|_F$ es la norma de Frobenius (la raíz de la suma de los cuadrados de todas las entradas de la matriz). Esto da una medida directa de lo que cuesta quedarse con k componentes.

2. Análisis experimental

Esta sección describe qué se hizo con los datos antes de analizarlos y sobre qué base se obtuvo cada resultado de la sección 3. El tratamiento tiene cuatro pasos: contar y tratar los valores faltantes, decidir qué variables y países se quedan, imputar los vacíos restantes y transformar las variables muy asimétricas. Las gráficas de la sección 3.1 se hicieron con los datos originales, antes de modificar nada, para mostrar la información tal como viene en la fuente.

2.1 Valores faltantes

Primero contamos los vacíos de cada columna. Las que más faltan son Clima (22 países, 9.7 %), Alfabetización (18 países, 7.9 %), Industria (16 países, 7.0 %), Agricultura (15 países, 6.6 %). Ninguna columna numérica pasa del 8 % de vacíos, así que no hay razón para descartarlas únicamente por faltantes.

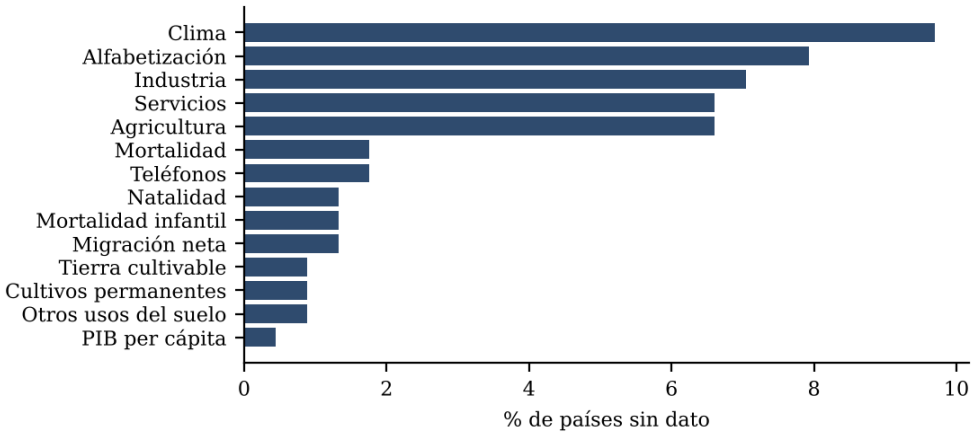


Figura 2. Porcentaje de países sin dato en cada columna (solo se muestran las que tienen vacíos).

```
nulos = raw.isna().sum()
nulos = (100 * nulos[nulos > 0] / len(raw)).sort_values()
fig, ax = plt.subplots(figsize=(5.6, 2.6))
ax.barh([NOMBRES[v] for v in nulos.index], nulos.values, color=C1)
ax.set_xlabel("% de países sin dato")
fig.tight_layout(); fig.savefig(FIG / "fig_faltantes.png")
```

2.2 Variables que descartamos y por qué

De las 18 columnas distintas de País, 13 numéricas entran al estudio de correlaciones y componentes principales. Las demás se descartan por las razones de la Tabla 2. Hablamos de variables (columnas): descartar una significa que no participa en las matrices de covarianza y correlación ni en el PCA, pero sigue visible en las gráficas de la sección 3.1.

Tabla 2. Variables que no entran a las matrices de correlación ni al PCA.

Variable	Decisión	Razón
País	Índice	Es un identificador; no es una medición.
Región	Fuera del PCA	Es categórica nominal (11 niveles) y no tiene sentido calcular media o covarianza con ella. La usamos para colorear gráficas y para imputar faltantes.
Clima	Se descarta	Es una categoría ordinal con 22 países sin dato (9.7 %) y con valores intermedios (1.5 y 2.5) que no son medidas reales. Su media o covarianza no tiene interpretación.
Otros usos del suelo	Se descarta	Es exactamente 100 menos tierra cultivable menos cultivos permanentes (la suma de las tres va de 99.88 a 100.01, la diferencia es redondeo). Una variable que es combinación lineal de otras hace singular la matriz de covarianza y no agrega información.
Industria	Se descarta	Agricultura + industria + servicios suman entre 0.906 y 1.010, por lo que las tres son casi dependientes. Conservamos agricultura y servicios; industria queda como el resto (su correlación con ellas es -0.32 y -0.54) y además tiene 16 vacíos.
Población y superficie	Fuera del PCA	Miden el tamaño del país, no sus condiciones de vida, y su resumen útil ya está en la densidad de población (población entre superficie). Tienen la asimetría más fuerte (9.2 y 6.0) y dominarían las matrices.

2.3 Países eliminados y valores imputados

Para decidir qué hacer con los vacíos de las 13 variables que sí usamos, contamos cuántos le faltan a cada país. Eliminamos a los que tienen cuatro o más vacíos (más del 30 % de sus variables): Mayotte, Wallis and Futuna, Western Sahara. Quedan 224 países. A los demás les rellenamos cada vacío con la mediana de su región; usamos la mediana porque no la afectan los valores extremos y la región porque agrupa países con condiciones parecidas, de modo que es mejor imputar con ella que con la mediana mundial.

Se imputaron Alfabetización (16), Servicios (13), Agricultura (12), Teléfonos (3) y pocos valores en el resto. El caso más grande, alfabetización, representa 7.1 % de los países. Imputar con la mediana reduce un poco la varianza real de esas variables, lo cual dejamos señalado como limitación.

```
VARS = ["Pop. Density (per sq. mi.)", "Coastline (coast/area ratio)", "Net migration",
            "Infant mortality (per 1000 births)", "GDP ($ per capita)", "Literacy (%)",
            "Phones (per 1000)", "Arable (%)", "Crops (%)", "Birthrate", "Deathrate",
            "Agriculture", "Service"]
datos = raw[VARS + ["Region"]].copy()
faltan = datos[VARS].isna().sum(axis=1)
eliminados = datos.index[faltan >= 4].tolist()      # más del 30 % de las variables sin dato
datos = datos[faltan < 4].copy()
med_region = datos.groupby("Region")[VARS].transform("median")
datos[VARS] = datos[VARS].fillna(med_region)
datos[VARS] = datos[VARS].fillna(datos[VARS].median())
print("eliminados:", eliminados, "| quedan:", len(datos), "| nulos:",
    int(datos[VARS].isna().sum().sum()))
```

2.4 Transformación de variables muy asimétricas

Esta es la flecha de "corregir datos" del esquema del pizarrón: los resultados de la sección 3.1 muestran que algunas variables tienen colas derechas extremas que, al calcular correlaciones y componentes, dejarían que unos pocos países decidan el resultado. Con un criterio fijo, aplicamos *log10(x + 1)* a las variables con coeficiente de asimetría mayor o igual a 2 en valor absoluto. Elegimos el logaritmo porque comprime las colas derechas y respeta el orden de los países, y sumamos 1 porque estas variables tienen ceros (por ejemplo, países sin costa). Las variables transformadas son: Densidad de población, Costa / área, Cultivos permanentes.

```
asim_antes = datos[VARS].skew()
a_log = asim_antes[asim_antes.abs() >= 2].index.tolist()
trans = datos.copy()
for v in a_log:
    trans[v] = np.log10(trans[v] + 1)
asim_despues = trans[VARS].skew()
print(pd.DataFrame({"antes": asim_antes, "despues": asim_despues}).loc[a_log].round(2))
```

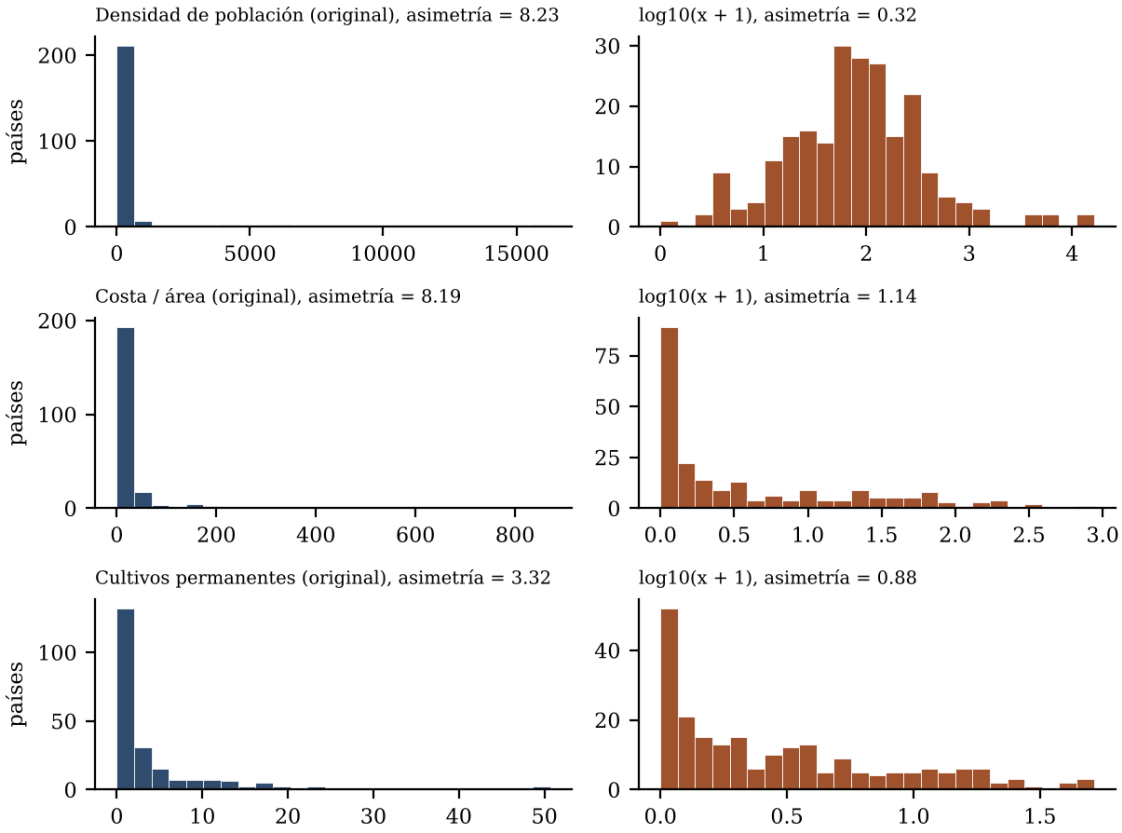


Figura 3. Efecto de la transformación logarítmica sobre las tres variables más asimétricas (izquierda: original; derecha: transformada).

La asimetría de densidad baja de 8.23 a 0.32, la de costa/área de 8.19 a 1.14 y la de cultivos permanentes de 3.32 a 0.88. Las demás variables tienen asimetría menor que 2 y se dejan en su escala original para conservar su interpretación.

2.5 Cómo se obtuvo cada resultado

Gráficas de cada variable (3.1). Se hicieron con los datos originales (227 filas, omitiendo los vacíos de cada variable): un histograma de 20 intervalos con líneas de media y mediana, y un diagrama de caja, con la función *hist_box* del programa.

Medidas descriptivas y covarianza (3.2) y atípicos (3.3). Se calcularon sobre la base depurada (224 países × 13 variables), antes de transformar, con *mean*, *median*, *var*, *std* y *cov*. Los atípicos se contaron con el criterio del RIC antes y después de la transformación logarítmica; los diagramas de caja comparativos usan valores z para que las variables sean comparables.

Correlaciones (3.4). Se calcularon sobre la base transformada (224 × 13) con *corr(method="pearson")*. La clasificación en variables independientes y dependientes se hizo a partir del significado de cada variable y de su mayor correlación con las demás; es una hipótesis razonada, no una prueba.

PCA (3.5). Se aplicó a la base transformada y estandarizada. Calculamos la matriz de covarianza, extrajimos valores y vectores propios con *numpy.linalg.eigh* y los ordenamos de mayor a menor. El signo de una

componente es arbitrario, así que fijamos una convención (CP1 con signo positivo en el PIB per cápita). Verificamos el cálculo con *sklearn.decomposition.PCA* (los valores propios coinciden) y comprobamos que las componentes no están correlacionadas. La simulación de Horn usa 500 repeticiones con semilla fija, de modo que el resultado se puede reproducir. El programa toma como número de componentes la mediana de los tres criterios (4, 2 y 5, por lo que resulta 4); la justificación detallada está en la sección 3.5.

Reconstrucción (3.5). Con las puntuaciones T y los vectores propios V se reconstruye la matriz estandarizada con k componentes, se deshacen la estandarización y el logaritmo, y se compara con la base depurada. El error se mide con la norma de la diferencia entre matrices y, variable por variable, con el R^2 en la escala original (1 menos la suma de cuadrados del error entre la suma de cuadrados total).

Comparación con y sin estandarización (3.6). Se repite el mismo cálculo sobre la misma base transformada, una vez con los datos solo centrados (matriz de covarianza) y otra con datos estandarizados (matriz de correlación). Por eso, "sin estandarizar" significa sin dividir entre la desviación estándar, pero con la transformación logarítmica ya aplicada. Todo el código está en el archivo *exploracion_pca.py*.

3. Resultados

Los resultados se presentan en el orden del flujo de trabajo: gráficas de cada variable (3.1), medidas descriptivas (3.2), valores atípicos (3.3), correlaciones (3.4), componentes principales (3.5) y comparación con y sin estandarización (3.6). Cada resultado lleva una lectura breve; la comparación con las hipótesis, las limitaciones y las mejoras posibles se discuten en la sección 4.

3.1 Gráficas de cada característica

Antes de modificar nada, graficamos cada variable numérica con un histograma y un diagrama de caja. En el histograma la línea discontinua marca la media y la continua la mediana; cuando están muy separadas, la distribución es asimétrica. En el diagrama de caja, la caja va del primer al tercer cuartil, los bigotes llegan hasta 1.5 veces el rango intercuartílico y los círculos son valores atípicos. Las variables se grafican con los datos originales, con los vacíos omitidos en cada una.

```
NUMERICAS = [c for c in raw.columns if c not in ("Region", "Climate")]


def hist_box(x, titulo, unidad, ruta):
    x = x.dropna()
    fig, (a, b) = plt.subplots(1, 2, figsize=(6.6, 1.9),
                               gridspec_kw={"width_ratios": [2.6, 1.6]})
    a.hist(x, bins=20, color=C1, edgecolor="white", linewidth=.4)
    a.axvline(x.mean(), color=C2, ls="--", lw=1, label=f"media = {x.mean():.4g}")
    a.axvline(x.median(), color="black", lw=1, label=f"mediana = {x.median():.4g}")
    a.set_xlabel(unidad); a.set_ylabel("países"); a.set_title(titulo, loc="left", fontsize=8.5)
    a.legend(frameon=False, fontsize=6.5)
    b.boxplot(x, vert=False, widths=.5, medianprops=dict(color="black"),
              flierprops=dict(marker="o", ms=2.5, mfc="none", mec=C2))
    b.set_yticks([]); b.set_xlabel(unidad)
    fig.tight_layout(); fig.savefig(ruta); plt.close(fig)


estad = []
for i, v in enumerate(NUMERICAS):
    hist_box(raw[v], NOMBRES[v], UNIDADES[v], FIG / f"hb_{i:02d}.png")
    x = raw[v].dropna()
    estad.append({"var": v, "nombre": NOMBRES[v], "archivo": f"hb_{i:02d}.png", "n": int(x.size),
                  "nulos": int(raw[v].isna().sum()), "media": x.mean(), "mediana": x.median(),
                  "asim": x.skew(), "atip": int(len(iqr_atipicos(x))),
                  "min": x.min(), "max": x.max(), "pais_max": x.idxmax()})
```

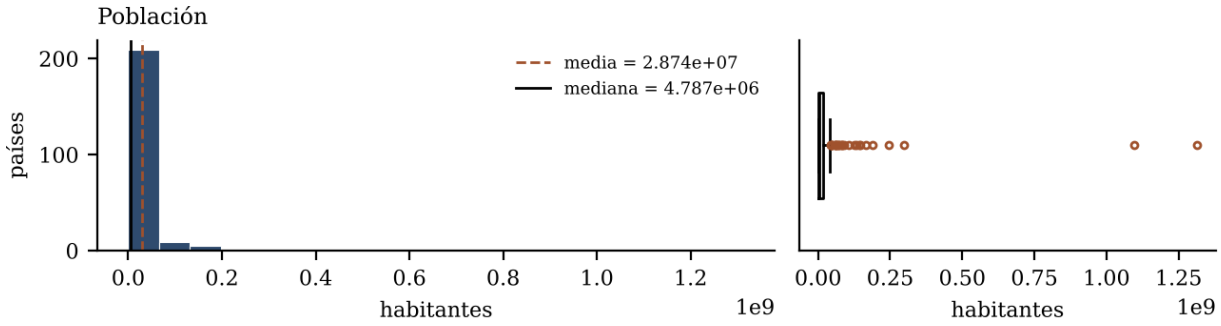


Figura 4. Población. Unos pocos países enormes (China, India, Estados Unidos) contrastan con una mayoría de países pequeños. Asimetría 9.2; media 28,740,284 frente a mediana 4,786,994; 28 valores atípicos por el criterio del rango intercuartílico.

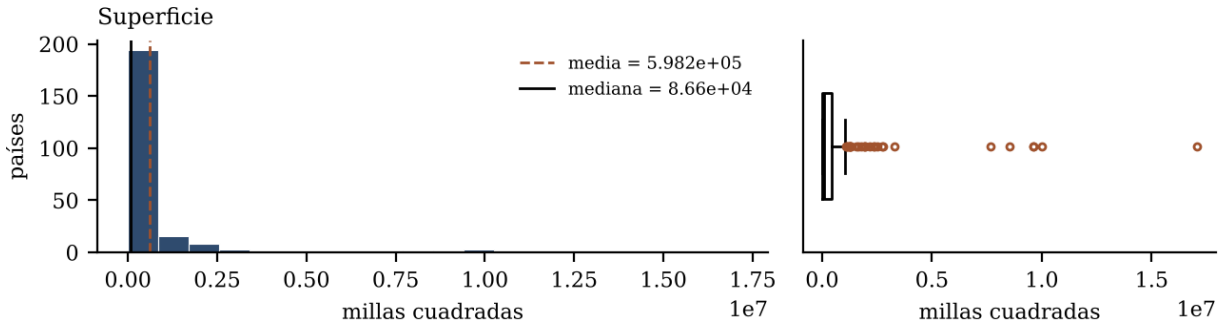


Figura 5. Superficie. Pocos países ocupan superficies muy grandes (Russia, Canada, China); la mayoría son pequeños o islas. Asimetría 6.0; media 598,227 frente a mediana 86,600; 28 valores atípicos por el criterio del rango intercuartílico.

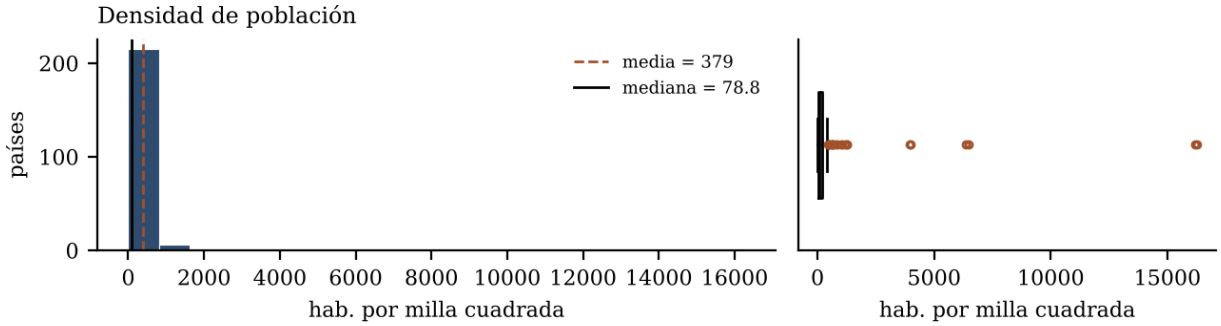


Figura 6. Densidad de población. Casi todos los países tienen pocas centenas de habitantes por milla cuadrada, pero territorios diminutos como Monaco, Macau o Singapore llegan a miles. Asimetría 8.3; media 379.0 frente a mediana 78.80; 21 valores atípicos por el criterio del rango intercuartílico.

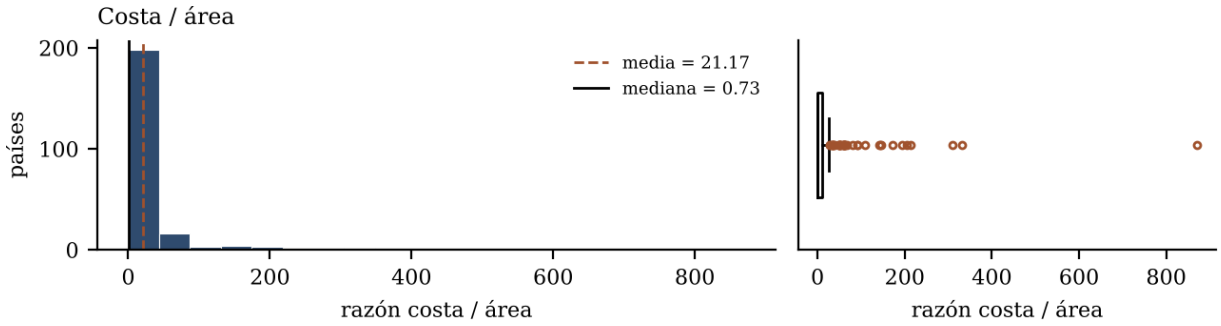


Figura 7. Costa / área. La razón vale cero en países sin litoral y es muy alta en islas pequeñas, lo que alarga la cola derecha. Asimetría 8.2; media 21.17 frente a mediana 0.730; 37 valores atípicos por el criterio del rango intercuartílico.

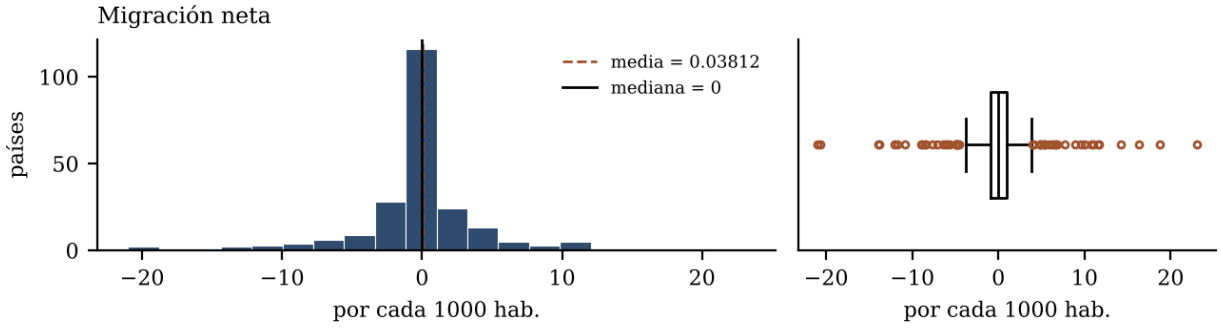


Figura 8. Migración neta. Se concentra alrededor de cero. En 62 de 224 países vale exactamente cero, y es probable que en la fuente ese cero sustituya un dato no disponible. Asimetría 0.1; media 0.038 frente a mediana 0; 50 valores atípicos por el criterio del rango intercuartílico.

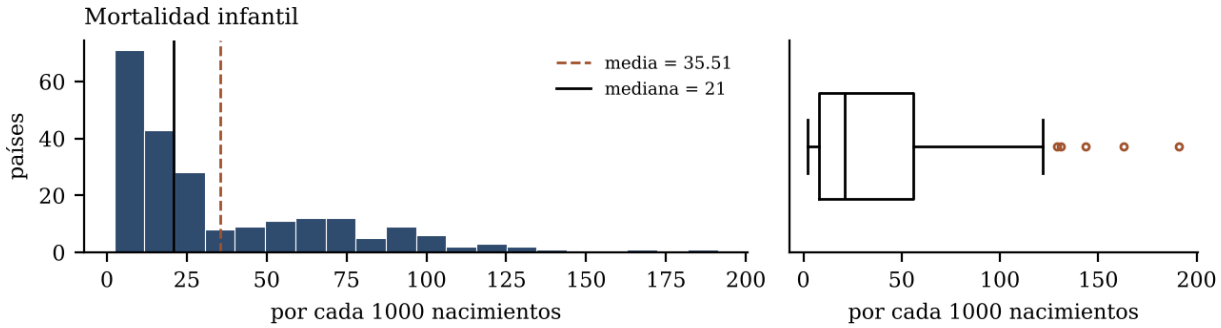


Figura 9. Mortalidad infantil. La mayoría de los países tiene valores bajos; hay una cola de países africanos con más de 100 muertes por cada 1000 nacimientos. Asimetría 1.4; media 35.51 frente a mediana 21.00; 5 valores atípicos por el criterio del rango intercuartílico.

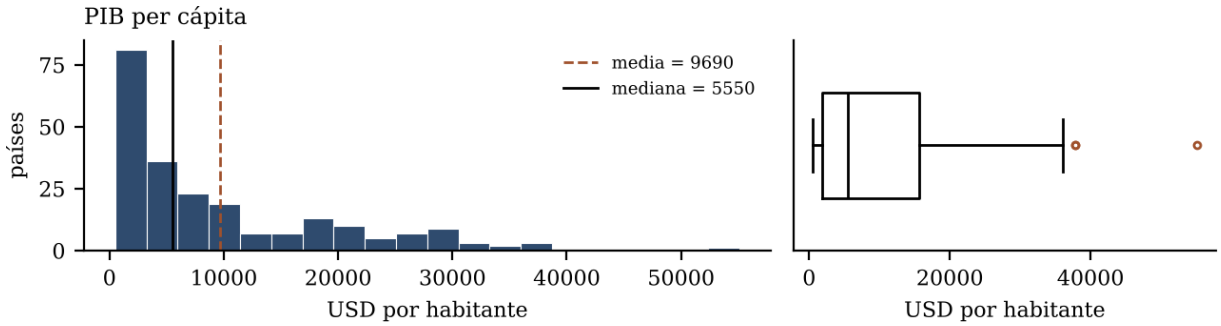


Figura 10. PIB per cápita. Muchos países están por debajo de 10,000 USD y solo unos pocos superan los 30,000 (Luxembourg, Norway, United States). Asimetría 1.4; media 9,689.8 frente a mediana 5,550.0; 3 valores atípicos por el criterio del rango intercuartílico.

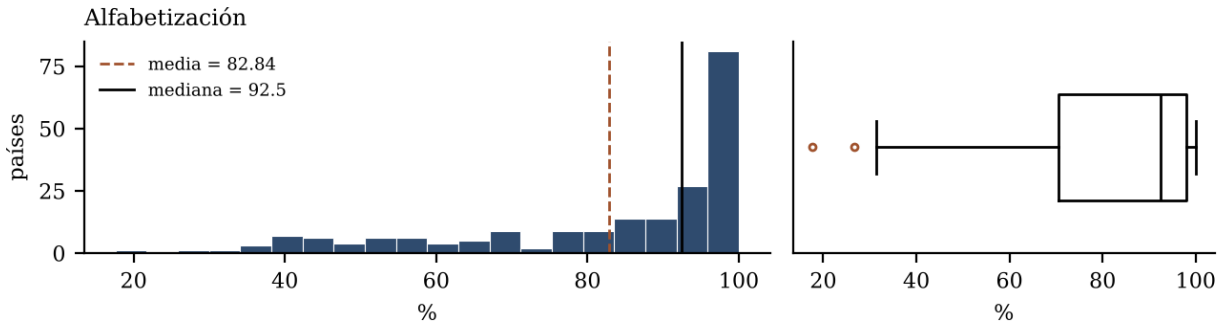


Figura 11. Alfabetización. La distribución se carga hacia el 100 %, con una cola de países de baja alfabetización (sesgo a la izquierda). Asimetría -1.2; media 82.84 frente a mediana 92.50; 2 valores atípicos por el criterio del rango intercuartílico.

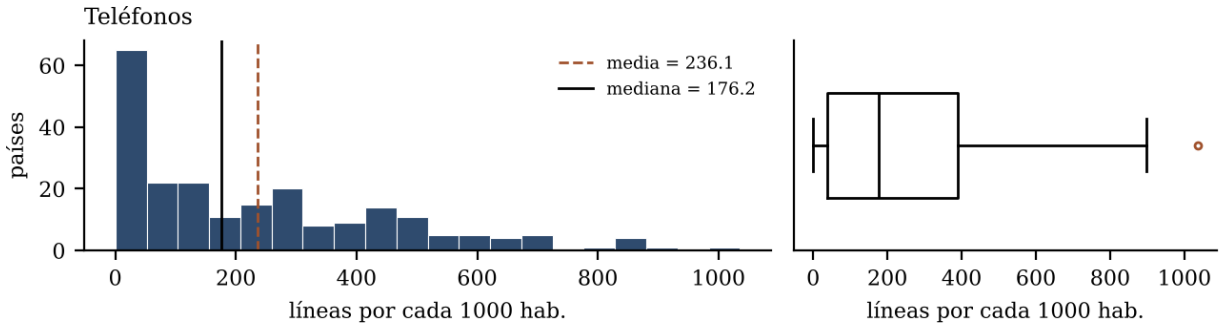


Figura 12. Teléfonos. Cola derecha producida por países con muchísimas líneas por habitante, sobre todo Monaco. Asimetría 1.0; media 236.1 frente a mediana 176.2; 1 valores atípicos por el criterio del rango intercuartílico.

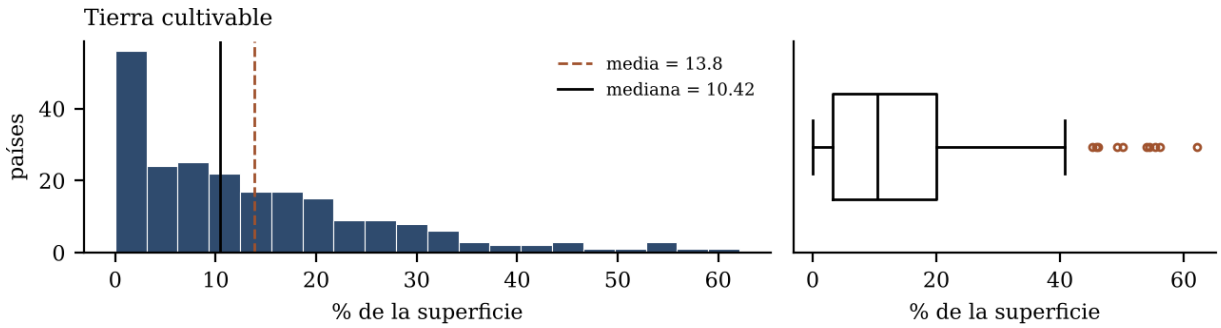


Figura 13. Tierra cultivable. Casi todos los países destinan menos de 30 % a tierra cultivable; Bangladesh es el extremo. Asimetría 1.3; media 13.80 frente a mediana 10.42; 10 valores atípicos por el criterio del rango intercuartílico.

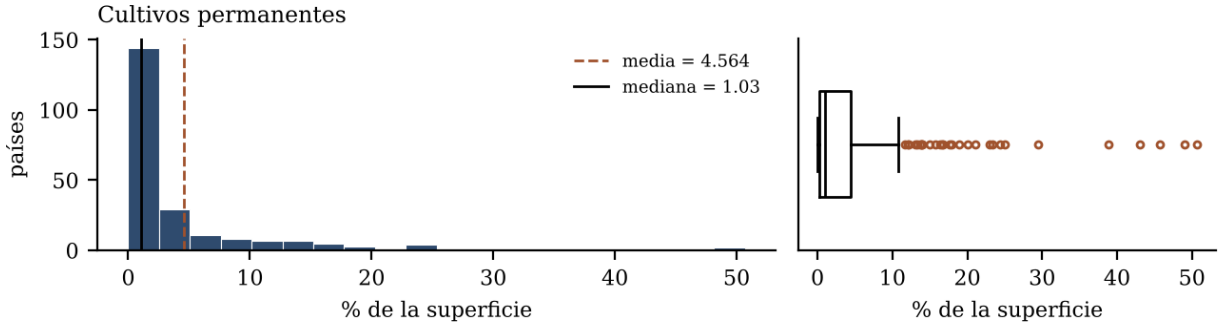


Figura 14. Cultivos permanentes. La mayoría dedica menos de 5 % a cultivos permanentes, pero varias islas pasan del 40 %. Asimetría 3.2; media 4.56 frente a mediana 1.03; 29 valores atípicos por el criterio del rango intercuartílico.

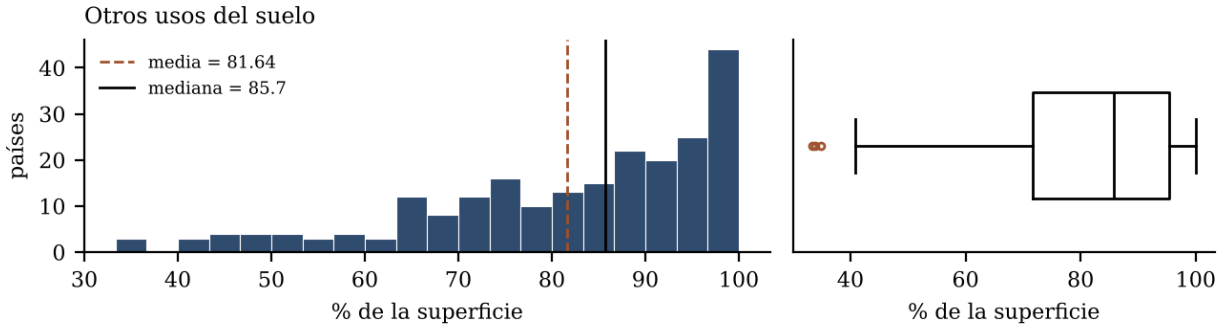


Figura 15. Otros usos del suelo. Es el complemento de las dos variables anteriores (se comprueba en la sección 2), por lo que no aporta información nueva. Asimetría -1.0; media 81.64 frente a mediana 85.70; 3 valores atípicos por el criterio del rango intercuartílico.

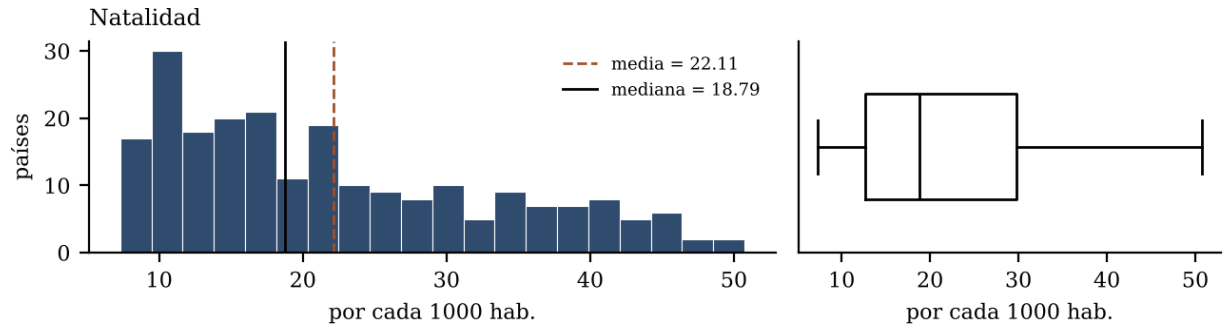


Figura 16. Natalidad. Distribución bastante simétrica, sin valores atípicos por el criterio del rango intercuartílico. Asimetría 0.7; media 22.11 frente a mediana 18.79; 0 valores atípicos por el criterio del rango intercuartílico.

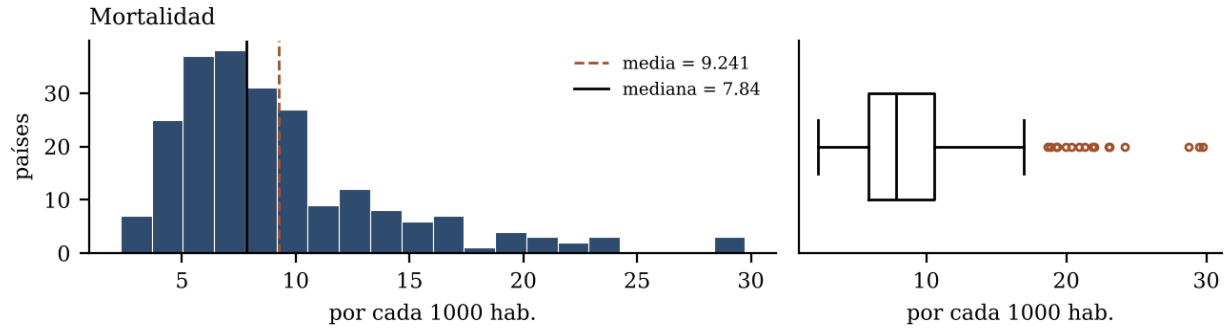


Figura 17. Mortalidad. Concentrada entre 5 y 12; los atípicos son países del sur de África (Swaziland, Botswana, Lesotho). Asimetría 1.7; media 9.24 frente a mediana 7.84; 16 valores atípicos por el criterio del rango intercuartílico.

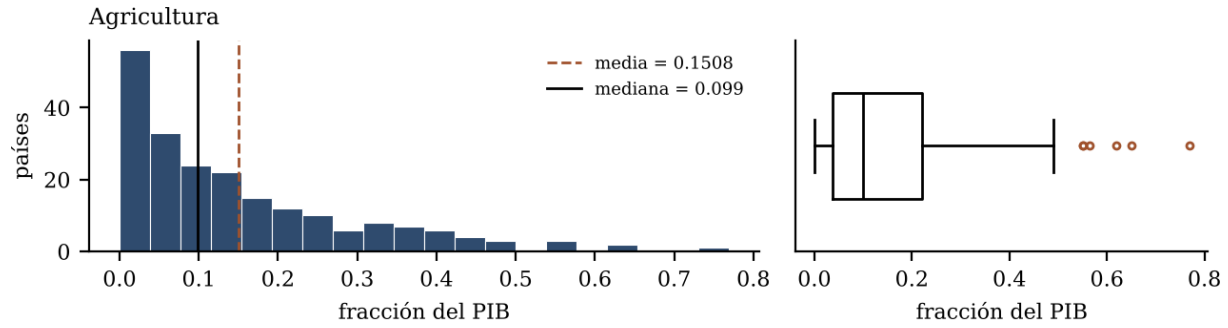


Figura 18. Agricultura. La mayoría de los países depende poco de la agricultura; los extremos (Liberia, Somalia) superan 60 % del PIB. Asimetría 1.4; media 0.151 frente a mediana 0.099; 6 valores atípicos por el criterio del rango intercuartílico.

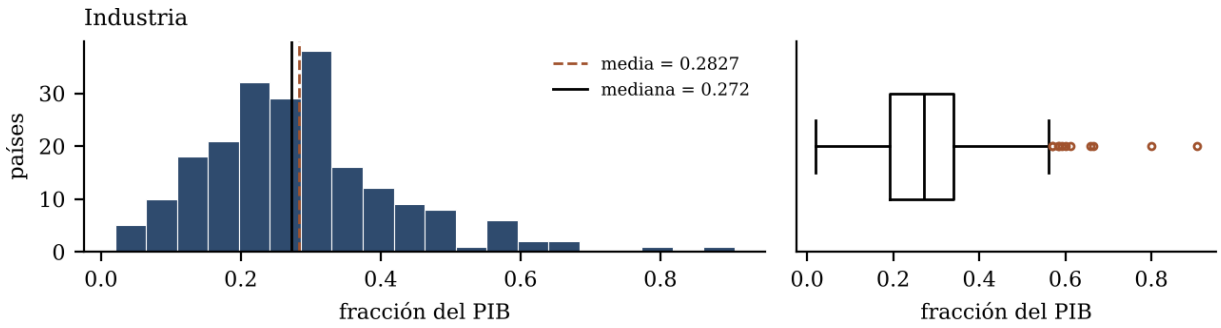


Figura 19. Industria. Distribución con cola derecha moderada; el máximo es Equatorial Guinea. Asimetría 1.1; media 0.283 frente a mediana 0.272; 11 valores atípicos por el criterio del rango intercuartílico.

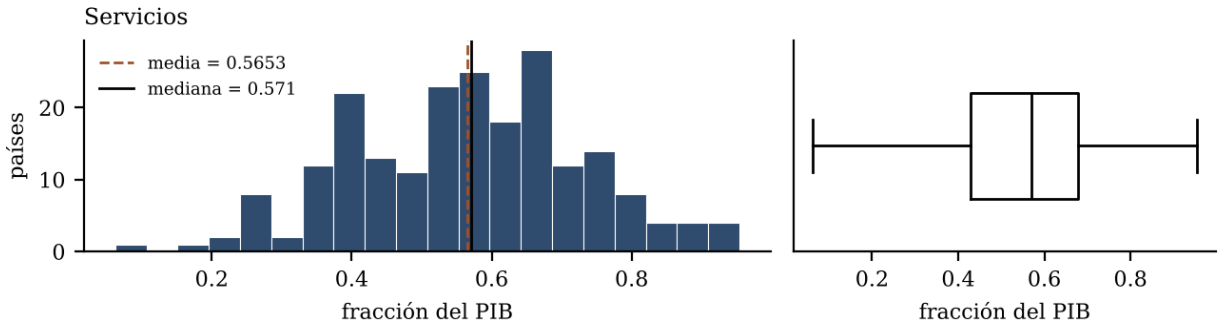


Figura 20. Servicios. Es la más simétrica de todas, sin valores atípicos. Asimetría -0.1; media 0.565 frente a mediana 0.571; 0 valores atípicos por el criterio del rango intercuartílico.

En conjunto, casi todas las variables tienen asimetría positiva (la media es mayor que la mediana). Las más asimétricas son población, superficie, densidad, costa/área y cultivos permanentes, con coeficientes de asimetría de 3.2 a 9.2. Esto anticipa que algunas necesitarán una transformación antes de calcular correlaciones y componentes principales, algo que se resuelve en la sección 2.

3.2 Medidas descriptivas

Calculamos las medidas descriptivas con las 13 variables elegidas, ya depuradas pero todavía en su escala original (así se pueden interpretar). La media resume el centro, pero se mueve con los valores extremos; la mediana no. Por eso comparar ambas dice si hay asimetría. La varianza mide la dispersión alrededor de la media, y su raíz cuadrada (desviación estándar) está en las mismas unidades que la variable:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad\qquad s^2(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

$$\mathrm{Cov}(X, Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

Los símbolos son los definidos en la sección 1.4: n es el número de países, x_i y y_i son los valores de cada variable en el país i, y la barra sobre una letra indica su media.

```
desc = pd.DataFrame({
    "media": datos[VARS].mean(), "mediana": datos[VARS].median(),
```

```
    "varianza": datos[VARS].var(), "desv_est": datos[VARS].std(),
    "minimo": datos[VARS].min(), "maximo": datos[VARS].max()})
cov_orig = datos[VARS].cov()            # covarianza en unidades originales
clave = ["GDP ($ per capita)", "Infant mortality (per 1000 births)", "Literacy (%)",
         "Phones (per 1000)", "Birthrate"]
print(desc.round(3))
print(cov_orig.loc[clave, clave].round(1))
```

Tabla 3. Medidas descriptivas de las 13 variables elegidas (224 países, escala original).

Variable	Media	Mediana	Varianza	Desv. est.	Mínimo	Máximo
Densidad de población	381.5	79.15	2,792,075	1,671.0	0	16,272
Costa / área	21.02	0.725	5,287.1	72.71	0	870.7
Migración neta	0.008	0	23.70	4.87	-20.99	23.06
Mortalidad infantil	35.28	20.94	1,251.5	35.38	2.29	191.2
PIB per cápita	9,748.2	5,700.0	101,501,163	10,075	500.0	55,100
Alfabetización	83.91	92.90	370.6	19.25	17.60	100.0
Teléfonos	236.5	180.3	51,670	227.3	0.200	1,035.6
Tierra cultivable	13.91	10.60	169.6	13.02	0	62.11
Cultivos permanentes	4.47	1.02	68.34	8.27	0	50.68
Natalidad	21.98	18.75	124.0	11.14	7.29	50.73
Mortalidad	9.24	7.97	24.84	4.98	2.29	29.74
Agricultura	0.148	0.098	0.021	0.145	0	0.769
Servicios	0.572	0.581	0.027	0.164	0.062	0.954

La media supera a la mediana en 11 de las 13 variables (todas salvo alfabetización y servicios), lo que confirma la asimetría derecha. El caso más claro es costa/área, con media 21.0 y mediana 0.73, y también densidad de población (381 contra 79). En el PIB per cápita la media (9,748) casi duplica a la mediana (5,700): un país "típico" tiene un ingreso mucho menor al que sugiere el promedio.

Tabla 4. Matriz de covarianza (escala original) de cinco indicadores de desarrollo. La diagonal contiene las varianzas.

	PIB per cápita	Mortalidad infantil	Alfabetización	Teléfonos	Natalidad
PIB per cápita	101,501,163	-212,989	97,969	1,904,505	-72,175
Mortalidad infantil	-212,989	1,251.5	-524.5	-5,379.0	333.3
Alfabetización	97,969	-524.5	370.6	2,558.4	-167.4
Teléfonos	1,904,505	-5,379.0	2,558.4	51,670	-1,825.9
Natalidad	-72,175	333.3	-167.4	-1,825.9	124.0

Elegimos estas cinco variables para mostrar la covarianza porque son las que, como veremos en la sección 3.4, más se relacionan entre sí. Los signos tienen sentido: el PIB per cápita covaría positivamente con los teléfonos y la alfabetización, y negativamente con la mortalidad infantil y la natalidad. Sin embargo, las magnitudes no son comparables entre pares: la covarianza entre PIB y teléfonos (1,904,505) es enorme solo porque el PIB se mide en miles de dólares, mientras que la varianza de la natalidad es 124. La covarianza depende de las unidades, y por eso en la sección 3.4 pasamos a la correlación, que no tiene unidades.

3.3 Datos atípicos

Un valor es atípico por el criterio del rango intercuartílico (RIC) si queda más allá de 1.5 veces el RIC por debajo del primer cuartil o por encima del tercero. Contamos esos valores en cada variable antes y después de la transformación de la sección 2, y comparamos las variables en una escala común (valores z) para ver cuáles tienen colas más pesadas.

```
def zscores(df):
    return (df[VARS] - df[VARS].mean()) / df[VARS].std()

at_antes = {v: iqr_atipicos(datos[v]) for v in VARS}
at_despues = {v: iqr_atipicos(trans[v]) for v in VARS}
fig, (a, b) = plt.subplots(1, 2, figsize=(6.6, 3.2), sharey=True)
for ax, df, t in ((a, datos, "Datos depurados"), (b, trans, "Tras la transformación")):
    ax.boxplot(zscores(df).values, vert=False, widths=.6, medianprops=dict(color="black"),
               flierprops=dict(marker="o", ms=2, mfc="none", mec=C2))
    ax.set_title(t, loc="left", fontsize=8); ax.set_xlabel("valor estandarizado (z)")
a.set_yticks(range(1, len(VARS) + 1))
a.set_yticklabels([NOMBRES[v] for v in VARS], fontsize=6.5)
fig.tight_layout(); fig.savefig(FIG / "fig_atipicos.png")
```

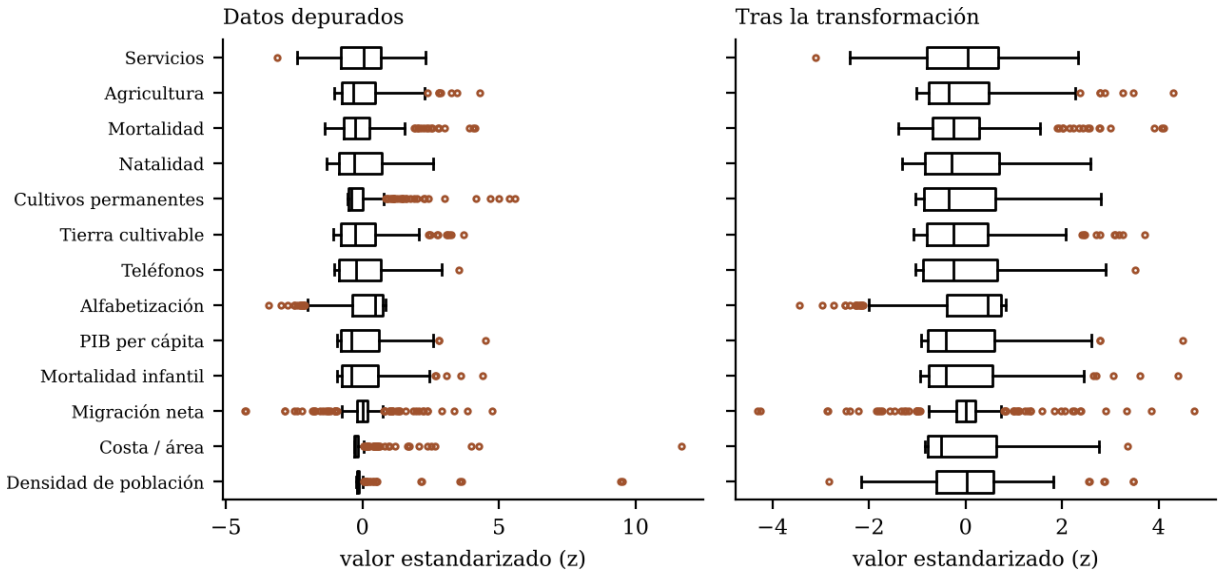


Figura 21. Diagramas de caja de las 13 variables estandarizadas, con los datos depurados (izquierda) y tras la transformación (derecha).

Tabla 5. Valores atípicos por el criterio del RIC. Natalidad no tiene ninguno y no aparece.

Variable	Atípicos antes	Atípicos después	Casos más alejados (datos depurados)
Densidad de población	20	7	Monaco, Macau, Singapore
Costa / área	37	1	Micronesia, Fed. St., Palau, N. Mariana Islands
Migración neta	50	50	Afghanistan, Micronesia, Fed. St., American Samoa
Mortalidad infantil	5	5	Angola, Afghanistan, Sierra Leone
PIB per cápita	3	3	Luxembourg, Norway, United States
Alfabetización	16	16	Niger, Burkina Faso, Sierra Leone
Teléfonos	1	1	Monaco
Tierra cultivable	10	10	Bangladesh, Ukraine, Moldova
Cultivos permanentes	28	0	Kiribati, Sao Tome & Principe, Micronesia, Fed. St.
Mortalidad	16	16	Swaziland, Botswana, Lesotho

Variable	Atípicos antes	Atípicos después	Casos más alejados (datos depurados)
Agricultura	7	7	Liberia, Somalia, Guinea-Bissau
Servicios	1	1	Equatorial Guinea

No eliminamos ningún país por ser atípico. Los casos extremos son valores reales y esperables: Luxembourg tiene el PIB per cápita más alto de la muestra, Monaco el mayor número de teléfonos por habitante y Macau la mayor densidad, no son errores de captura. Quitarlos haría que el estudio dejara fuera justamente a los países que más contrastan. En su lugar, reducimos su influencia de dos maneras: la transformación logarítmica (que baja los atípicos de densidad de 20 a 7, de costa/área de 37 a 1 y de cultivos permanentes de 28 a 0) y la estandarización que se discute en la sección 3.6.

Un caso aparte es migración neta, con 50 atípicos. Aquí el criterio engaña: como 62 países tienen exactamente cero, el rango intercuartílico es muy angosto y valores de apenas unas unidades quedan señalados. La variable va solo de −21 a 23, de modo que no tiene valores realmente extremos y la dejamos sin cambios. Mortalidad (16) y alfabetización (16) se mantienen por la misma razón: son países reales con situaciones distintas, como el sur de África con alta mortalidad.

3.4 Correlaciones y relación entre variables

3.4.1 Covarianza y correlación de Pearson

Como se vio en la sección 3.2, la covarianza depende de las unidades. El coeficiente de correlación de Pearson la divide entre las desviaciones estándar de ambas variables:

$$r(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\,\sigma(Y)}$$

Aquí σ(X) y σ(Y) son las desviaciones estándar de X y de Y. Así el resultado queda entre −1 y 1, sin unidades: valores cercanos a 1 indican que las variables crecen juntas, cercanos a −1 que una crece cuando la otra baja y cercanos a 0 que no hay relación lineal. A partir de aquí trabajamos con la base transformada (la que usaremos en el PCA). La Figura de covarianza muestra por qué la covarianza sola es difícil de leer: el PIB per cápita, con varianza del orden de 10^8, domina todo el mapa de color.

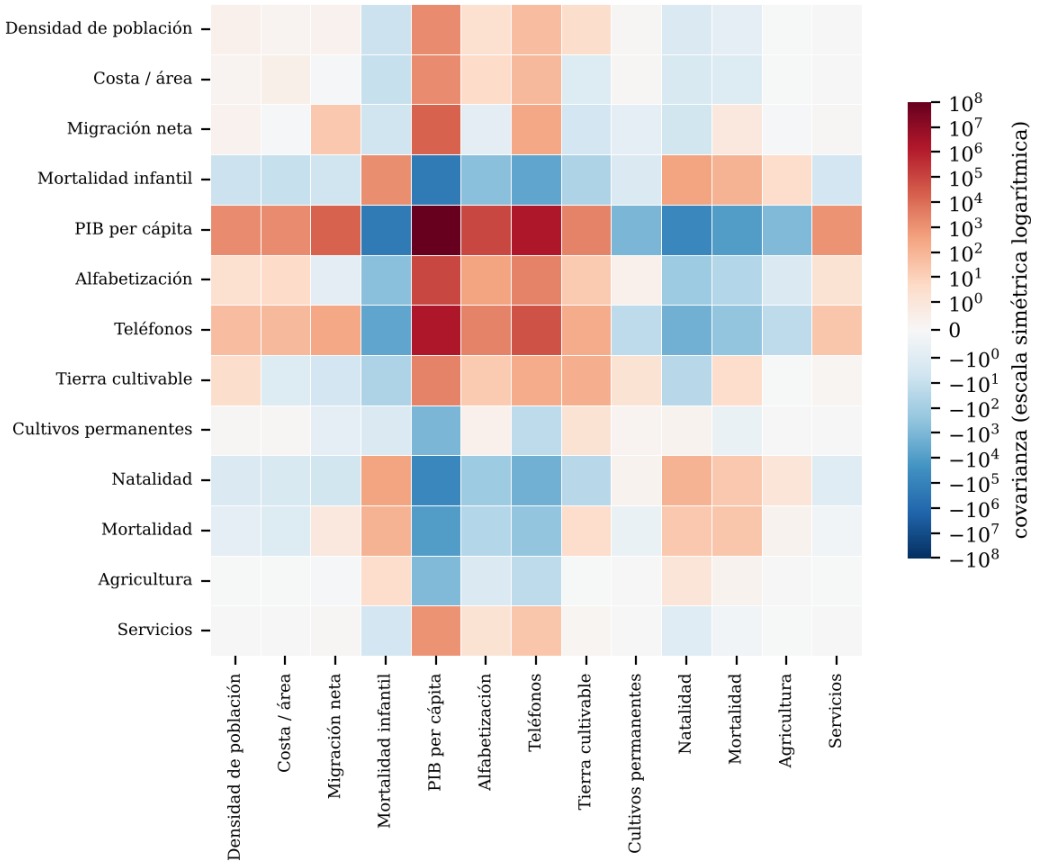


Figura 22. Matriz de covarianza de las 13 variables (escala simétrica logarítmica para que se aprecien todas las magnitudes).

3.4.2 Matriz de correlación

```
corr = trans[VARS].corr(method="pearson")
etq = [NOMBRES[v] for v in VARS]
fig, ax = plt.subplots(figsize=(6.4, 5.3))
sns.heatmap(corr, annot=True, fmt=".2f", cmap="RdBu_r", vmin=-1, vmax=1, square=True,
            linewidths=.3, annot_kws={"size": 5.5}, cbar_kws={"shrink": .7},
            xticklabels=etq, yticklabels=etq, ax=ax)
ax.tick_params(labelsize=6.5)
fig.tight_layout(); fig.savefig(FIG / "fig_corr.png")
```

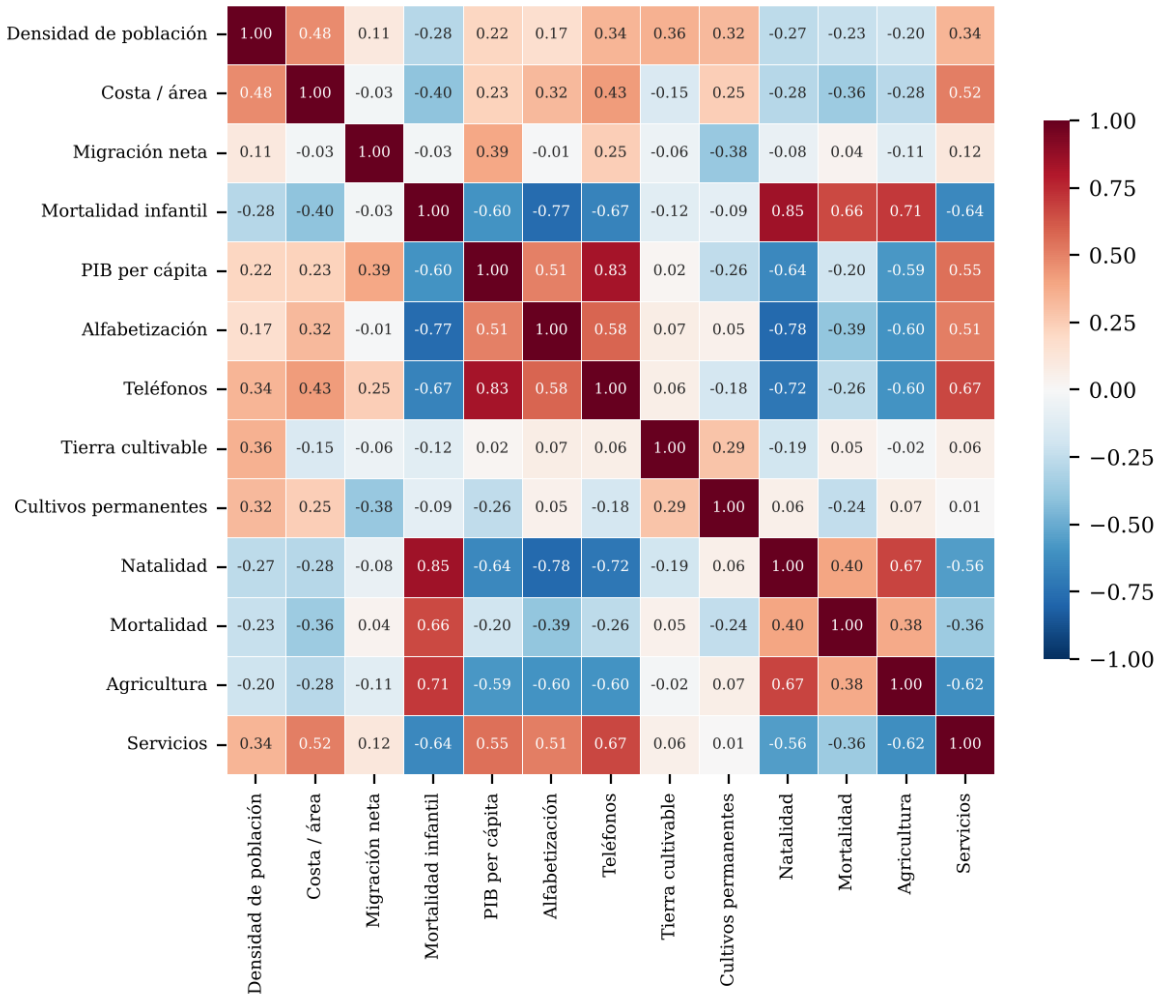


Figura 23. Matriz de correlación de Pearson de las 13 variables (base transformada).

De los 78 pares distintos de variables, 23 tienen correlación de al menos 0.5 en valor absoluto y 2 superan 0.8. La diagonal vale 1 porque cada variable se correlaciona perfectamente consigo misma, y la matriz es simétrica.

Tabla 6. Los ocho pares con mayor correlación en valor absoluto.

Par de variables	**r**
Natalidad y Mortalidad infantil	0.85
Teléfonos y PIB per cápita	0.83
Natalidad y Alfabetización	-0.78
Alfabetización y Mortalidad infantil	-0.77
Natalidad y Teléfonos	-0.72
Agricultura y Mortalidad infantil	0.71
Agricultura y Natalidad	0.67
Servicios y Teléfonos	0.67

Se forma un bloque claro: la natalidad, la mortalidad infantil y la proporción de agricultura se mueven juntas y en sentido contrario al PIB, los teléfonos, la alfabetización y los servicios. Es decir, varias columnas están diciendo casi lo mismo, el grado de desarrollo del país. En cambio, la tierra cultivable y los cultivos permanentes casi no se relacionan con ese bloque (por ejemplo, $|r| = 0.09$ entre cultivos permanentes y mortalidad infantil). Esta redundancia es lo que hace útil un PCA.

3.4.3 Variables independientes y dependientes

Para separar variables que actúan como punto de partida de las que parecen depender de otras, usamos dos pistas: el sentido que tiene cada variable (una característica física del territorio no depende del ingreso de un país; la mortalidad infantil sí puede depender de él) y qué tan fuerte es su correlación con las demás. La Tabla 7 resume la clasificación junto con la mayor correlación de cada variable.

Tabla 7. Clasificación de las variables según su papel y mayor correlación con otra variable.

Variable	**Papel**	**Justificación**	**Mayor |r| (con)**
Densidad de población	Independiente	Es una condición de partida (población entre superficie).	0.48 (Costa / área)
Costa / área	Independiente	Es una característica geográfica fija.	0.52 (Servicios)
Migración neta	Dependiente (débil)	Responde a condiciones económicas, pero su relación lineal es baja.	0.39 (PIB per cápita)
Mortalidad infantil	Dependiente	Resultado de la salud y el ingreso; muy ligada a la natalidad.	0.85 (Natalidad)
PIB per cápita	Dependiente	Se mueve con la infraestructura (teléfonos) y la educación.	0.83 (Teléfonos)
Alfabetización	Dependiente	Resultado de la educación, relacionada con el desarrollo.	0.78 (Natalidad)
Teléfonos	Dependiente	Indicador de infraestructura que acompaña al ingreso.	0.83 (PIB per cápita)
Tierra cultivable	Independiente	Depende del suelo y del clima, no del ingreso.	0.36 (Densidad de población)
Cultivos permanentes	Independiente	Depende del suelo y del clima.	0.38 (Migración neta)
Natalidad	Dependiente	Cambia con el nivel de desarrollo y educación.	0.85 (Mortalidad infantil)
Mortalidad	Dependiente	Depende de la edad de la población y de la salud.	0.66 (Mortalidad infantil)
Agricultura	Dependiente	Su peso disminuye al crecer la economía.	0.71 (Mortalidad infantil)
Servicios	Dependiente	Su peso aumenta al crecer la economía.	0.67 (Teléfonos)

Las cuatro variables que clasificamos como independientes tienen correlaciones máximas bajas (entre 0.36 y 0.52), lo que es coherente con que no las determine el resto. Las dependientes forman el bloque con correlaciones de 0.66 a 0.85. La correlación no demuestra causalidad, de modo que la clasificación debe leerse como una hipótesis razonable: por ejemplo, el PIB y los teléfonos pueden influirse mutuamente. Si más adelante se quisiera ajustar un modelo, buenas variables respuesta serían el PIB per cápita o la mortalidad infantil, explicadas con las condiciones geográficas y demográficas.

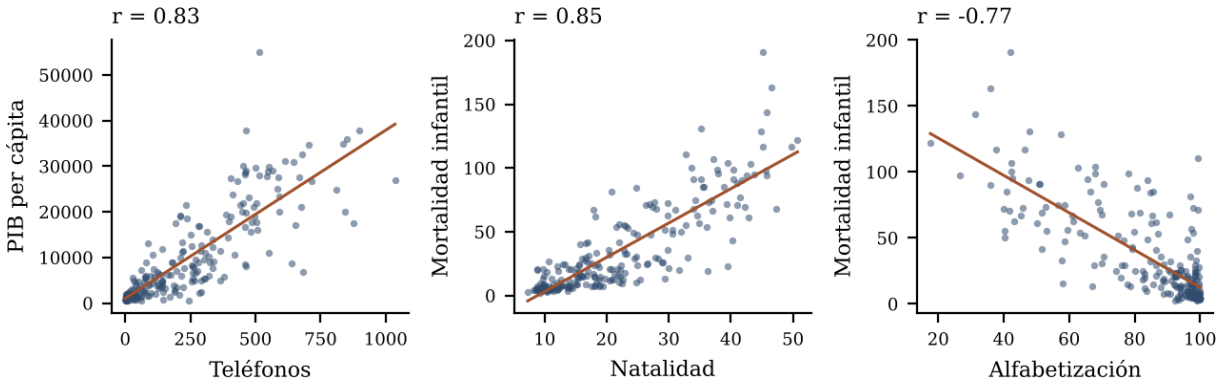


Figura 24. Tres relaciones entre variables dependientes, con su recta de ajuste y su coeficiente de correlación.

3.5 Componentes principales (PCA)

3.5.1 Qué ventaja ofrece el PCA

Con 13 variables y una estructura de correlación como la de la sección 3.4, trabajar variable por variable es redundante. El PCA construye combinaciones lineales de las variables (las componentes principales, CP) que están ordenadas por la varianza que explican y no están correlacionadas entre sí. Las ventajas concretas para estos datos son:

Primero, la reducción: veremos que 4 componentes conservan alrededor de 77 % de la información de las 13 variables. Segundo, la eliminación de redundancia: las componentes son ortogonales, y lo verificamos numéricamente, pues la mayor covarianza entre dos componentes es 3.3e-15, es decir, cero salvo error de redondeo. Tercero, la visualización: las dos primeras componentes (57.8 % de la varianza) permiten dibujar a los países en un plano. Cuarto, en un modelo posterior las componentes evitan la multicolinealidad entre las variables originales. A cambio, perdemos parte de la información (lo que queda fuera de las componentes elegidas) y las componentes son más difíciles de interpretar que las variables originales.

3.5.2 Cómo se calculan

El procedimiento es el siguiente. Se centran los datos restando la media de cada variable; se calcula la matriz de covarianza; se obtienen sus valores propios λ y vectores propios; cada vector propio da los coeficientes de una componente y su valor propio es la varianza de esa componente. La proporción de varianza explicada por la componente i es λ_i / Σλ, donde λ_i es el valor propio de la componente *i* y Σλ es la suma de todos los valores propios (la varianza total). Las puntuaciones (scores) de cada país se obtienen multiplicando los datos centrados por los vectores propios.

Calculamos el PCA de dos formas: con la matriz de covarianza de los datos sin estandarizar y con la de los datos estandarizados (cada variable dividida entre su desviación estándar). Como se anota en el pizarrón, la matriz de covarianza de los datos estandarizados es igual a la matriz de correlación; lo comprobamos en el programa. Programamos el cálculo con los valores propios directamente y lo comparamos con la función PCA de scikit-learn, con coincidencia total en los valores propios (verificado).

```
X = trans[VARS].to_numpy(float)
Xc = X - X.mean(axis=0)                    # datos centrados
S = np.cov(Xc, rowvar=False)               # covarianza sin estandarizar
Z = Xc / X.std(axis=0, ddof=1)             # datos estandarizados
```

```
R = np.cov(Z, rowvar=False)                  # covarianza de los estandarizados
print("cov(Z) coincide con la matriz de correlación:", np.allclose(R, np.corrcoef(X, rowvar=False)))


def pca_manual(M):
    valores, vectores = np.linalg.eigh(M)
    orden = np.argsort(valores)[::-1]
    valores, vectores = valores[orden], vectores[:, orden]
    for j in range(vectores.shape[1]):        # signo: CP1 con PIB positivo; en las demás, la mayor
        carga positiva
        ref = VARS.index("GDP ($ per capita)") if j == 0 else np.abs(vectores[:, j]).argmax()
        if vectores[ref, j] < 0:
            vectores[:, j] *= -1
    return valores, vectores


val_s, vec_s = pca_manual(S)                 # sin estandarizar
val_z, vec_z = pca_manual(R)                 # estandarizados
```

3.5.3 Por qué elegimos cuatro componentes

El número de componentes no se puede escoger al azar, así que usamos tres criterios sobre el caso estandarizado, que es el que tiene sentido interpretar (la sección 3.6 lo justifica):

El criterio de Kaiser conserva las componentes con valor propio mayor que 1, es decir, las que explican más varianza que una variable original estandarizada; da 4 componentes. La simulación de Horn compara cada valor propio con el que se obtendría por azar con datos sin estructura (percentil 95 de 500 simulaciones); da 2. El criterio de la varianza acumulada pide llegar a una proporción alta, aquí 80 %; da 5. Además, la gráfica de sedimentación (scree plot) muestra un codo después de la segunda componente.

```
p = len(VARS)
prop_z = val_z / val_z.sum()
acum_z = np.cumsum(prop_z)
rng = np.random.default_rng(0)
sim = np.array([np.sort(np.linalg.eigvalsh(np.corrcoef(rng.standard_normal((len(X), p)),
    rowvar=False)))[::-1]
                for _ in range(500)])
horn = np.percentile(sim, 95, axis=0)        # simulación de Horn (valores propios esperados por
    azar)
k_kaiser = int((val_z > 1).sum())
k_horn = int((val_z > horn).sum())
k_80 = int(np.argmax(acum_z >= .80) + 1)
k = int(np.median([k_kaiser, k_horn, k_80]))
print("Kaiser:", k_kaiser, "| Horn:", k_horn, "| 80 %:", k_80, "| elegido:", k)
print(np.round(val_z, 2)); print(np.round(100 * acum_z, 1))
```

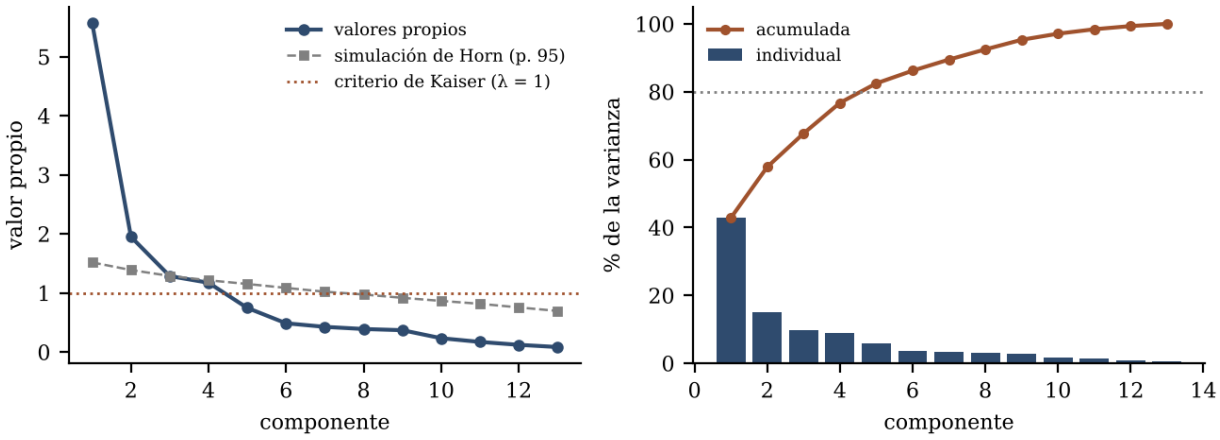


Figura 25. Izquierda: valores propios, umbral de Kaiser y valores esperados por azar. Derecha: varianza explicada individual y acumulada.

Tabla 8. Valores propios de la matriz de correlación (primeras seis componentes).

Componente	Valor propio	% de varianza	% acumulado	Umbral por azar (Horn)
CP1	5.57	42.8	42.8	1.52
CP2	1.95	15.0	57.8	1.39
CP3	1.29	9.9	67.7	1.29
CP4	1.17	9.0	76.7	1.21
CP5	0.75	5.7	82.5	1.15
CP6	0.49	3.7	86.2	1.08

Los criterios no coinciden. Kaiser pide 4, la simulación de Horn solo 2 y la varianza acumulada 5. Elegimos 4 componentes por tres razones. La CP3 y la CP4 tienen valores propios de 1.29 y 1.17, por encima de 1, y juntas aportan 18.9 % de la varianza. Con 4 componentes se explica 76.7 %, cercano al 80 % y mucho más que el 57.8 % de dos componentes. Y, como se ve en la siguiente subsección, la CP3 y la CP4 tienen una interpretación geográfica clara. La CP5 (0.75) queda por debajo de 1 y no la incluimos aunque con ella se pasaría de 80 %. Reconocemos que la CP3 y la CP4 son marginales (sus valores propios están cerca del umbral), así que la parte sólida del resultado son las dos primeras componentes.

3.5.4 Interpretación de las componentes

Los coeficientes de cada componente se interpretan mejor como cargas, es decir, como la correlación entre cada variable original y la componente. Una carga grande en valor absoluto indica que esa variable pesa mucho en la componente.

```
cargas = vec_z * np.sqrt(val_z)              # correlación entre variable y componente
CP = [f"CP{i}" for i in range(1, p + 1)]
tabla_cargas = pd.DataFrame(cargas, index=[NOMBRES[v] for v in VARS], columns=CP)
scores_z = Z @ vec_z
off = np.abs(np.cov(scores_z, rowvar=False) - np.diag(val_z)).max()
print(tabla_cargas.iloc[:, :k + 1].round(2))
print("covarianza entre componentes (máx. fuera de la diagonal):", f"{off:.1e}")
```

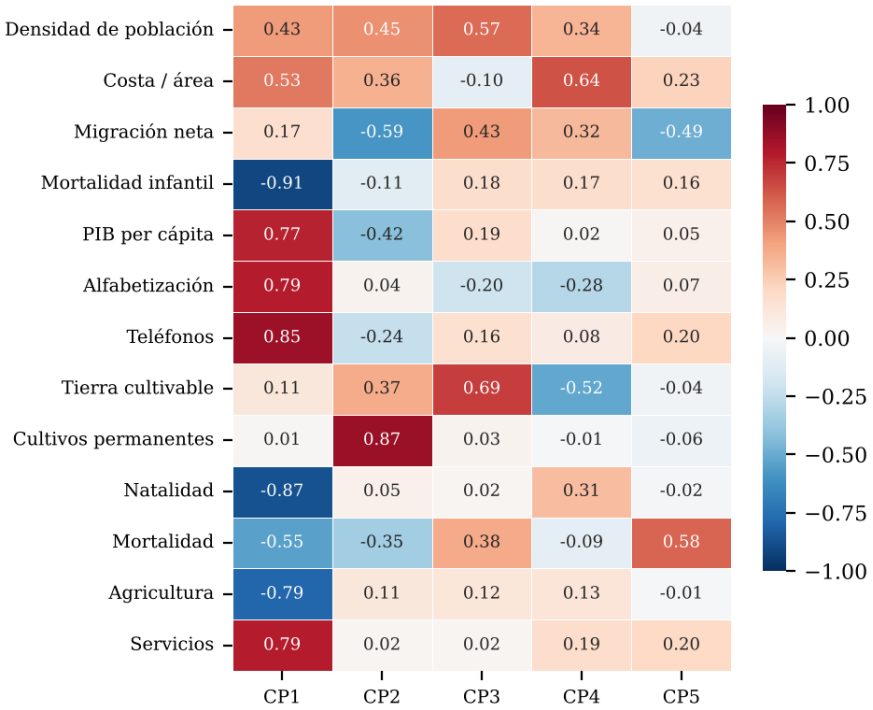


Figura 26. Cargas de las variables en las primeras cinco componentes (rojo: positivas; azul: negativas).

La CP1 (42.8 % de la varianza) separa a los países por nivel de desarrollo: pesan a favor el PIB per cápita (0.77), los teléfonos (0.85), la alfabetización (0.79) y los servicios (0.79), y en contra la mortalidad infantil (−0.91), la natalidad (−0.87), la agricultura (−0.79) y la mortalidad (−0.55). Una puntuación alta indica un país con ingreso, infraestructura y educación altos y una población con baja natalidad.

La CP2 (15.0 %) está dominada por los cultivos permanentes (0.87), con aportes de la migración neta (−0.59), la densidad (0.45), el PIB (−0.42) y la costa/área (0.36). Describe un perfil de territorios pequeños, con mucha costa y densidad, cultivos permanentes y emigración, típico de islas. Esta lectura es nuestra interpretación y no algo que los datos afirmen por sí mismos.

La CP3 (9.9 %) mezcla tierra cultivable (0.69) y densidad (0.57), con migración neta y mortalidad: la intensidad del uso agrícola del territorio y su relación con la población. La CP4 (9.0 %) contrapone la razón costa/área (0.64) con la tierra cultivable (−0.52): geografía costera frente a tierra de cultivo.

3.5.5 Los países en el plano de las dos primeras componentes

```
grupos = trans["Region"].map(GRUPO)
fig, ax = plt.subplots(figsize=(6.4, 4.8))
for g, c in COLORES.items():
    m = (grupos == g).to_numpy()
    ax.scatter(scores_z[m, 0], scores_z[m, 1], s=14, color=c, alpha=.75, linewidths=0, label=g)
esc = 0.85 * np.abs(scores_z[:, :2]).max() / np.abs(cargas[:, :2]).max()
for i, v in enumerate(VARS):
    ax.arrow(0, 0, esc * cargas[i, 0], esc * cargas[i, 1], color="black", lw=.6, head_width=.08)
    ax.text(esc * cargas[i, 0] * 1.07, esc * cargas[i, 1] * 1.07, NOMBRES[v], fontsize=6.2)
ax.axhline(0, color="gray", lw=.4); ax.axvline(0, color="gray", lw=.4)
ax.set_xlabel(f"CP1 ({100 * prop_z[0]:.1f} % de la varianza)")
ax.set_ylabel(f"CP2 ({100 * prop_z[1]:.1f} % de la varianza)")
ax.legend(frameon=False, fontsize=6.5, loc="lower left")
fig.tight_layout(); fig.savefig(FIG / "fig_biplot.png")
```

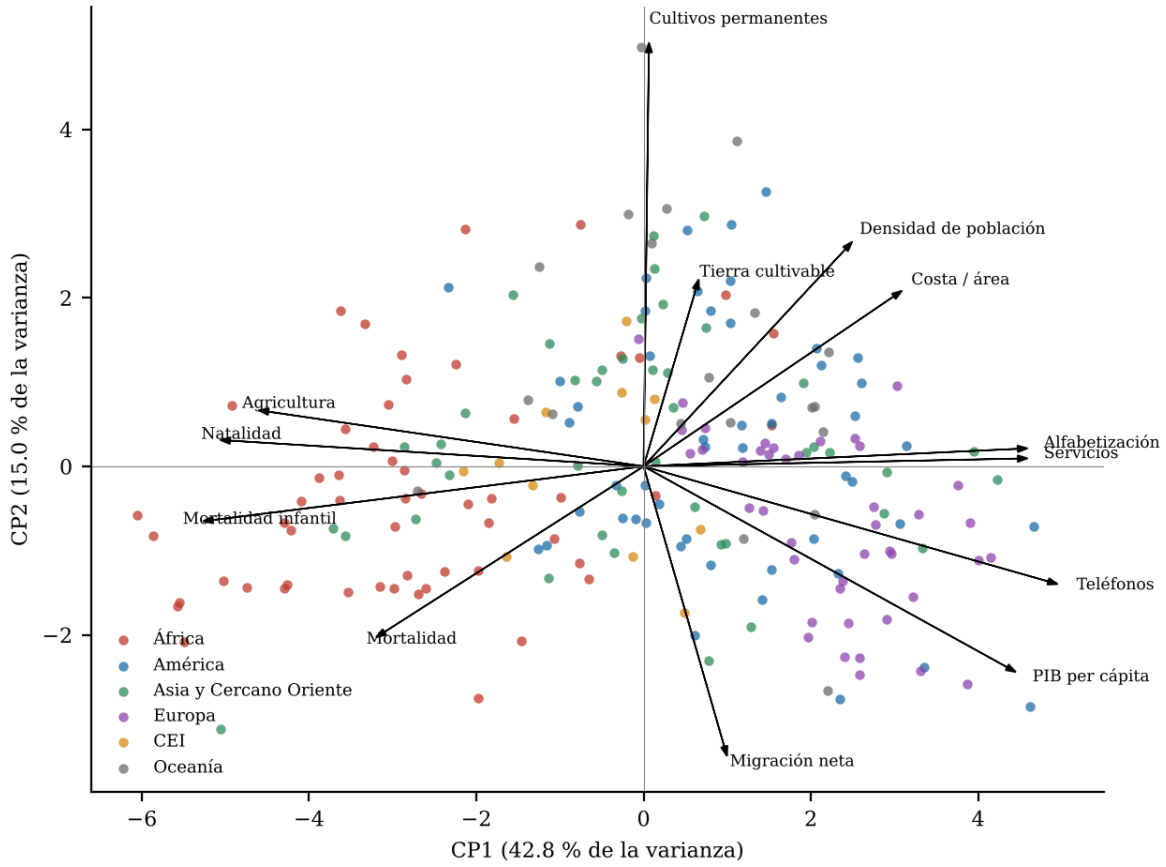


Figura 27. Países en el plano de CP1 y CP2, coloreados por grupo de regiones; las flechas son las cargas de las variables.

Las regiones se ordenan sobre la CP1 como cabría esperar. Las puntuaciones medias son: Europa 2.21, América 1.05, Oceanía 0.61, Asia y Cercano Oriente -0.06, CEI -0.61 y África -2.73. Los puntos más altos en la CP1 son Bermuda, Cayman Islands, Hong Kong, y los más bajos Liberia, Sierra Leone, Somalia. Que una variable construida solo con números reproduzca la geografía del desarrollo es una señal de que las componentes recogen estructura real y no ruido.

3.5.6 Regresar a la matriz original: reconstrucción con k componentes

Una forma de juzgar la reducción es volver de las componentes a la matriz de datos y comparar con la original. Reconstruimos la matriz estandarizada con las primeras *k* componentes, deshacemos la estandarización y el logaritmo y medimos el error. Con las 13 componentes se recupera exactamente la matriz original (lo verificamos numéricamente), así que toda la pérdida viene de las componentes que se descartan.

```
media, desv = X.mean(axis=0), X.std(axis=0, ddof=1)


def reconstruir(kk):
    Zk = scores_z[:, :kk] @ vec_z[:, :kk].T        # aproximación de Z con kk componentes
    Xk = Zk * desv + media                         # se deshace la estandarización
    for j, v in enumerate(VARS):
        if v in a_log:
            Xk[:, j] = 10 ** Xk[:, j] - 1          # se deshace log10(x + 1)
    return Zk, Xk
```

```
original = datos[VARS].to_numpy(float)
sst = ((original - original.mean(axis=0)) ** 2).sum(axis=0)
err_rel, r2_var = [], {}
for kk in range(1, p + 1):
    Zk, Xk = reconstruir(kk)
    err_rel.append(np.linalg.norm(Z - Zk) / np.linalg.norm(Z))
    r2_var[kk] = 1 - ((original - Xk) ** 2).sum(axis=0) / sst
err_rel = np.array(err_rel)
print("con k = p se recupera la matriz original:", np.allclose(reconstruir(p)[1], original))
print("error^2 = varianza no explicada:", np.allclose(err_rel ** 2, 1 - acum_z))
print("error relativo con k componentes:", np.round(err_rel, 3))
```

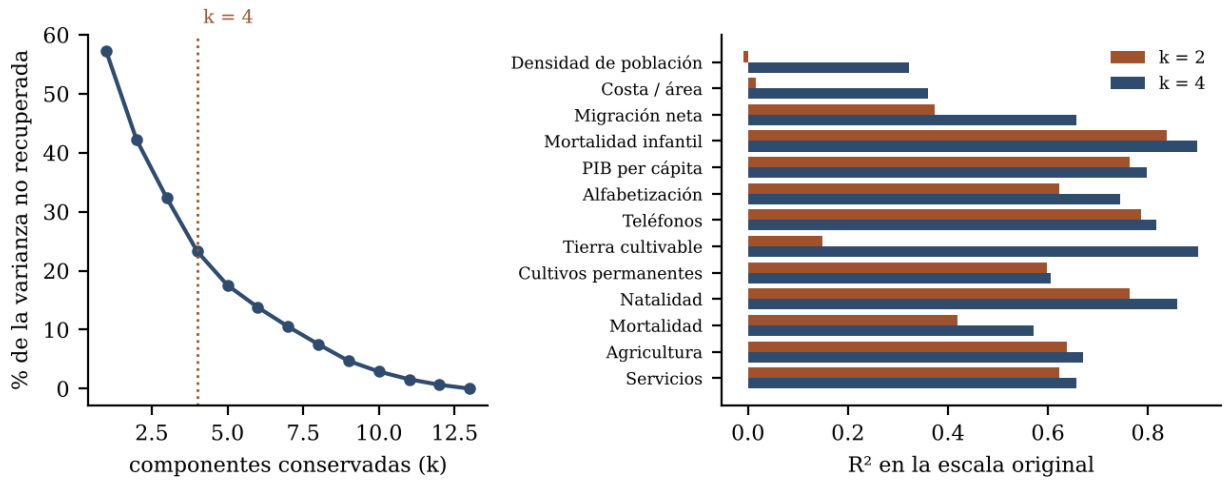


Figura 28. Izquierda: porcentaje de la varianza que no se recupera según el número de componentes conservadas. Derecha: R^2 de cada variable, en su escala original, al reconstruir con 2 y con 4 componentes.

El error relativo baja de 0.76 con una componente a 0.48 con cuatro. Su cuadrado es igual a 1 menos la varianza acumulada (también lo comprobamos), de modo que con cuatro componentes se deja de recuperar 23.3 % de la varianza, justo lo que predice la ecuación de la sección 1.4.

Variable por variable, con cuatro componentes se recuperan bien Tierra cultivable (0.90), Mortalidad infantil (0.90), Natalidad (0.86), Teléfonos (0.82), PIB per cápita (0.80). Se recuperan peor Mortalidad (0.57), Costa / área (0.36), Densidad de población (0.32): son variables con colas muy largas, en las que unos pocos territorios (Monaco, Macau, islas pequeñas) concentran la varianza, y el R^2 se mide en la escala original, donde esos casos pesan mucho. Con solo dos componentes, la tierra cultivable y la densidad casi no se recuperan, lo que coincide con que su información está en la CP3 y la CP4.

Tabla 9. Valores originales y reconstruidos con 2 y 4 componentes para tres países (escala original).

País	Variable	Original	k = 2	k = 4
México	PIB per cápita	9,000.0	11,110	9,288.1
	Mortalidad infantil	20.91	24.72	14.42
	Teléfonos	181.6	282.4	235.8
	Natalidad	20.69	19.19	16.50
Alemania	PIB per cápita	27,600	22,395	25,106
	Mortalidad infantil	4.16	-1.87	0.933
	Teléfonos	667.9	517.1	553.3
	Natalidad	8.25	9.46	5.80
Níger	PIB per cápita	800.0	-3,513.3	-2,416.8

País	Variable	Original	k = 2	k = 4
	Mortalidad infantil	121.7	115.4	125.7
	Teléfonos	1.90	-156.2	-117.3
	Natalidad	50.73	44.11	48.25

La reconstrucción de México con cuatro componentes es razonable (PIB per cápita de 9,288 contra 9,000 reales). Los extremos muestran el límite del método: para Alemania, la mortalidad infantil reconstruida con dos componentes es negativa, y para Níger el PIB per cápita sale negativo con dos y con cuatro componentes. El PCA es lineal y no sabe que estas variables no pueden ser negativas, por lo que en países muy alejados del promedio la reconstrucción puede dar valores imposibles. Es un aviso para no interpretar la matriz reconstruida como datos, sino como una aproximación.

3.6 Estandarización: con y sin

3.6.1 Por qué importa la escala

El PCA maximiza la varianza, y la varianza depende de las unidades. Si una variable está en miles de dólares y otra en fracciones entre 0 y 1, la primera aporta varianza varios órdenes de magnitud mayor solo por su escala. La Tabla 10 muestra el rango y la varianza de cada variable en la base transformada.

Tabla 10. Rango y varianza de cada variable antes de estandarizar (base transformada).

Variable	Mínimo	Máximo	Rango	Varianza
Densidad de población	0	4.21	4.21	0.448
Costa / área	0	2.94	2.94	0.493
Migración neta	-20.99	23.06	44.05	23.70
Mortalidad infantil	2.29	191.2	188.9	1,251.5
PIB per cápita	500.0	55,100	54,600	101,501,163
Alfabetización	17.60	100.0	82.40	370.6
Teléfonos	0.200	1,035.6	1,035.4	51,670
Tierra cultivable	0	62.11	62.11	169.6
Cultivos permanentes	0	1.71	1.71	0.199
Natalidad	7.29	50.73	43.44	124.0
Mortalidad	2.29	29.74	27.45	24.84
Agricultura	0	0.769	0.769	0.021
Servicios	0.062	0.954	0.892	0.027

La varianza del PIB per cápita es 101,501,163, y la de agricultura es 0.021. El PIB aporta 99.95 % de la varianza total de las 13 variables. Si no se estandariza, el PCA solo "ve" al PIB.

3.6.2 Qué ocurre sin estandarizar y estandarizando

```
prop_s = val_s / val_s.sum()
scores_s = Xc @ vec_s
cargas_s = vec_s * np.sqrt(val_s)
r_cp1 = np.corrcoef(scores_s[:, 0], scores_z[:, 0])[0, 1]
print("varianza de CP1 sin estandarizar: %.2f %%" % (100 * prop_s[0]))
print("varianza de CP1 estandarizando:   %.2f %%" % (100 * prop_z[0]))
print("carga de CP1 (sin estandarizar) sobre el PIB:", round(vec_s[VARS.index("GDP ($ per capita)"),
     0], 4))
print("correlación entre las puntuaciones de CP1 de ambos casos:", round(r_cp1, 3))
```

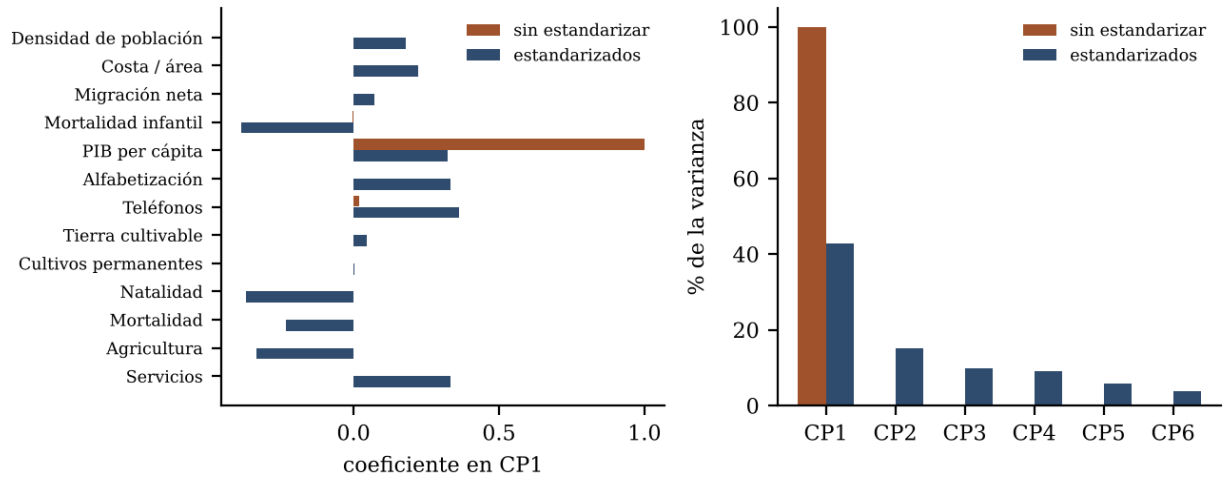


Figura 29. Izquierda: coeficientes de la CP1 en ambos casos. Derecha: varianza explicada por las primeras seis componentes.

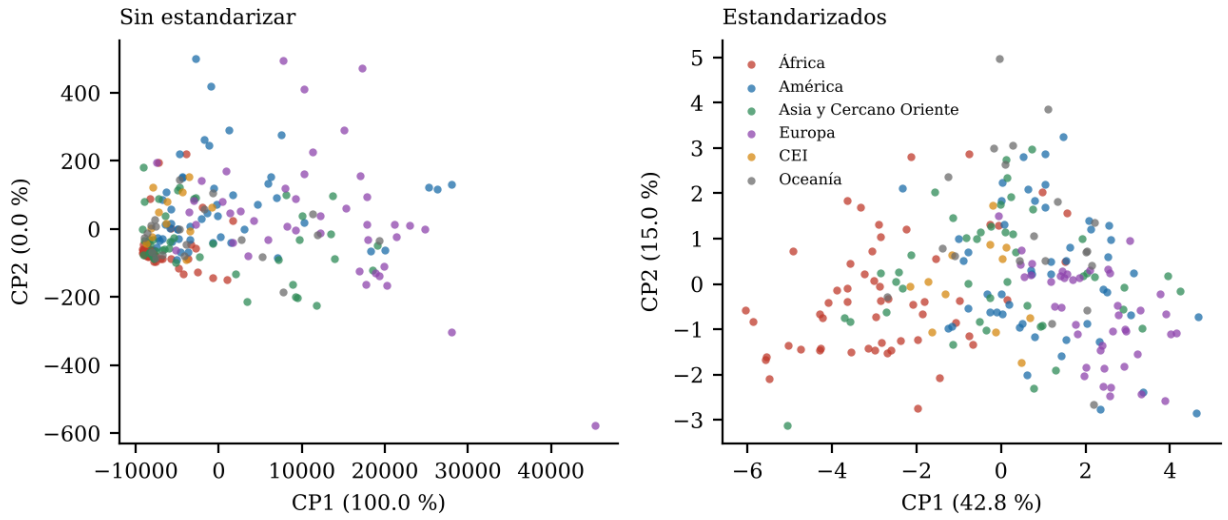


Figura 30. Países en el plano CP1–CP2 sin estandarizar (izquierda) y estandarizando (derecha).

Tabla 11. Comparación del PCA con y sin estandarización.

Aspecto	Sin estandarizar	Estandarizados
Matriz usada	Covarianza	Correlación (covarianza de los datos estandarizados)
Varianza explicada por la CP1	99.98 %	42.8 %
Componentes para llegar a 80 %	1	5
Variables con peso importante en la CP1	1 (PIB per cápita, coeficiente 1.00)	9 (|carga| ≥ 0.5)
Qué representa la CP1	El PIB per cápita casi por sí solo	Un eje de desarrollo con muchas variables

Sin estandarizar, la CP1 explica 99.98 % de la varianza y su vector propio vale 0.9998 en el PIB per cápita y casi cero en las demás variables. La componente es, en la práctica, el PIB con otro nombre, y el PCA no reduce nada: ordena a los países por ingreso e ignora la mortalidad infantil, la natalidad o la alfabetización. El 99.98 % es un artefacto de la escala, no una señal de que la información esté concentrada.

Al estandarizar, cada variable tiene varianza 1 y la información se reparte: la CP1 explica 42.8 % y recibe peso de 9 variables, las cuatro primeras componentes suman 76.7 %. Las puntuaciones de la CP1 de ambos casos tienen correlación de 0.77: ordenan de forma parecida a los países, porque el PIB también forma parte del eje de desarrollo, pero la versión estandarizada incorpora la información social y demográfica que la otra descarta.

3.6.3 Conclusión sobre la estandarización

Las variables de este conjunto están en unidades distintas (dólares, porcentajes, fracciones, razones), así que estandarizar es la decisión adecuada y la que usamos para elegir componentes en la sección 3.5. Solo tendría sentido no estandarizar si todas las variables estuvieran en la misma unidad y la diferencia de varianzas fuera información que se quiere conservar. Aquí no es el caso.

4. Discusión

4.1 Comparación con las hipótesis

H1 (las variables miden desarrollo y se pueden resumir). Se cumple en lo esencial. 23 de los 78 pares de variables tienen $|r| \geq 0.5$ y se forma un bloque claro de desarrollo; la primera componente (42.8 %) ordena a las regiones de África a Europa. Sin embargo, la reducción es moderada: hacen falta cuatro componentes para llegar a 76.7 %, y la simulación de Horn solo respalda 2 (57.8 %). Es decir, los 13 indicadores no se reducen a una sola dimensión, porque las variables geográficas (tierra cultivable, cultivos permanentes, costa) aportan estructura propia.

H2 (la estandarización es necesaria). Se cumple de forma contundente: sin estandarizar, la CP1 explica 99.98 % de la varianza y es prácticamente el PIB per cápita; estandarizando, explica 42.8 % y recibe peso de siete variables.

4.2 Resultados inesperados y limitaciones

Los criterios para elegir componentes no coinciden (Kaiser 4, Horn 2, varianza acumulada 5). Una explicación es que Horn es el más exigente, pues descuenta lo que se obtendría por azar con 224 países y 13 variables, mientras que Kaiser es más permisivo; la CP3 y la CP4 tienen valores propios de 1.29 y 1.17, apenas por encima de 1, por lo que son interpretables pero marginales. Por eso las dos primeras componentes son el resultado más firme.

Otras limitaciones: (1) en migración neta, 62 países tienen exactamente cero, y es probable que algunos de esos ceros sean datos no disponibles, lo que debilita su correlación con las demás variables; (2) la imputación con la mediana regional reduce algo la varianza de las variables más afectadas (alfabetización, con 16 de 224 países imputados); (3) los datos son de mediados de la década de 2000, de modo que las conclusiones describen ese periodo; (4) la interpretación de la CP2, CP3 y CP4 es nuestra lectura de las cargas; (5) la clasificación en variables independientes y dependientes se apoya en correlaciones, que no prueban causalidad; (6) al regresar a la matriz original con cuatro componentes algunas variables se recuperan mal y, en países extremos como Níger, aparecen valores imposibles (negativos), porque el PCA es lineal y no sabe que el PIB o la densidad no pueden ser negativos.

4.3 Cómo se podría mejorar el análisis

Con más tiempo se podría: tratar los ceros de migración neta como faltantes y repetir el análisis; comparar la imputación con la mediana regional contra otros métodos de imputación; repetir el PCA sin los territorios muy pequeños (Monaco, Macau, Singapore) para ver si cambian las componentes; actualizar los datos con fuentes más recientes; y usar las componentes como variables explicativas en un modelo para el PIB per cápita o la mortalidad infantil.

5. Conclusiones

Partimos de 227 países y 18 variables. Después de la depuración quedaron 224 países y 13 variables numéricas; descartamos las variables categóricas y las redundantes (otros usos del suelo, industria) con razones explícitas, y transformamos con logaritmo las tres variables de asimetría extrema.

Las correlaciones muestran un bloque de variables que describe el nivel de desarrollo (mortalidad infantil, natalidad, alfabetización, PIB per cápita, teléfonos, agricultura y servicios), mientras que las condiciones geográficas (tierra cultivable, cultivos permanentes, costa) se relacionan poco con él. Por eso las clasificamos como independientes y el bloque como dependiente, aclarando que se trata de una hipótesis y no de una prueba de causalidad.

Con datos estandarizados, cuatro componentes explican 76.7 % de la varianza. La primera (el 42.8 %) es un eje de desarrollo que ordena a las regiones de forma coherente. La elección de cuatro componentes se apoya en Kaiser y en la varianza acumulada, aunque la simulación de Horn sugiere solo dos, de modo que las dos primeras son las más firmes.

Al regresar a la matriz original con cuatro componentes se recuperan razonablemente las variables de desarrollo (mortalidad infantil, natalidad, teléfonos, PIB per cápita), pero no las geográficas de colas largas (densidad de población y costa/área); la reconstrucción es una aproximación y puede dar valores imposibles en países extremos.

Sin estandarizar, el PCA se reduce al PIB por la diferencia de escalas y pierde su utilidad. Limitaciones: los datos son de mediados de los años 2000; imputamos con la mediana regional una parte pequeña de los valores; y el cero de migración neta puede ser un dato faltante disfrazado. Una extensión natural sería ajustar un modelo para el PIB per cápita o la mortalidad infantil usando las componentes como predictores.

6. Bibliografía

[1] fernandol. *Countries of the World* [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/fernandol/countries-of-the-world

[2] Jolliffe, I. T. (2002). *Principal Component Analysis* (2.ª ed.). Springer.

[3] Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.

[4] Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika*, 30(2), 179–185.

[5] United Nations Development Programme (1990). *Human Development Report 1990*. Oxford University Press.

[6] McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 51–56.

[7] Harris, C. R. et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

[8] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.

[9] Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

[10] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.