UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas
Licenciatura en Ciencia de Datos

Métodos Matemáticos Computacionales para Ciencia de Datos

Exploración de datos y reducción de dimensiones con componentes principales

Indicadores demográficos, económicos y geográficos de 227 países

---

Integrantes	De La Cruz Maldonado José Eduardo López Reyes Jorge
Profesora	Nora Isabel Pérez Quezadas
Datos	Countries of the World (Kaggle, fernandol)

Ciudad Universitaria, Ciudad de México
Noviembre de 2026

Resumen

Se realiza un análisis exploratorio de 227 países descritos por 19 variables demográficas, económicas y geográficas (*Countries of the World*, Kaggle) para saber si pueden resumirse en pocas componentes principales. Se depuró la base (variables redundantes descartadas, tres territorios eliminados por exceso de faltantes, imputación con la mediana regional y logaritmo en las variables de asimetría extrema) y se obtuvieron gráficas, medidas descriptivas, valores atípicos y matrices de covarianza y correlación, identificando las variables más y menos relacionadas. Luego se aplicó el análisis de componentes principales (PCA) con y sin estandarización, eligiendo el número de componentes con el criterio de Kaiser. Con datos estandarizados, cuatro componentes explican 76.7 % de la varianza y la primera (42.8 %) funciona como un eje de nivel de desarrollo; sin estandarizar, la primera explica 99.98 % pero solo refleja el PIB per cápita por su escala. Por ello, estandarizar es indispensable cuando las variables tienen unidades distintas.

Palabras clave: análisis exploratorio, componentes principales, estandarización, correlación, indicadores de países.

Contenido

1. Introducción **6**

1.1 Objetivo e hipótesis de trabajo 6

1.2 Justificación y antecedentes 6

1.3 Origen y descripción de los datos 6

1.4 Herramientas y métodos 7

1.4.1 Medidas descriptivas y covarianza 8

1.4.2 Correlación de Pearson 8

1.4.3 Valores atípicos: rango intercuartílico 8

1.4.4 Transformación logarítmica y estandarización 8

1.4.5 Componentes principales 8

1.4.6 Cuántas componentes conservar 9

1.4.7 Reconstrucción de la matriz con k componentes 9

2. Análisis experimental **10**

2.1 Valores faltantes 10

2.2 Variables que descartamos y por qué 10

2.3 Países eliminados y valores imputados 11

2.4 Transformación de variables muy asimétricas 11

2.5 Cómo se obtuvo cada resultado 12

3. Resultados **13**

3.1 Gráficas de cada característica 13

3.2 Medidas descriptivas 20

3.3 Datos atípicos . . . 21
3.4 Correlaciones y relación entre variables . . . 23
3.4.1 Covarianza y correlación de Pearson . . . 23
3.4.2 Matriz de correlación . . . 24
3.4.3 Variables más y menos relacionadas . . . 25
3.4.4 Comparación gráfica de los vectores más y menos correlacionados . . . 26
3.4.5 Variables independientes y dependientes . . . 29
3.5 Componentes principales (PCA) . . . 31
3.5.1 Qué ventaja ofrece el PCA . . . 31
3.5.2 Cómo se calculan . . . 31
3.5.3 Por qué elegimos cuatro componentes . . . 32
3.5.4 Interpretación de las componentes . . . 33
3.5.5 Los países en el plano de las dos primeras componentes . . . 34
3.5.6 Regresar a la matriz original: reconstrucción con k componentes . . . 35
3.6 Estandarización: con y sin . . . 37
3.6.1 Por qué importa la escala . . . 37
3.6.2 Qué ocurre sin estandarizar y estandarizando . . . 38
3.6.3 Conclusión sobre la estandarización . . . 39

4. Discusión **39**

4.1 Comparación con las hipótesis . . . 39
4.2 Limitaciones . . . 40
4.3 Cómo se podría mejorar el análisis . . . 40

5. Conclusiones **40**

6. Bibliografía **41**

1. Introducción

1.1 Objetivo e hipótesis de trabajo

El objetivo de este trabajo es realizar un análisis exploratorio del conjunto de datos *Countries of the World* [1] y, con la base ya depurada, determinar si los indicadores demográficos, económicos y geográficos de los países pueden resumirse en unas pocas componentes principales sin perder demasiada información. El análisis sigue el siguiente flujo planteado: datos, exploración (gráficas, preprocesamiento, correlaciones, medidas descriptivas y valores atípicos), corrección de los datos cuando hace falta y reducción de dimensiones con PCA.

Partimos de dos hipótesis de trabajo, que se retoman en la Discusión (sección 4). **H1:** muchas variables miden en el fondo el nivel de desarrollo de un país (salud, ingreso, educación, estructura económica), por lo que estarán fuertemente correlacionadas y unas pocas componentes bastarán para resumir buena parte de la varianza. **H2:** como las variables están en unidades muy distintas, el PCA sin estandarizar quedará dominado por la variable de mayor escala, mientras que con estandarización sí resumirá la estructura de los datos.

1.2 Justificación y antecedentes

Los países se describen con decenas de indicadores y varios de ellos dicen casi lo mismo. Resumirlos en pocas dimensiones permite comparar países, visualizarlos en un plano y usar menos variables en modelos posteriores. Además, este conjunto puede ser un buen caso para entender el PCA, porque la decisión de estandarizar o no cambia por completo el resultado.

El análisis de componentes principales es una técnica clásica para reducir dimensiones [2], y los criterios para decidir cuántas componentes conservar se han estudiado desde hace décadas [3, 10]. Como antecedente de la idea de resumir el desarrollo de un país con pocas dimensiones, el Índice de Desarrollo Humano del PNUD [4] combina salud, educación e ingreso en un solo indicador; a diferencia del PCA, se construye con una fórmula fija y no a partir de la estructura de los datos.

1.3 Origen y descripción de los datos

Los datos vienen del conjunto *Countries of the World*, publicado en Kaggle por el usuario fernandol (https://www.kaggle.com/datasets/fernandol/countries-of-the-world) [1]. Cada fila es un país o territorio y cada columna una característica. Por los valores que contiene (por ejemplo, China aparece con 1,313,973,713 habitantes), la información corresponde a mediados de la década de 2000, así que las conclusiones describen ese periodo y no la actualidad.

El archivo usa coma como separador decimal ("48,0") y los nombres de país y de región traen espacios al final, por lo que al leerlo indicamos *decimal=","* y limpiamos los textos. La Tabla 1 resume las columnas.

```
raw = pd.read_csv(BASE / "datos" / "countries_of_the_world.csv", decimal=",")
raw.columns = [c.strip() for c in raw.columns]
raw["Country"] = raw["Country"].str.strip()
raw["Region"] = raw["Region"].str.strip()
raw = raw.set_index("Country")
print(raw.shape)
print(raw.dtypes)
print(raw.isna().sum())
```

Tabla 1. Variables del conjunto de datos tal como se usan en este trabajo.

Variable	Tipo	Qué mide
País	texto	Nombre del país o territorio (se usa como identificador).
Región	categórica (11 niveles)	Región geográfica definida por la fuente.
Población	numérica	Número de habitantes.
Superficie	numérica	Área en millas cuadradas.
Densidad de población	numérica	Habitantes por milla cuadrada.
Costa / área	numérica	Razón entre la longitud de costa y la superficie.
Migración neta	numérica	Migrantes netos por cada 1000 habitantes.
Mortalidad infantil	numérica	Muertes por cada 1000 nacimientos.
PIB per cápita	numérica	Dólares estadounidenses por habitante.
Alfabetización	numérica	Porcentaje de la población alfabetizada.
Teléfonos	numérica	Líneas telefónicas por cada 1000 habitantes.
Tierra cultivable, cultivos permanentes, otros usos	numéricas	Porcentaje de la superficie en cada uso del suelo.
Clima	categórica ordinal	Tipo de clima codificado de 1 a 4, con algunos valores intermedios (1.5 y 2.5).
Natalidad, mortalidad	numéricas	Nacimientos y muertes por cada 1000 habitantes.
Agricultura, industria, servicios	numéricas	Fracción del PIB que aporta cada sector.

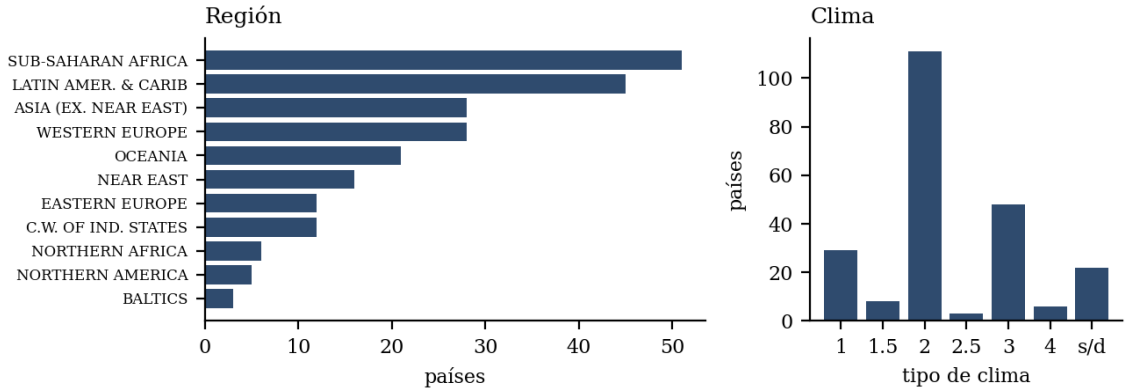


Figura 1. Distribución de las dos variables categóricas. Clima tiene 22 países sin dato (s/d).

La región con más países es África subsahariana (51), seguida de América Latina y el Caribe (45); Países Bálticos (3) es la más pequeña. En clima, el tipo 2 concentra 111 países.

1.4 Herramientas y métodos

Todo el análisis se hizo en Python con estos paquetes: pandas [5] (lectura del CSV con *read_csv*, imputación con *groupby/transform* y *fillna*, y los métodos *mean*, *median*, *var*, *std*, *skew*, *cov* y *corr*); NumPy [6] (matriz de covarianza con *numpy.cov*, valores y vectores propios con *numpy.linalg.eigh* y *log10*); Matplotlib [7] y seaborn [8] (histogramas, diagramas de caja, dispersión y mapas de calor); SciPy (valor crítico de la correlación) y scikit-learn [9], cuya clase *PCA* usamos solo para verificar nuestro cálculo. Las herramientas vistas en clase (matrices de covarianza y correlación, PCA y estandarización) se describen a grandes rasgos; las demás (transformación logarítmica y criterio del rango intercuartílico) se explican con más detalle.

1.4.1 Medidas descriptivas y covarianza

La media, la varianza y la covarianza de dos variables X e Y medidas en *n* países son:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad s^2(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

$$\mathrm{Cov}(X,Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

Aquí *n* es el número de países, x_i y y_i son los valores de X y Y en el país *i*, la barra sobre una letra indica su media y cada suma recorre $i = 1, \ldots, n$. La desviación estándar *s* es la raíz cuadrada de la varianza. La mediana es el valor central de los datos ordenados y, a diferencia de la media, no la afectan los valores extremos.

1.4.2 Correlación de Pearson

$$r(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma(X)\,\sigma(Y)}$$

donde σ(X) y σ(Y) son las desviaciones estándar de X y de Y. El coeficiente *r* va de −1 a 1 y no depende de las unidades. La matriz de correlación reúne el valor de *r* de todos los pares de variables; vale 1 en la diagonal y es simétrica.

1.4.3 Valores atípicos: rango intercuartílico

$$x < Q_1 - 1.5\,\mathrm{RIC} \quad \text{o} \quad x > Q_3 + 1.5\,\mathrm{RIC}, \qquad \mathrm{RIC} = Q_3 - Q_1$$

donde Q_1 y Q_3 son el primer y el tercer cuartil de la variable (los valores que dejan por debajo al 25 % y al 75 % de los países) y RIC es el rango intercuartílico. Un valor *x* que cumple alguna de las dos condiciones se considera atípico. Es el criterio que dibuja los círculos de los diagramas de caja.

1.4.4 Transformación logarítmica y estandarización

$$y = \log_{10}(x+1) \qquad z_i = \frac{x_i - \bar{x}}{s}$$

donde *x* es el valor original, *y* el valor transformado y z_i el valor estandarizado de la variable en el país *i*, con media 0 y desviación estándar 1. El logaritmo comprime las colas derechas largas y conserva el orden de los países; se suma 1 porque hay valores iguales a cero. La estandarización pone todas las variables en la misma escala.

1.4.5 Componentes principales

$$S\,v_j = \lambda_j\,v_j \qquad \mathrm{prop}_j = \frac{\lambda_j}{\lambda_1 + \cdots + \lambda_p} \qquad T = ZV$$

Aquí *S* es la matriz de covarianza de los datos (de $p \times p$, con $p = 13$ variables), v_j es el vector propio de la componente *j* (sus coeficientes) y λ_j su valor propio, que es la varianza de esa componente; las componentes se ordenan de mayor a menor λ, y prop_j es la proporción de varianza que explica la componente *j*. *Z* es la matriz de datos estandarizados ($n \times p$), *V* es la matriz cuyas columnas son los vectores propios y *T* contiene las puntuaciones (scores) de cada país. Si *S* se calcula con datos estandarizados, es la matriz de correlación.

La carga de la variable *i* en la componente *j* es $v_{ij} \cdot \sqrt{\lambda_j}$, y equivale a la correlación entre ambas cuando se parte de datos estandarizados.

1.4.6 Cuántas componentes conservar

El PCA produce tantas componentes como variables (aquí $p = 13$) y solo conservándolas todas se mantiene el 100 % de la varianza; reducir dimensiones significa quedarse con las primeras *k* y descartar las demás. La elección de *k* es un compromiso entre dos errores. Si se conservan **muy pocas**, se pierde estructura real de los datos. Si se conservan **demasiadas**, se incluyen componentes que solo reflejan el ruido del muestreo o la variación propia de una sola variable: no se pueden interpretar y cambiarían con otra muestra de países.

Criterio de Kaiser [3, 10]. Con datos estandarizados se conservan las componentes cuyo valor propio es mayor que 1:

$$\operatorname{tr}(R) = \lambda_1 + \lambda_2 + \cdots + \lambda_p = p \quad \Rightarrow \quad \bar{\lambda} = 1; \qquad \text{se conserva la CP}_j \text{ si } \lambda_j > 1$$

La justificación es la siguiente. Al estandarizar, cada variable tiene varianza 1, así que la varianza total es la traza de la matriz de correlación *R*, que vale *p*, y el valor propio promedio es 1. Como λ_j es la varianza de la componente *j*, una componente con $\lambda_j > 1$ resume más varianza que cualquiera de las variables originales por separado, es decir, sí comprime información; una con $\lambda_j < 1$ explica menos que una sola variable y conservarla no supone ninguna ganancia frente a quedarse con esa variable. Por eso el criterio solo tiene sentido con datos estandarizados: sin estandarizar, el umbral equivalente sería el promedio de los valores propios de *S*, que en estos datos domina el PIB per cápita (sección 3.6). Su limitación es que el umbral 1 vale para la población y no toma en cuenta el tamaño de la muestra: aunque las variables fueran independientes, los valores propios muestrales se dispersan alrededor de 1 y los primeros lo superan solo por azar.

1.4.7 Reconstrucción de la matriz con k componentes

Con solo las primeras *k* componentes se puede volver a la matriz de datos:

$$\hat{Z}_k = T_k V_k^{\top} \qquad \hat{X}_k = \hat{Z}_k D + \mathbf{1}\,\bar{x}^{\top}$$

Aquí T_k y V_k son las primeras *k* columnas de *T* y de *V*, $\hat{Z}_k$ es la matriz estandarizada aproximada, *D* es la matriz diagonal con las desviaciones estándar *s* de cada variable, **1** es un vector columna de unos y *x* con barra es el vector de medias. Si además se aplicó el logaritmo, se deshace con $x = 10^{y} - 1$. Con $k = p$ la reconstrucción es exacta; con $k < p$ se pierde justo la varianza de las componentes descartadas:

$$\frac{\|Z - \hat{Z}_k\|_F^2}{n-1} = \lambda_{k+1} + \cdots + \lambda_p$$

donde $\|\cdot\|_F$ es la norma de Frobenius (la raíz de la suma de los cuadrados de todas las entradas de la matriz). Esto da una medida directa de lo que cuesta quedarse con *k* componentes.

2. Análisis experimental

Esta sección describe qué se hizo con los datos antes de analizarlos y sobre qué base se obtuvo cada resultado de la sección 3. El procedimiento tiene cuatro pasos: contar y tratar los valores faltantes, decidir qué variables y países se quedan, imputar los vacíos restantes y transformar las variables muy asimétricas. Las gráficas de la sección 3.1 se hicieron con los datos originales, antes de modificar nada, para mostrar la información tal cual viene en la fuente.

2.1 Valores faltantes

Primero contamos los vacíos de cada columna. Las que más faltan son Clima (22 países, 9.7 %), Alfabetización (18 países, 7.9 %), Industria (16 países, 7.0 %), Servicios (15 países, 6.6 %) y Agricultura (15 países, 6.6 %). Ninguna columna numérica pasa del 8 % de vacíos, así que no hay razón para descartarlas únicamente por faltantes.

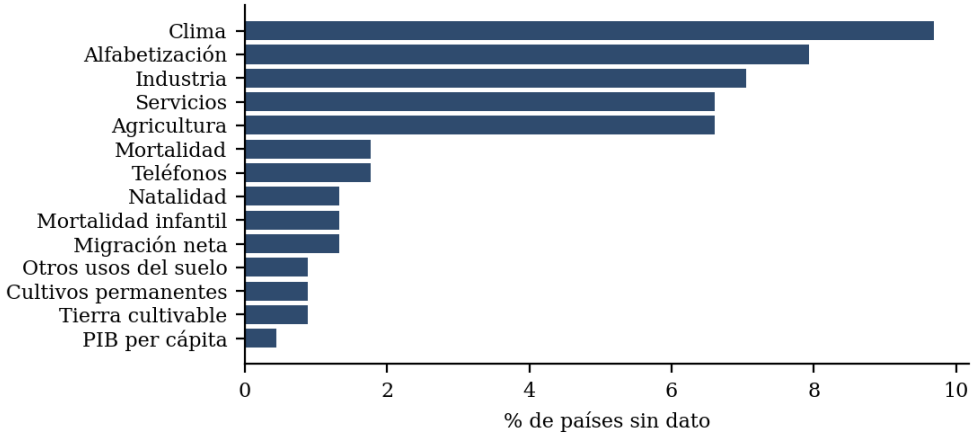


Figura 2. Porcentaje de países sin dato en cada columna (solo se muestran las que tienen vacíos).

```
nulos = raw.isna().sum()
nulos = (100 * nulos[nulos > 0] / len(raw)).sort_values()
fig, ax = plt.subplots(figsize=(5.6, 2.6))
ax.barh([NOMBRES[v] for v in nulos.index], nulos.values, color=C1)
ax.set_xlabel("% de países sin dato")
fig.tight_layout(); fig.savefig(FIG / "fig_faltantes.png")
```

2.2 Variables que descartamos y por qué

De las 19 columnas distintas de País, 13 numéricas entran al estudio de correlaciones y componentes principales. Las demás se descartan por las razones de la Tabla 2. Hablamos de variables (columnas): descartar una significa que no participa en las matrices de covarianza y correlación ni en el PCA, pero sigue visible en las gráficas de la sección 3.1.

Tabla 2. Variables que no entran a las matrices de correlación ni al PCA.

Variable	Decisión	Razón
País	Índice	Es un identificador; no es una medición.
Región	Fuera del PCA	Es categórica nominal (11 niveles) y no tiene sentido calcular media o covarianza con ella. La usamos para colorear gráficas y para imputar faltantes.
Clima	Se descarta	Es una categoría ordinal con 22 países sin dato (9.7 %) y con valores intermedios (1.5 y 2.5) que no son medidas reales. Su media o covarianza no tiene interpretación.
Otros usos del suelo	Se descarta	Es exactamente 100 menos tierra cultivable menos cultivos permanentes (la suma de las tres va de 99.88 a 100.01, la diferencia es redondeo). Una variable que es combinación lineal de otras hace singular la matriz de covarianza y no agrega información.
Industria	Se descarta	Agricultura + industria + servicios suman entre 0.906 y 1.010, por lo que las tres son casi dependientes. Conservamos agricultura y servicios; industria queda como el resto (su correlación con ellas es -0.32 y -0.54) y además tiene 16 vacíos.
Población y superficie	Fuera del PCA	Miden el tamaño del país, no sus condiciones de vida, y su resumen útil ya está en la densidad de población (población entre superficie). Tienen la asimetría más fuerte (9.2 y 6.0) y dominarían las matrices.

2.3 Países eliminados y valores imputados

Para decidir qué hacer con los vacíos de las 13 variables que sí usamos, contamos cuántos le faltan a cada país. Eliminamos a los que tienen cuatro o más vacíos (más del 30 % de sus variables): Mayotte, Wallis and Futuna, Western Sahara. Quedan 224 países. A los demás les rellenamos cada vacío con la mediana de su región; usamos la mediana porque no la afectan los valores extremos y la región porque agrupa países con condiciones parecidas, de modo que es mejor imputar con ella que con la mediana mundial.

Se imputaron Alfabetización (16), Servicios (13), Agricultura (12), Teléfonos (3) y pocos valores en el resto. El caso más grande, alfabetización, representa 7.1 % de los países. Imputar con la mediana reduce un poco la varianza real de esas variables, lo cual dejamos señalado como limitación.

```
VARS = ["Pop. Density (per sq. mi.)", "Coastline (coast/area ratio)", "Net migration",
        "Infant mortality (per 1000 births)", "GDP ($ per capita)", "Literacy (%)",
        "Phones (per 1000)", "Arable (%)", "Crops (%)", "Birthrate", "Deathrate",
        "Agriculture", "Service"]
datos = raw[VARS + ["Region"]].copy()
faltan = datos[VARS].isna().sum(axis=1)
eliminados = datos.index[faltan >= 4].tolist()      # más del 30 % de las variables sin dato
datos = datos[faltan < 4].copy()
med_region = datos.groupby("Region")[VARS].transform("median")
datos[VARS] = datos[VARS].fillna(med_region)
datos[VARS] = datos[VARS].fillna(datos[VARS].median())
print("eliminados:", eliminados, "| quedan:", len(datos), "| nulos:",
      int(datos[VARS].isna().sum().sum()))
```

2.4 Transformación de variables muy asimétricas

Los resultados de la sección 3.1 muestran que algunas variables tienen colas derechas extremas que, al calcular correlaciones y componentes, dejarían que unos pocos países decidan el resultado. Con un criterio fijo, aplicamos *log10(x + 1)* a las variables con coeficiente de asimetría mayor o igual a 2 en valor absoluto. Elegimos el logaritmo porque comprime las colas derechas y respeta el orden de los países, y sumamos 1 porque estas variables tienen ceros (por ejemplo, países sin costa). Las variables transformadas son: Densidad de población, Costa / área, Cultivos permanentes.

```
asim_antes = datos[VARS].skew()
a_log = asim_antes[asim_antes.abs() >= 2].index.tolist()
trans = datos.copy()
for v in a_log:
    trans[v] = np.log10(trans[v] + 1)
```

```
asim_despues = trans[VARS].skew()
print(pd.DataFrame({"antes": asim_antes, "despues": asim_despues}).loc[a_log].round(2))
```

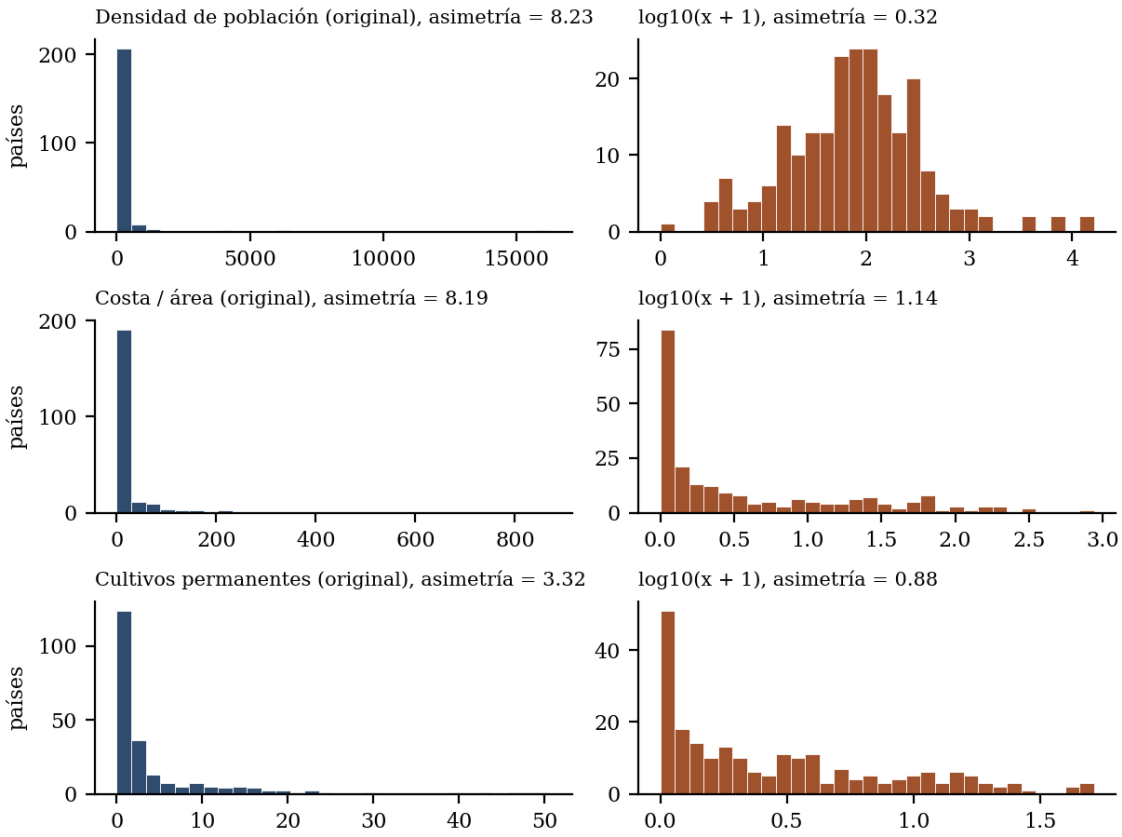


Figura 3. Efecto de la transformación logarítmica sobre las tres variables más asimétricas (izquierda: original; derecha: transformada).

La asimetría de densidad baja de 8.23 a 0.32, la de costa/área de 8.19 a 1.14 y la de cultivos permanentes de 3.32 a 0.88. Las demás variables tienen asimetría menor que 2 y se dejan en su escala original para conservar su interpretación.

2.5 Cómo se obtuvo cada resultado

Gráficas de cada variable (3.1). Se hicieron con los datos originales (227 filas, omitiendo los vacíos de cada variable): un histograma de 20 intervalos con líneas de media y mediana, y un diagrama *box plot*.

Coeficiente de asimetría (2.4 y 3.1). Para medir qué tan cargada hacia un lado está la distribución de cada variable usamos el coeficiente de asimetría muestral ajustado de Fisher-Pearson, que es el que calcula el método *skew* de pandas:

$$g = \frac{n}{(n-1)(n-2)} \sum_{i=1}^{n} \frac{(x_i - \bar{x})^3}{s^3}$$

donde n es el número de países con dato en la variable, x_i es el valor de la variable en el país i, $\bar{x}$ es su media y s su desviación estándar muestral (calculada con $n - 1$). Cada término mide a cuántas desviaciones estándar está un país de la media y lo eleva al cubo, de modo que conserva el signo y da mucho más peso a

los valores alejados; el factor $n/((n-1)(n-2))$ corrige el sesgo que tiene esta medida en muestras pequeñas. Si $g = 0$, la distribución es simétrica; si $g > 0$, tiene una cola larga hacia la derecha (la media queda por encima de la mediana), y si $g < 0$, la cola está a la izquierda. Con este coeficiente se decidió qué variables transformar con logaritmo ($|g| \geq 2$, sección 2.4) y se describe cada variable en la sección 3.1.

Medidas descriptivas, covarianza y atípicos. (3.2) Se calcularon sobre la base depurada (224 países × 13 variables), antes de transformar, con *mean*, *median*, *var*, *std* y *cov*. Los atípicos se contaron con el criterio del RIC (Rango Intercuartílico) antes y después de la transformación logarítmica.

Correlaciones (3.4). Se calcularon sobre la base transformada (224 × 13) con *corr(method="pearson")*. La selección de las variables más y menos correlacionadas usa criterios explícitos. La clasificación en variables independientes y dependientes se hizo a partir del significado de cada variable y de su mayor correlación con las demás.

PCA (3.5). Se aplicó a la base transformada y estandarizada. Calculamos la matriz de covarianza, extrajimos valores y vectores propios con *numpy.linalg.eigh* y los ordenamos de mayor a menor. Verificamos el cálculo con *sklearn.decomposition.PCA* (los valores propios coinciden) y comprobamos que las componentes no están correlacionadas. El número de componentes se eligió con el criterio de Kaiser (valores propios mayores que 1), que da 4; la justificación detallada está en la sección 3.5.3.

Reconstrucción (3.5.6). Con las puntuaciones T y los vectores propios V se reconstruye la matriz estandarizada con k componentes, se deshacen la estandarización y el logaritmo, y se compara con la base. El error se mide con la norma de la diferencia entre matrices.

Comparación con y sin estandarización (3.6). Se repite el mismo cálculo sobre la misma base transformada, una vez con los datos solo centrados (matriz de covarianza) y otra con datos estandarizados (matriz de correlación). Por eso, "sin estandarizar" significa sin dividir entre la desviación estándar, pero con la transformación logarítmica ya aplicada.

3. Resultados

Los resultados se presentan en el orden del flujo de trabajo: gráficas de cada variable (3.1), medidas descriptivas (3.2), valores atípicos (3.3), correlaciones (3.4), componentes principales (3.5) y estandarización (3.6). Cada resultado lleva una explicación breve; la comparación con las hipótesis, las limitaciones y las mejoras posibles se discuten en la sección 4.

3.1 Gráficas de cada característica

Antes de modificar nada, graficamos cada variable numérica con un histograma y un *box plot*. En el histograma la línea discontinua marca la media y la continua la mediana; cuando están muy separadas, la distribución es asimétrica. En el diagrama de caja, la caja va del primer al tercer cuartil, los bigotes llegan hasta 1.5 veces el rango intercuartílico y los círculos son valores atípicos. Las variables se grafican con los datos originales, con los vacíos omitidos en cada una.

```
NUMERICAS = [c for c in raw.columns if c not in ("Region", "Climate")]


def cifra(v):
    """Cifra completa con separador de miles para valores grandes (población, superficie)."""
    return f"{v:,.0f}" if abs(v) >= 1e4 else f"{v:.4g}"

def hist_box(x, titulo, unidad, ruta):
```

```
    x = x.dropna()
    fig, (a, b) = plt.subplots(1, 2, figsize=(6.6, 1.9),
                               gridspec_kw={"width_ratios": [2.6, 1.6]})
    a.hist(x, bins=20, color=C1, edgecolor="white", linewidth=.4)
    a.axvline(x.mean(), color=C2, ls="--", lw=1, label=f"media = {cifra(x.mean())}")
    a.axvline(x.median(), color="black", lw=1, label=f"mediana = {cifra(x.median())}")
    a.set_xlabel(unidad); a.set_ylabel("países"); a.set_title(titulo, loc="left", fontsize=8.5)
    a.legend(frameon=False, fontsize=6.5)
    b.boxplot(x, vert=False, widths=.5, medianprops=dict(color="black"),
              flierprops=dict(marker="o", ms=2.5, mfc="none", mec=C2))
    b.set_yticks([]); b.set_xlabel(unidad)
    fig.tight_layout(); fig.savefig(ruta); plt.close(fig)


estad = []
for i, v in enumerate(NUMERICAS):
    hist_box(raw[v], NOMBRES[v], UNIDADES[v], FIG / f"hb_{i:02d}.png")
    x = raw[v].dropna()
    estad.append({"var": v, "nombre": NOMBRES[v], "archivo": f"hb_{i:02d}.png", "n": int(x.size),
                  "nulos": int(raw[v].isna().sum()), "media": x.mean(), "mediana": x.median(),
                  "asim": x.skew(), "atip": int(len(iqr_atipicos(x))),
                  "min": x.min(), "max": x.max(), "pais_max": x.idxmax()})
```

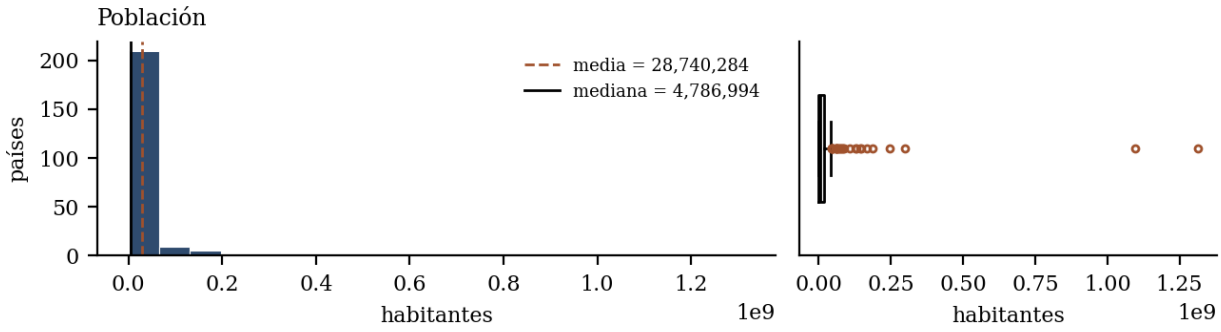


Figura 4. Población. Unos pocos países enormes (China, India, Estados Unidos) contrastan con una mayoría de países pequeños. Asimetría 9.2; media de 28,740,284 frente a la mediana 4,786,994; 28 valores atípicos por el criterio del rango intercuartílico.

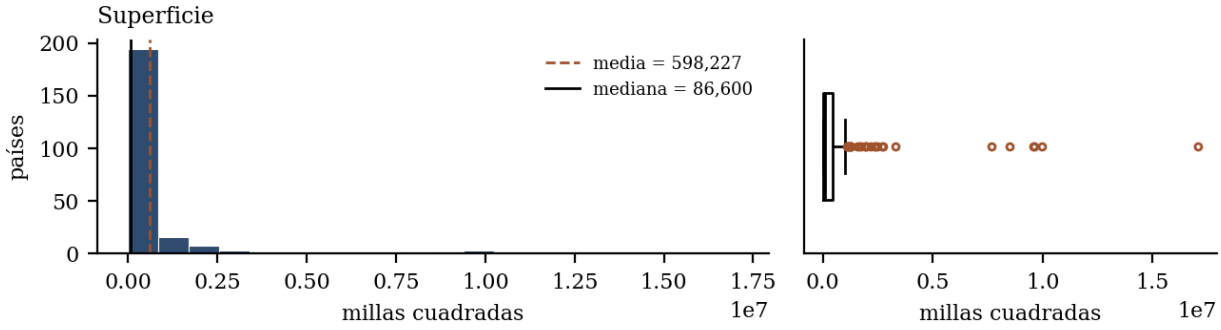


Figura 5. Superficie. Pocos países ocupan superficies muy grandes (Russia, Canada, United States); la mayoría son pequeños. Asimetría 6.0; media de 598,227 frente a la mediana 86,600; 28 valores atípicos por el criterio del rango intercuartílico.

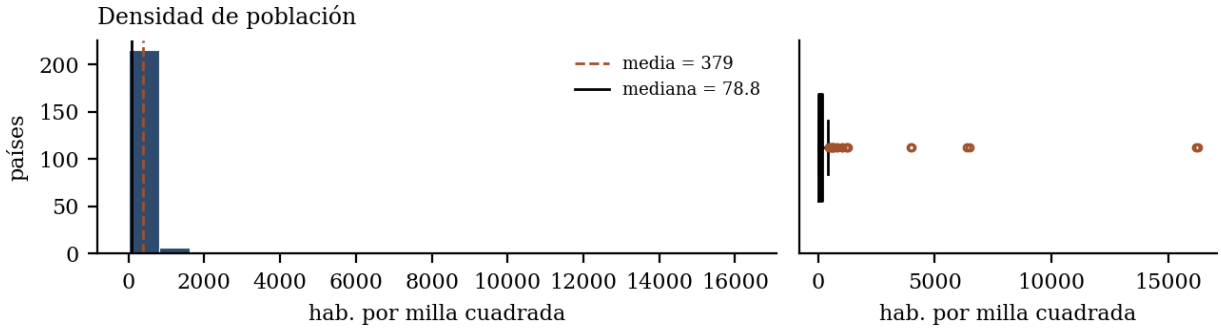


Figura 6. Densidad de población. Casi todos los países tienen pocas centenas de habitantes por milla cuadrada, pero territorios diminutos como Monaco, Macau o Singapore llegan a miles. Asimetría 8.3; media de 379.0 frente a la mediana 78.80; 21 valores atípicos por el criterio del rango intercuartílico.

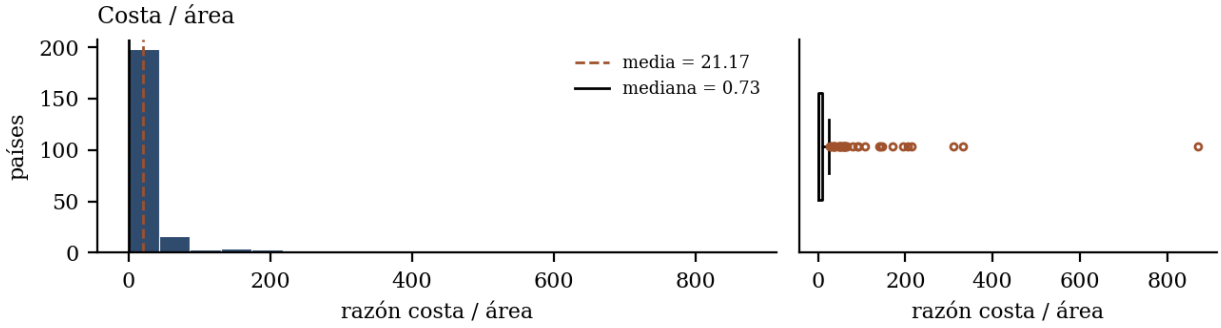


Figura 7. Costa / área. La razón vale cero en países sin litoral y es muy alta en islas pequeñas, lo que alarga la cola derecha. Asimetría 8.2; media de 21.17 frente a la mediana 0.730; 37 valores atípicos por el criterio del rango intercuartílico.

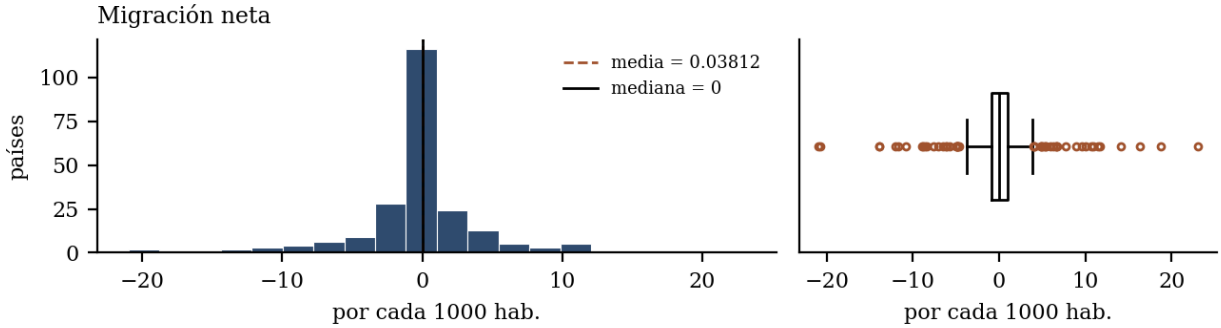


Figura 8. Migración neta. Se concentra alrededor de cero. En 62 de 224 países vale exactamente cero, y es probable que en la fuente ese cero sustituya un dato no disponible. Asimetría 0.1; media de 0.038 frente a la mediana 0; 50 valores atípicos por el criterio del rango intercuartílico.

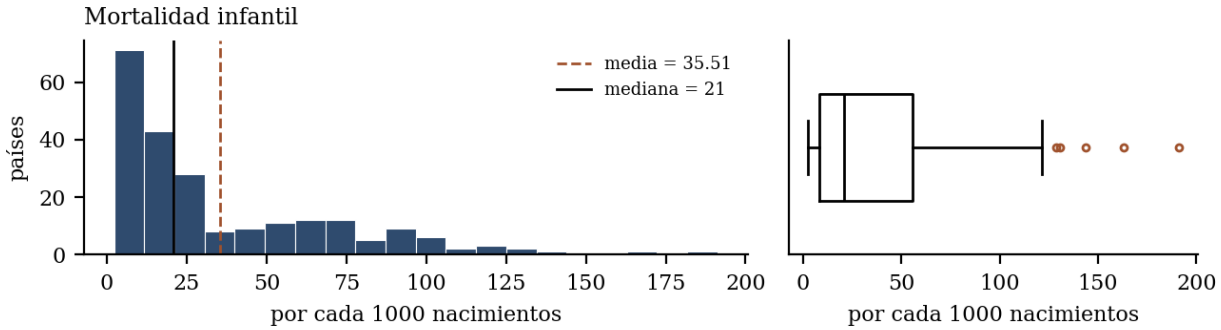


Figura 9. Mortalidad infantil. La mayoría de los países tiene valores bajos; hay una cola de países africanos con más de 100 muertes por cada 1000 nacimientos. Asimetría 1.4; media de 35.51 frente a la mediana 21.00; 5 valores atípicos por el criterio del rango intercuartílico.

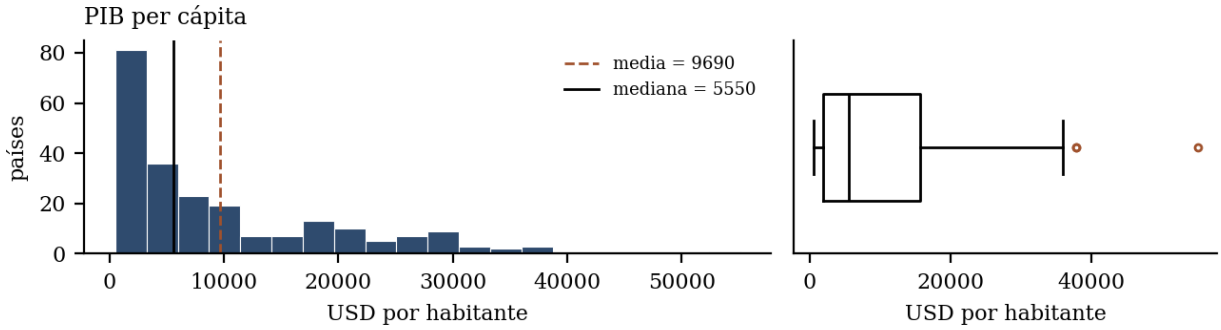


Figura 10. PIB per cápita. Muchos países están por debajo de 10,000 USD y solo unos pocos superan los 30,000 (Luxembourg, Norway, United States). Asimetría 1.4; media de 9,689.8 frente a la mediana 5,550.0; 3 valores atípicos por el criterio del rango intercuartílico.

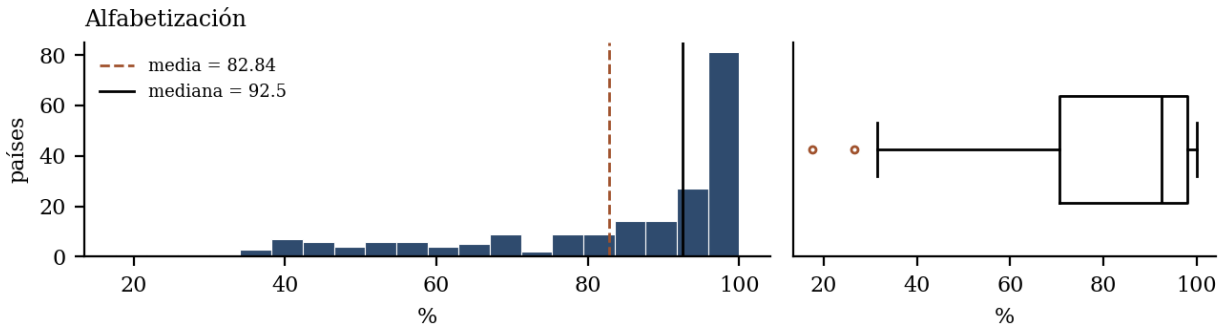


Figura 11. Alfabetización. La distribución se carga hacia el 100 %, con una cola de países de baja alfabetización (sesgo a la izquierda). Asimetría -1.2; media de 82.84 frente a la mediana 92.50; 2 valores atípicos por el criterio del rango intercuartílico.

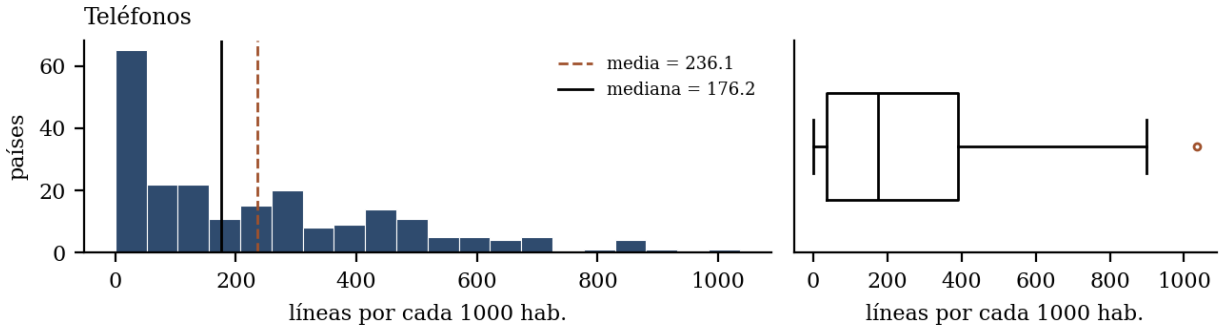


Figura 12. Teléfonos. Cola derecha producida por países con muchísimas líneas por habitante, sobre todo Monaco. Asimetría 1.0; media de 236.1 frente a la mediana 176.2; 1 valor atípico por el criterio del rango intercuartílico.

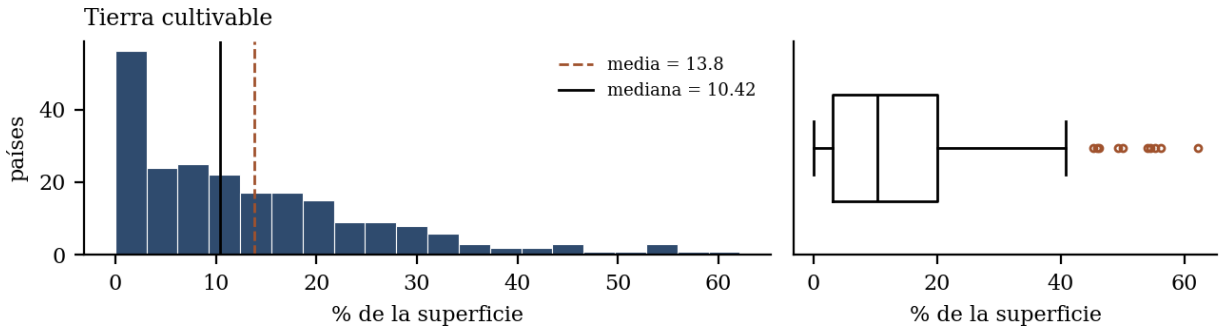


Figura 13. Tierra cultivable. Casi todos los países destinan menos de 30 % a tierra cultivable; Bangladesh es el extremo. Asimetría 1.3; media de 13.80 frente a la mediana 10.42; 10 valores atípicos por el criterio del rango intercuartílico.

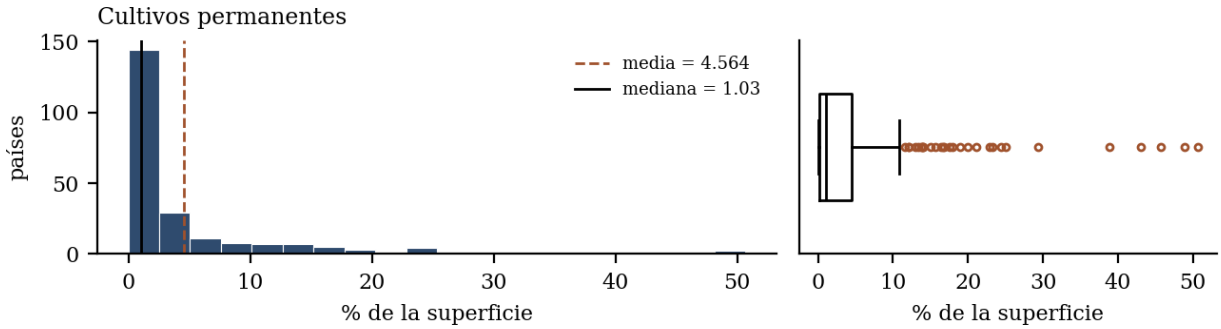


Figura 14. Cultivos permanentes. La mayoría dedica menos de 5 % a cultivos permanentes, pero varias islas pasan del 40 %. Asimetría 3.2; media de 4.56 frente a la mediana 1.03; 29 valores atípicos por el criterio del rango intercuartílico.

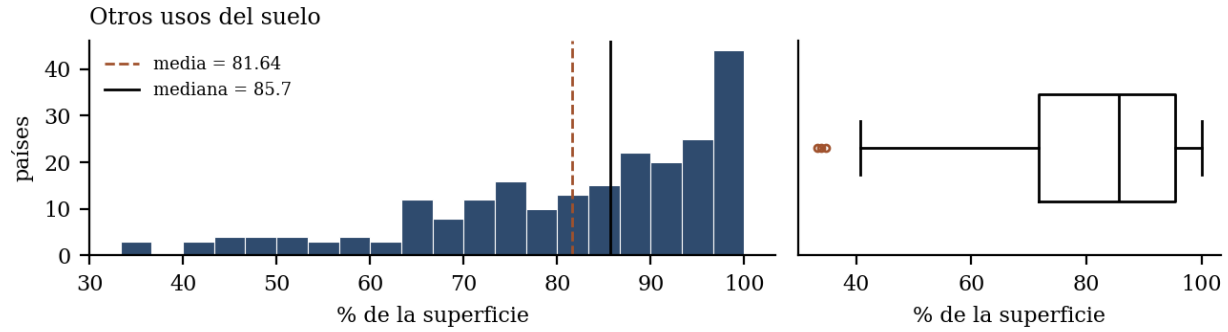


Figura 15. Otros usos del suelo. Es el complemento de las dos variables anteriores (se comprueba en la sección 2), por lo que no aporta información nueva. Asimetría -1.0; media de 81.64 frente a la mediana 85.70; 3 valores atípicos por el criterio del rango intercuartílico.

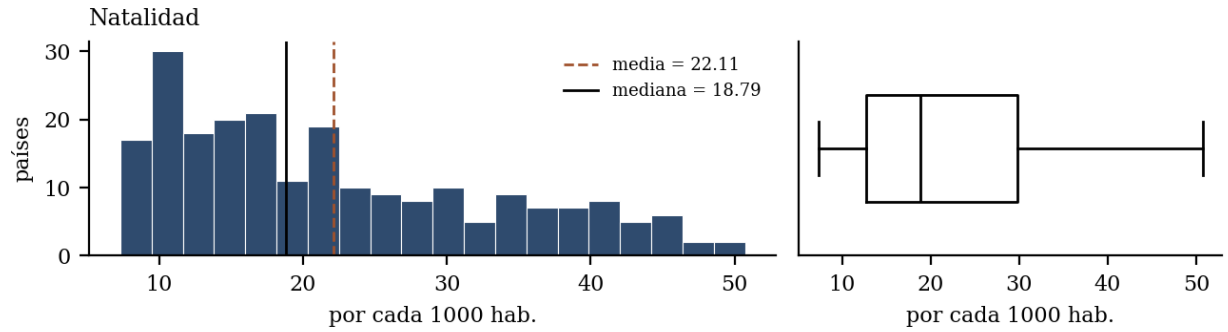


Figura 16. Natalidad. Distribución bastante simétrica, sin valores atípicos por el criterio del rango intercuartílico. Asimetría 0.7; media de 22.11 frente a la mediana 18.79; 0 valores atípicos por el criterio del rango intercuartílico.

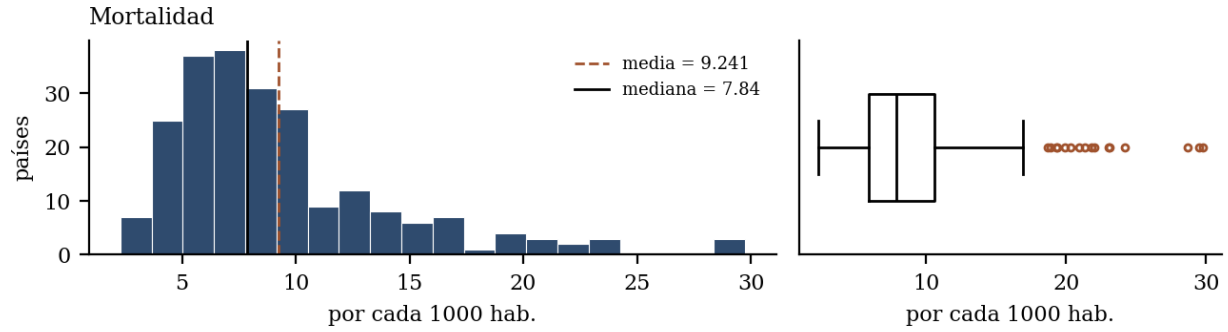


Figura 17. Mortalidad. Concentrada entre 5 y 12; los atípicos son países del sur de África (Swaziland, Botswana, Lesotho). Asimetría 1.7; media de 9.24 frente a la mediana 7.84; 16 valores atípicos por el criterio del rango intercuartílico.

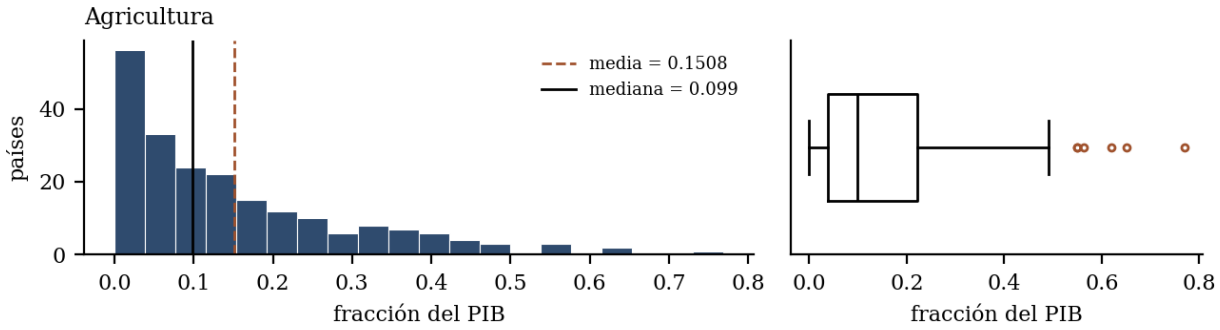


Figura 18. Agricultura. La mayoría de los países depende poco de la agricultura; los extremos (Liberia, Somalia) superan 60 % del PIB. Asimetría 1.4; media de 0.151 frente a la mediana 0.099; 6 valores atípicos por el criterio del rango intercuartílico.

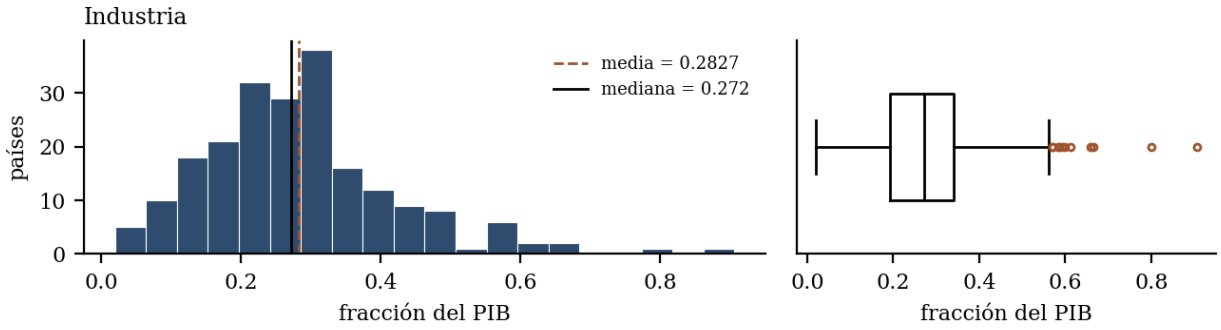


Figura 19. Industria. Distribución con cola derecha moderada; el máximo es Equatorial Guinea. Asimetría 1.1; media de 0.283 frente a la mediana 0.272; 11 valores atípicos por el criterio del rango intercuartílico.

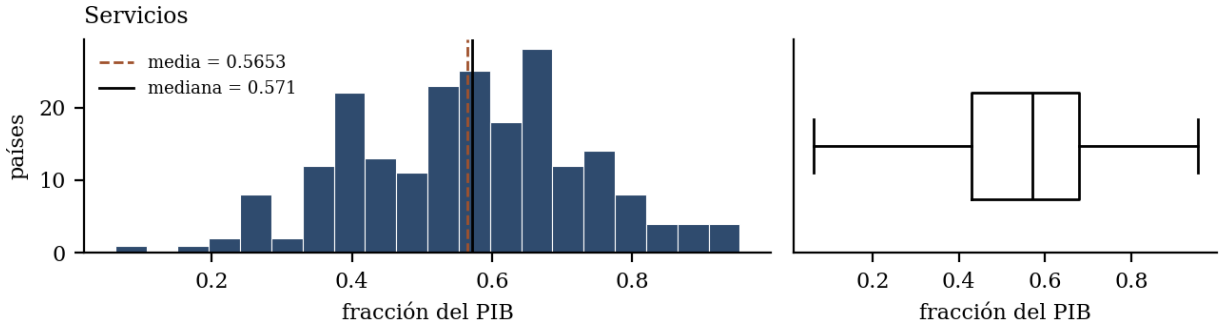


Figura 20. Servicios. Es la más simétrica de todas, sin valores atípicos. Asimetría -0.1; media de 0.565 frente a la mediana 0.571; 0 valores atípicos por el criterio del rango intercuartílico.

En conjunto, casi todas las variables tienen asimetría positiva (la media es mayor que la mediana). Las más asimétricas son población, densidad de población, costa / área, superficie y cultivos permanentes, con coeficientes de asimetría de 3.2 a 9.2. Esto anticipa que algunas necesitarán una transformación antes de calcular correlaciones y componentes principales, algo que se resuelve en la sección 2.

3.2 Medidas descriptivas

Calculamos las medidas descriptivas con las 13 variables elegidas, ya depuradas pero todavía en su escala original (para interpretarlas). La media resume el centro, pero se mueve con los valores extremos; la mediana no. Por eso comparar ambas dice si hay asimetría. La varianza mide la dispersión alrededor de la media:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad s^2(X) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

$$\mathrm{Cov}(X, Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

Los símbolos son los definidos en la sección 1.4: n es el número de países, x_i y y_i son los valores de cada variable en el país i, y la barra sobre una letra indica su media.

```
desc = pd.DataFrame({
    "media": datos[VARS].mean(), "mediana": datos[VARS].median(),
    "varianza": datos[VARS].var(), "desv_est": datos[VARS].std(),
    "minimo": datos[VARS].min(), "maximo": datos[VARS].max()})
cov_orig = datos[VARS].cov()            # covarianza en unidades originales
clave = ["GDP ($ per capita)", "Infant mortality (per 1000 births)", "Literacy (%)",
         "Phones (per 1000)", "Birthrate"]
print(desc.round(3))
print(cov_orig.loc[clave, clave].round(1))
```

Tabla 3. Medidas descriptivas de las 13 variables elegidas (224 países, escala original).

Variable	Media	Mediana	Varianza	Desv. est.	Mínimo	Máximo
Densidad de población	381.5	79.15	2,792,075	1,671.0	0	16,272
Costa / área	21.02	0.725	5,287.1	72.71	0	870.7
Migración neta	0.008	0	23.70	4.87	-20.99	23.06
Mortalidad infantil	35.28	20.94	1,251.5	35.38	2.29	191.2
PIB per cápita	9,748.2	5,700.0	101,501,163	10,075	500.0	55,100
Alfabetización	83.91	92.90	370.6	19.25	17.60	100.0
Teléfonos	236.5	180.3	51,670	227.3	0.200	1,035.6
Tierra cultivable	13.91	10.60	169.6	13.02	0	62.11
Cultivos permanentes	4.47	1.02	68.34	8.27	0	50.68
Natalidad	21.98	18.75	124.0	11.14	7.29	50.73
Mortalidad	9.24	7.97	24.84	4.98	2.29	29.74
Agricultura	0.148	0.098	0.021	0.145	0	0.769
Servicios	0.572	0.581	0.027	0.164	0.062	0.954

La media supera a la mediana en 11 de las 13 variables (todas menos alfabetización y servicios), lo que confirma la asimetría derecha. El caso más claro es costa/área, con media 21.0 y mediana 0.73, y también densidad de población (381 contra 79). En el PIB per cápita la media (9,748) casi duplica a la mediana (5,700): un país "cualquiera" tiene un ingreso mucho menor al que sugiere el promedio.

La Tabla 4 presenta la matriz de covarianza completa de las 13 variables, en su escala original; la diagonal contiene las varianzas y la matriz es simétrica, porque Cov(X, Y) = Cov(Y, X). Las magnitudes van de 0.0148 a 101,501,163 (la varianza del PIB per cápita), es decir, cubren muchos órdenes de magnitud solo

por las unidades de cada variable.

Tabla 4. Matriz de covarianza completa de las 13 variables (escala original, 224 países). La diagonal contiene las varianzas.

	Densidad de población	Costa / área	Migración neta	Mortalidad infantil	PIB per cápita	Alfabeti-zación	Teléfonos	Tierra cultivable	Cultivos perma-nentes	Natalidad	Mortalidad	Agricultura	Servicios
Densidad de población	2,792,075	29,377	1,449.8	−8,518.0	3,298,701	3,142.1	106,738	−1,799.2	−430.5	−2,970.8	−578.2	−26.80	63.10
Costa / área	29,377	5,287.1	−48.56	−357.9	37,680	195.1	2,567.9	−114.4	204.6	−62.82	−58.95	−0.401	2.52
Migración neta	1,449.8	−48.56	23.70	−5.14	19,068	−0.884	271.9	−3.63	−14.02	−4.13	0.859	−0.0798	0.0929
Mortalidad infantil	−8,518.0	−357.9	−5.14	1,251.5	−212,989	−524.5	−5,379.0	−53.08	−18.42	333.3	116.0	3.61	−3.72
PIB per cápita	3,298,701	37,680	19,068	−212,989	101,501,163	97,969	1,904,505	2,492.4	−18,117	−72,175	−10,119	−853.2	917.0
Alfabetización	3,142.1	195.1	−0.884	−524.5	97,969	370.6	2,558.4	18.68	8.89	−167.4	−37.59	−1.66	1.61
Teléfonos	106,738	2,567.9	271.9	−5,379.0	1,904,505	2,558.4	51,670	188.4	−282.8	−1,825.9	−293.4	−19.69	25.05
Tierra cultivable	−1,799.2	−114.4	−3.63	−53.08	2,492.4	18.68	188.4	169.6	10.81	−28.05	3.50	−0.0413	0.132
Cultivos permanentes	−430.5	204.6	−14.02	−18.42	−18,117	8.89	−282.8	10.81	68.34	11.36	−8.57	0.0779	0.0466
Natalidad	−2,970.8	−62.82	−4.13	333.3	−72,175	−167.4	−1,825.9	−28.05	11.36	124.0	22.08	1.09	−1.03
Mortalidad	−578.2	−58.95	0.859	116.0	−10,119	−37.59	−293.4	3.50	−8.57	22.08	24.84	0.273	−0.296
Agricultura	−26.80	−0.401	−0.0798	3.61	−853.2	−1.66	−19.69	−0.0413	0.0779	1.09	0.273	0.0209	−0.0148
Servicios	63.10	2.52	0.0929	−3.72	917.0	1.61	25.05	0.132	0.0466	−1.03	−0.296	−0.0148	0.0269

Tabla 5. Matriz de covarianza (escala original) de cinco indicadores de desarrollo, tomada de la Tabla 4. La diagonal contiene las varianzas.

	PIB per cápita	**Mortalidad infantil**	**Alfabetización**	**Teléfonos**	**Natalidad**
PIB per cápita	101,501,163	-212,989	97,969	1,904,505	-72,175
Mortalidad infantil	-212,989	1,251.5	-524.5	-5,379.0	333.3
Alfabetización	97,969	-524.5	370.6	2,558.4	-167.4
Teléfonos	1,904,505	-5,379.0	2,558.4	51,670	-1,825.9
Natalidad	-72,175	333.3	-167.4	-1,825.9	124.0

Estas cinco variables son las que, como veremos en la sección 3.4, más se relacionan entre sí. Los signos tienen sentido: el PIB per cápita covaría positivamente con los teléfonos y la alfabetización, y negativamente con la mortalidad infantil y la natalidad. Sin embargo, las magnitudes no son comparables entre pares: la covarianza entre PIB y teléfonos (1,904,505) es enorme solo porque el PIB se mide en miles de dólares, mientras que la varianza de la natalidad es 124.0. La covarianza depende de las unidades, y por eso en la sección 3.4 pasamos a la correlación, que no tiene unidades.

3.3 Datos atípicos

Un valor es atípico por el criterio del rango intercuartílico (RIC) si queda más allá de 1.5 veces el RIC por debajo del primer cuartil o por encima del tercero. Contamos esos valores en cada variable antes y después de la transformación de la sección 2, y comparamos las variables en una escala común (valores z) para ver cuáles tienen colas más pesadas.

```
def zscores(df):
    return (df[VARS] - df[VARS].mean()) / df[VARS].std()


at_antes = {v: iqr_atipicos(datos[v]) for v in VARS}
at_despues = {v: iqr_atipicos(trans[v]) for v in VARS}
fig, (a, b) = plt.subplots(1, 2, figsize=(6.6, 3.2), sharey=True)
for ax, df, t in ((a, datos, "Datos depurados"), (b, trans, "Tras la transformación")):
    ax.boxplot(zscores(df).values, vert=False, widths=.6, medianprops=dict(color="black"),
               flierprops=dict(marker="o", ms=2, mfc="none", mec=C2))
    ax.set_title(t, loc="left", fontsize=8); ax.set_xlabel("valor estandarizado (z)")
a.set_yticks(range(1, len(VARS) + 1))
a.set_yticklabels([NOMBRES[v] for v in VARS], fontsize=6.5)
```

```
fig.tight_layout(); fig.savefig(FIG / "fig_atipicos.png")
```

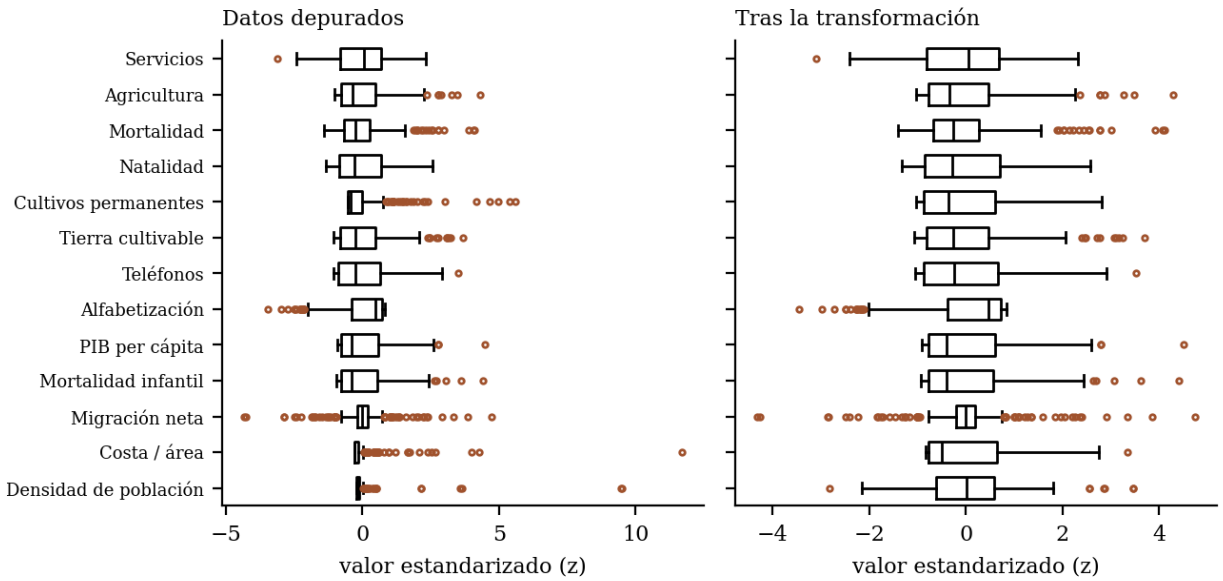


Figura 21. Diagramas de caja de las 13 variables estandarizadas, con los datos depurados (izquierda) y tras la transformación (derecha).

Tabla 6. Valores atípicos por el criterio del RIC. Natalidad no tiene ninguno y no aparece.

Variable	Atípicos antes	Atípicos después	Casos más alejados (datos depurados)
Densidad de población	20	7	Monaco, Macau, Singapore
Costa / área	37	1	Micronesia, Fed. St., Palau, N. Mariana Islands
Migración neta	50	50	Afghanistan, Micronesia, Fed. St., American Samoa
Mortalidad infantil	5	5	Angola, Afghanistan, Sierra Leone
PIB per cápita	3	3	Luxembourg, Norway, United States
Alfabetización	16	16	Niger, Burkina Faso, Sierra Leone
Teléfonos	1	1	Monaco
Tierra cultivable	10	10	Bangladesh, Ukraine, Moldova
Cultivos permanentes	28	0	Kiribati, Sao Tome & Principe, Micronesia, Fed. St.
Mortalidad	16	16	Swaziland, Botswana, Lesotho
Agricultura	7	7	Liberia, Somalia, Guinea-Bissau
Servicios	1	1	Equatorial Guinea

No eliminamos ningún país por ser atípico. Los casos extremos son valores reales y esperables: Luxembourg tiene el PIB per cápita más alto de la muestra, Monaco el mayor número de teléfonos por habitante y también la mayor densidad, seguido de cerca por Macau; no son errores de captura. Quitarlos haría que el estudio dejara fuera justamente a los países que más contrastan. En su lugar, reducimos su influencia de dos maneras: la transformación logarítmica (que baja los atípicos de densidad de 20 a 7, de costa/área de 37 a 1 y de cultivos permanentes de 28 a 0) y la estandarización que se discute en la sección 3.6.

Un caso aparte es migración neta, con 50 atípicos. Aquí el criterio engaña: como 62 países tienen exactamente cero, el rango intercuartílico es muy angosto y valores de apenas unas unidades quedan señalados. La variable va solo de −21 a 23, de modo que no tiene valores realmente extremos y la dejamos

sin cambios. Mortalidad (16) y alfabetización (16) se mantienen por la misma razón: son países reales con situaciones distintas, como el sur de África con alta mortalidad.

3.4 Correlaciones y relación entre variables

3.4.1 Covarianza y correlación de Pearson

Como vimos, la covarianza depende de las unidades. El coeficiente de correlación de Pearson la divide entre las desviaciones estándar de ambas variables:

$$r(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\,\sigma(Y)}$$

Aquí σ(X) y σ(Y) son las desviaciones estándar de X y de Y. Así el resultado queda entre −1 y 1, sin unidades: valores cercanos a 1 indican que las variables crecen juntas, cercanos a −1 que una crece cuando la otra baja y cercanos a 0 que no hay relación lineal. A partir de aquí trabajamos con la base transformada (la que usaremos en el PCA). La Figura 22 muestra por qué la covarianza sola es difícil de interpretar: el PIB per cápita, con varianza del orden de 10^8, domina todo el mapa de color.

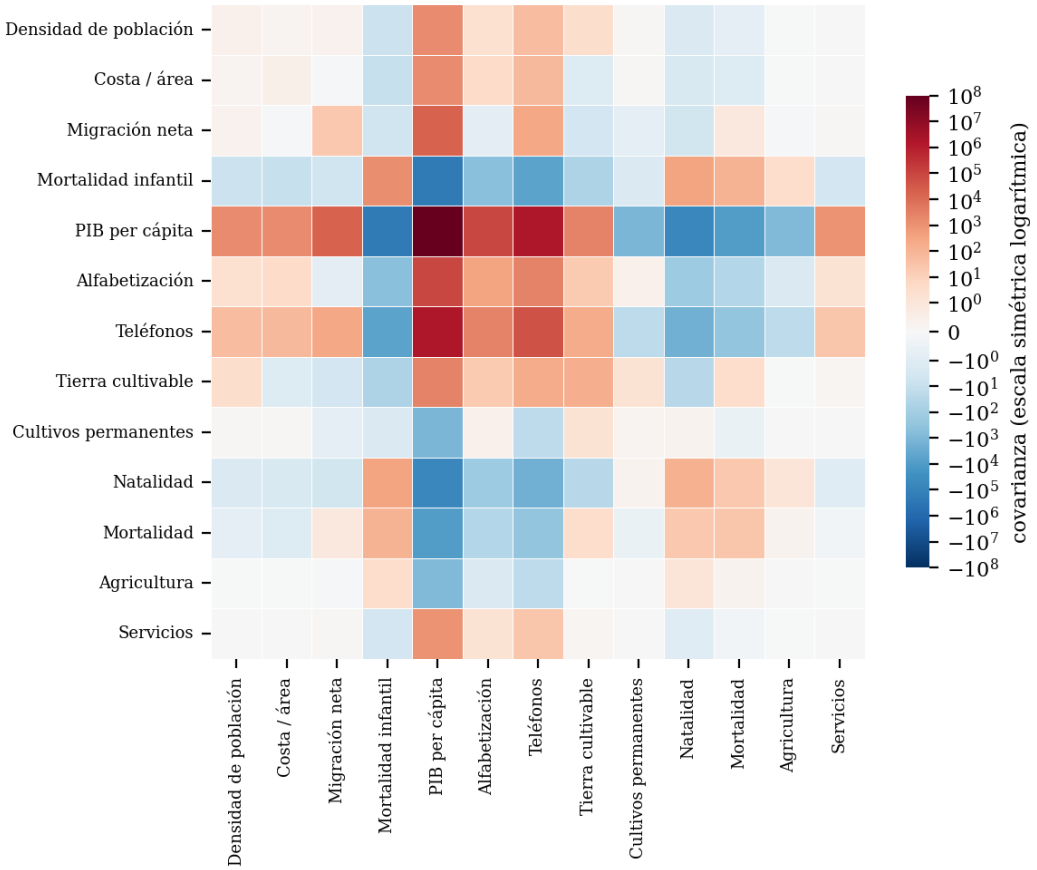


Figura 22. Matriz de covarianza de las 13 variables (escala simétrica logarítmica para que se aprecien todas las magnitudes).

3.4.2 Matriz de correlación

```
corr = trans[VARS].corr(method="pearson")
etq = [NOMBRES[v] for v in VARS]
fig, ax = plt.subplots(figsize=(6.4, 5.3))
sns.heatmap(corr, annot=True, fmt=".2f", cmap="RdBu_r", vmin=-1, vmax=1, square=True,
            linewidths=.3, annot_kws={"size": 5.5}, cbar_kws={"shrink": .7},
            xticklabels=etq, yticklabels=etq, ax=ax)
ax.tick_params(labelsize=6.5)
fig.tight_layout(); fig.savefig(FIG / "fig_corr.png")
```

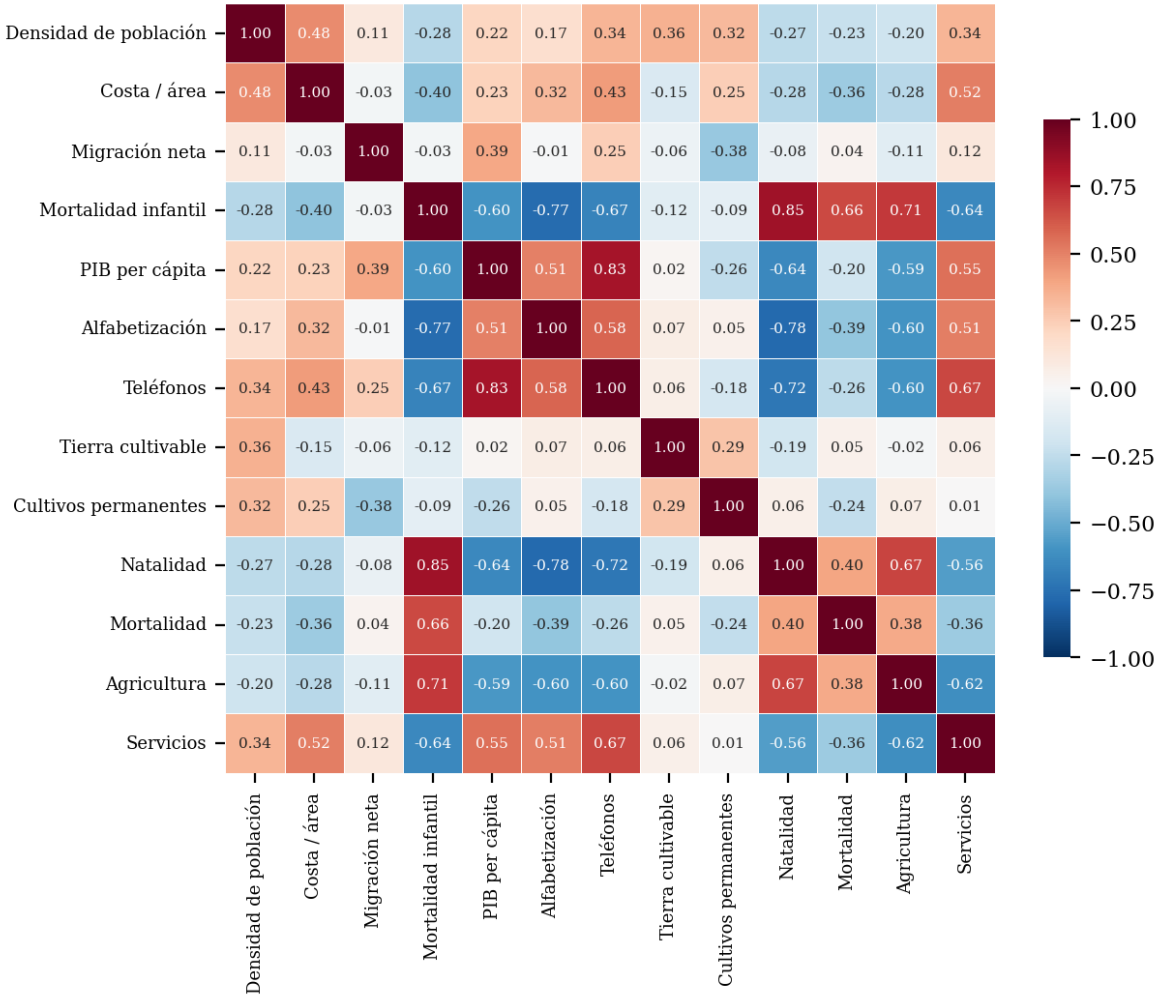


Figura 23. Matriz de correlación de Pearson de las 13 variables (base transformada).

De los 78 pares distintos de variables, 23 tienen correlación de al menos 0.5 en valor absoluto y 2 superan 0.8. La diagonal vale 1 porque cada variable se correlaciona perfectamente consigo misma, y la matriz es simétrica.

Tabla 7. Los ocho pares con mayor correlación en valor absoluto.

Par de variables	r
Natalidad y mortalidad infantil	0.85
Teléfonos y PIB per cápita	0.83
Natalidad y alfabetización	-0.78
Alfabetización y mortalidad infantil	-0.77
Natalidad y teléfonos	-0.72
Agricultura y mortalidad infantil	0.71
Agricultura y natalidad	0.67
Servicios y teléfonos	0.67

Se forma un bloque claro: la natalidad, la mortalidad infantil y la proporción de agricultura se mueven juntas y en sentido contrario al PIB, los teléfonos, la alfabetización y los servicios. En cambio, la tierra cultivable y los cultivos permanentes casi no se relacionan con ese bloque (por ejemplo, |r| = 0.09 entre cultivos permanentes y mortalidad infantil). Esta redundancia es lo que hace útil un PCA.

3.4.3 Variables más y menos relacionadas

Para leer el mapa de calor con más detalle conviene verlo de forma geométrica. Cada variable es un vector de 224 valores, uno por país; si se centran restando su media, el coeficiente de Pearson es el coseno del ángulo que forman los dos vectores. Así, $|r|$ cercano a 1 indica vectores casi paralelos ($r > 0$) u opuestos ($r < 0$), es decir, información repetida, y r cercano a 0 indica vectores casi perpendiculares, que aportan información distinta. Con $n = 224$, una correlación es significativamente distinta de cero al 5 % si $|r| > 0.131$ (prueba t de Pearson); por debajo de ese valor no se puede afirmar que haya relación lineal.

Las más relacionadas. Las relaciones fuertes se concentran en siete variables: mortalidad infantil, natalidad, agricultura, alfabetización, PIB per cápita, teléfonos y servicios. De los 23 pares con $|r| \geq 0.5$, 21 están dentro de ese bloque. Para elegir las cuatro variables más correlacionadas sin arbitrariedad, evaluamos los 715 grupos posibles de cuatro variables y elegimos el de mayor $|r|$ promedio entre sus seis pares; el valor absoluto hace que cuenten igual las relaciones positivas y las negativas. El grupo ganador es natalidad, mortalidad infantil, agricultura y alfabetización, con $|r|$ promedio de 0.729. El segundo, que cambia agricultura por teléfonos, queda prácticamente empatado (0.729), y el tercero, con PIB per cápita y teléfonos, tiene 0.718. Es decir, el núcleo del bloque (mortalidad infantil y natalidad) aparece siempre, y las demás variables del bloque son casi intercambiables entre sí.

Las menos relacionadas. En el otro extremo, 21 de los 78 pares no son significativos. Los valores más bajos son prácticamente cero (Tabla 8). Para elegir las dos variables menos correlacionadas usamos la intensidad media de asociación de cada variable, es decir, su $|r|$ promedio con las otras 12: las más bajas son tierra cultivable (0.12) y migración neta (0.13). Preferimos este criterio al de tomar el par con r más cercano a cero porque ese par puede incluir una variable muy relacionada con las demás: cultivos permanentes y servicios tienen $r = 0.005$, pero servicios forma parte del bloque de desarrollo.

Tabla 8. Los ocho pares con menor correlación en valor absoluto.

Par de variables	r
Servicios y cultivos permanentes	+0.005
Alfabetización y migración neta	-0.009
Tierra cultivable y PIB per cápita	+0.019
Agricultura y tierra cultivable	-0.022
Migración neta y costa / área	-0.027
Mortalidad infantil y migración neta	-0.030
Mortalidad y migración neta	+0.035
Cultivos permanentes y alfabetización	+0.051

```
abs_corr = corr.abs().to_numpy().copy()
np.fill_diagonal(abs_corr, 0.0)
# r_crit: correlación mínima significativa al 5 % con n países (prueba t de Pearson)
from scipy import stats
n = len(trans)
t_c = stats.t.ppf(0.975, n - 2)
r_crit = t_c / np.sqrt(n - 2 + t_c ** 2)
# Las 4 variables más correlacionadas: el grupo de 4 con mayor |r| promedio en sus 6 pares
mejor, top4 = -1.0, None
for comb in combinations(range(p), 4):
    puntaje = abs_corr[np.ix_(comb, comb)].sum() / 12      # cada par aparece dos veces
    if puntaje > mejor:
        mejor, top4 = puntaje, [VARS[k] for k in comb]
# Las 2 variables menos correlacionadas: menor |r| promedio con las otras 12 variables
intensidad = pd.Series(abs_corr.sum(axis=1) / (p - 1), index=VARS).sort_values()
bottom2 = intensidad.index[:2].tolist()
print("r crítico:", round(r_crit, 3), "| 4 más correlacionadas:", top4, round(mejor, 3))
print("2 menos correlacionadas:", bottom2, intensidad[bottom2].round(3).tolist())
```

3.4.4 Comparación gráfica de los vectores más y menos correlacionados

La Figura 24 compara por pares las cuatro variables más correlacionadas, y la Figura 25 y la Tabla 9 las contrastan con las dos menos correlacionadas (tierra cultivable y migración neta) a través de los valores y vectores propios de sus matrices de correlación. Todas usan la base transformada, la misma del mapa de calor.

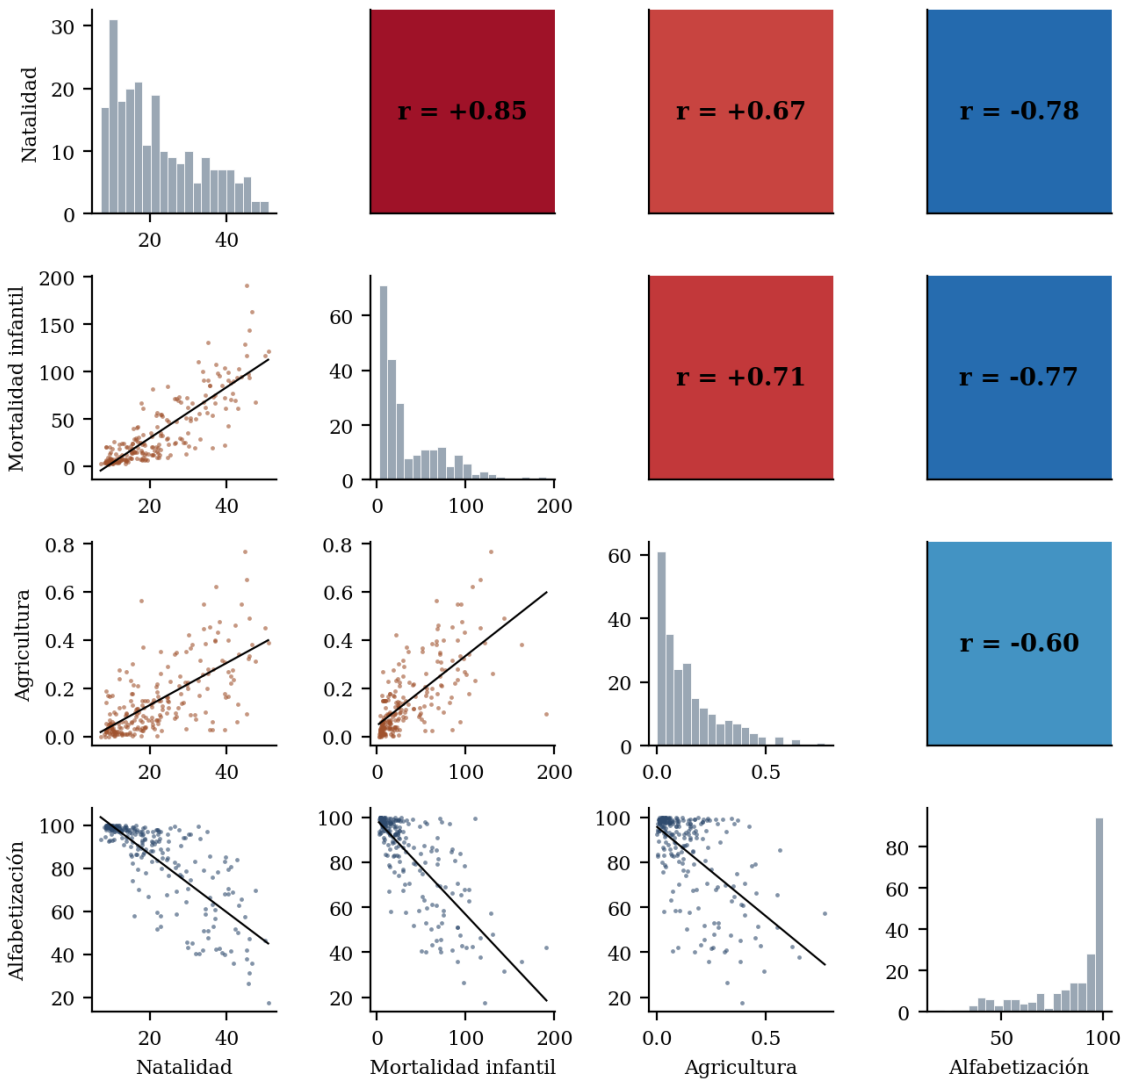


Figura 24. Comparación por pares de las cuatro variables más correlacionadas. Diagonal: distribución; abajo: dispersión con su recta de mínimos cuadrados (siena: r positivo; azul: r negativo); arriba: coeficiente de Pearson con el color del mapa de calor.

Relaciones positivas. Natalidad, mortalidad infantil y agricultura forman un bloque de rezago, con correlaciones entre +0.67 y +0.85: donde nacen más niños también mueren más y la economía depende más de la agricultura. Sus vectores son casi paralelos.

Relaciones negativas. Alfabetización tiene correlación negativa con las tres (de -0.60 a -0.78): su vector apunta en sentido contrario, porque los países con más alfabetización tienen menos natalidad, menos mortalidad infantil y menos peso agrícola.

No todo es lineal. La alfabetización se satura en el 100 % y la agricultura frente a la mortalidad infantil se abre en abanico. Pearson mide solo la parte lineal de la relación, así que en esos pares la asociación real es incluso más fuerte que *r*. **Consecuencia para el PCA:** cuatro vectores casi colineales contienen esencialmente una sola dirección de variación; por eso, en la sección 3.5.4, las cuatro tienen cargas grandes en la CP1 (−0.87, −0.91, −0.79, 0.79).

```
fig, axes = plt.subplots(4, 4, figsize=(6.6, 6.3))
for i, vi in enumerate(top4):
    for j, vj in enumerate(top4):
        ax, r = axes[i, j], corr.loc[vi, vj]
        if i == j:                                  # diagonal: distribución de la variable
            ax.hist(trans[vi], bins=20, color="#9aa7b4", edgecolor="white", linewidth=.3)
        elif i > j:                                 # abajo: dispersión y recta de mínimos cuadrados
            ax.scatter(trans[vj], trans[vi], s=3, alpha=.6, linewidths=0, color=C2 if r > 0 else C1)
            m, c0 = np.polyfit(trans[vj], trans[vi], 1)
            xs = np.linspace(trans[vj].min(), trans[vj].max(), 50)
            ax.plot(xs, m * xs + c0, color="black", lw=.8)
        else:                                       # arriba: coeficiente r con el color del mapa de calor
            ax.set_facecolor(cmap_r((r + 1) / 2)); ax.set_xticks([]); ax.set_yticks([])
            ax.text(.5, .5, f"r = {r:+.2f}", ha="center", va="center", fontsize=10,
                    fontweight="bold", transform=ax.transAxes)
        ax.set_xlabel(NOMBRES[vj] if i == 3 else ""); ax.set_ylabel(NOMBRES[vi] if j == 0 else "")
fig.tight_layout(); fig.savefig(FIG / "fig_comparacion_correlaciones.png")
```

Valores y vectores propios de las variables más y menos correlacionadas. Para ver qué distingue a las variables muy correlacionadas de las poco correlacionadas, conviene empezar por el caso más simple: dos variables estandarizadas. Su matriz de correlación y su descomposición en valores y vectores propios son:

$$R = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix} \qquad \lambda_1 = 1 + |r|, \quad \lambda_2 = 1 - |r| \qquad v \in \left\{ \frac{(1,\ 1)}{\sqrt{2}},\ \frac{(1,\ -1)}{\sqrt{2}} \right\}$$

donde r es la correlación del par. Los vectores propios son siempre las dos diagonales, sin importar el valor de r: el primero sigue la diagonal $(1, 1)/\sqrt{2}$ cuando $r > 0$ y la $(1, -1)/\sqrt{2}$ cuando $r < 0$. Lo que cambia con la intensidad de la relación son los valores propios: λ_1 es la varianza de los países a lo largo de la diagonal principal y λ_2 la varianza en la dirección perpendicular. Como $\lambda_1 + \lambda_2 = 2$, la primera componente explica $(1 + |r|)/2$ de la varianza del par, desde 50 % cuando no hay correlación hasta 100 % cuando es perfecta. La Figura 25 lo muestra con datos: el par más correlacionado positivamente y el más correlacionado negativamente dentro de las cuatro variables, frente al par de las dos menos correlacionadas.

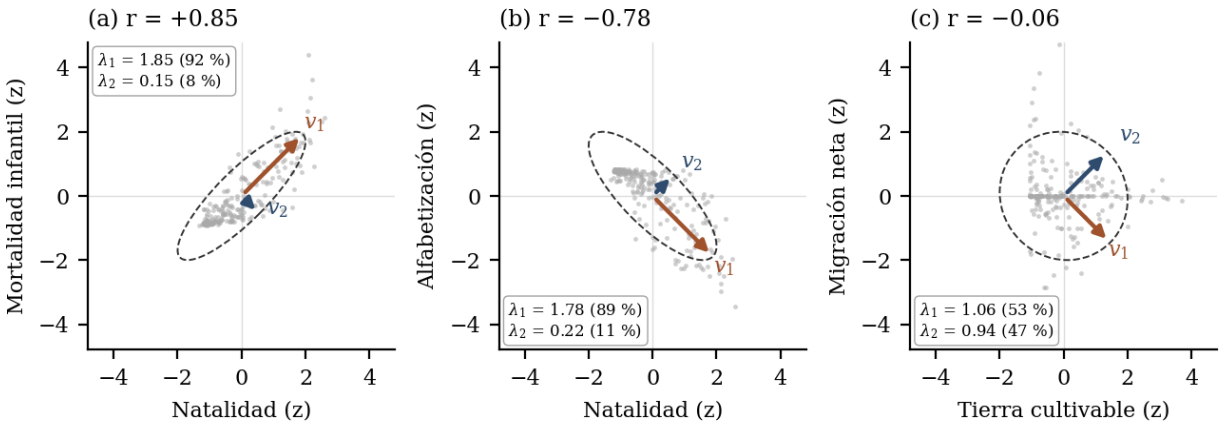


Figura 25. Vectores propios de la matriz de correlación de tres pares de variables, en valores z. La flecha siena es v_1 y la azul v_2; cada una mide $2\sqrt{\lambda}$, y la elipse punteada abarca dos desviaciones estándar en cada dirección propia. (a) Natalidad y mortalidad infantil; (b) natalidad y alfabetización; (c) tierra cultivable y migración neta, las dos variables menos correlacionadas.

En los paneles (a) y (b) la nube de países es una elipse alargada: λ_1 vale 1.85 y 1.78, de modo que la primera componente concentra 92 % y 89 % de la varianza del par y la segunda apenas 8 % y 11 %. Las dos variables comparten casi toda su información, y el signo de r solo decide si la elipse sigue la diagonal ascendente o la descendente. En el panel (c) la nube es casi un círculo: $\lambda_1 = 1.06$ y $\lambda_2 = 0.94$, así que la

"dirección principal" explica solo 53 % y cualquier otra dirección explicaría prácticamente lo mismo; resumir ese par en una componente perdería casi la mitad de su información.

Tabla 9. Valores propios y primer vector propio de la matriz de correlación de cada par: los seis pares de las cuatro variables más correlacionadas y, en la última fila, el par de las dos menos correlacionadas.

Par de variables	r	λ_1	λ_2	% en CP1	v_1
Natalidad y mortalidad infantil	+0.85	1.846	0.154	92.3	(+0.71, +0.71)
Natalidad y agricultura	+0.67	1.675	0.325	83.7	(+0.71, +0.71)
Natalidad y alfabetización	−0.78	1.781	0.219	89.0	(+0.71, −0.71)
Mortalidad infantil y agricultura	+0.71	1.707	0.293	85.3	(+0.71, +0.71)
Mortalidad infantil y alfabetización	−0.77	1.770	0.230	88.5	(+0.71, −0.71)
Agricultura y alfabetización	−0.60	1.597	0.403	79.8	(+0.71, −0.71)
Tierra cultivable y migración neta	−0.06	1.057	0.943	52.9	(+0.71, −0.71)

La Tabla 9 extiende la comparación a los seis pares del bloque. En todos, λ_1 va de 1.60 a 1.85 (80 % a 92 % de la varianza del par), mientras que en el par de las dos menos correlacionadas es 1.06 (52.9 %). El vector v_1 solo cambia de signo en su segunda coordenada según el signo de r. En el programa comprobamos que $\lambda_1 = 1 + |r|$ y $\lambda_2 = 1 - |r|$ en todos los pares.

Las cuatro más correlacionadas. Al tomar juntas las cuatro variables, en su matriz de correlación de 4 × 4, $\lambda_1 = 3.19$ concentra 79.9 % de la varianza del grupo y los otros tres valores propios quedan muy por debajo de 1 (0.42, 0.23 y 0.15): las cuatro variables ocupan, en la práctica, una sola dimensión. Su vector propio, v_1 = (+0.52 natalidad, +0.52 mortalidad infantil, +0.46 agricultura, −0.49 alfabetización), reparte el peso casi por igual, con coeficientes de magnitud entre 0.46 y 0.52, muy cerca de $1/\sqrt{4} = 0.5$, positivos para las variables de rezago y negativo para la alfabetización, por lo que la dirección principal es un promedio de las cuatro y no una de ellas en particular; los vectores siguientes solo describen diferencias pequeñas, como lo que distingue a la agricultura del resto (v_2, coeficiente −0.84).

Las dos menos correlacionadas. En su matriz de correlación de 2 × 2, los valores propios (1.06 y 0.94) están pegados a 1, el valor que tendrían si no hubiera ninguna correlación, y explican 53 % y 47 % de la varianza. Sus vectores propios, (+0.71, −0.71) y (+0.71, +0.71), son las diagonales que impone la simetría de cualquier matriz de 2 × 2, no una estructura de los datos: ninguna combinación resume mejor la información que las propias variables originales.

En resumen, las variables muy correlacionadas tienen un valor propio dominante y un vector propio que las combina a todas con pesos parecidos, por lo que son redundantes y el PCA las resume en una sola componente; en el PCA de las trece variables, las cuatro tienen cargas grandes en la CP1 (sección 3.5.4). Las poco correlacionadas tienen valores propios cercanos a 1: cada una conserva información propia que solo aparece en componentes posteriores. Por eso una o dos componentes no bastan para resumir las trece variables, y decidir cuántas conservar requiere criterios algo más formales (sección 3.5.3).

3.4.5 Variables independientes y dependientes

Para separar variables que actúan como punto de partida de las que parecen depender de otras, usamos dos pistas: el sentido que tiene cada variable (una característica física del territorio no depende del ingreso de un país; la mortalidad infantil sí puede depender de él) y qué tan fuerte es su correlación con las demás. La Tabla 10 resume la clasificación junto con la mayor correlación de cada variable.

Tabla 10. Clasificación de las variables según su papel y mayor correlación con otra variable.

Variable	Papel	Justificación	Mayor |r| (con)
Densidad de población	Independiente	Es una condición de partida (población entre superficie).	0.48 (Costa / área)
Costa / área	Independiente	Es una característica geográfica fija.	0.52 (Servicios)
Migración neta	Dependiente (débil)	Responde a condiciones económicas, pero su relación lineal es baja.	0.39 (PIB per cápita)
Mortalidad infantil	Dependiente	Resultado de la salud y el ingreso; muy ligada a la natalidad.	0.85 (Natalidad)
PIB per cápita	Dependiente	Se mueve con la infraestructura (teléfonos) y la educación.	0.83 (Teléfonos)
Alfabetización	Dependiente	Resultado de la educación, relacionada con el desarrollo.	0.78 (Natalidad)
Teléfonos	Dependiente	Indicador de infraestructura que acompaña al ingreso.	0.83 (PIB per cápita)
Tierra cultivable	Independiente	Depende del suelo y del clima, no del ingreso.	0.36 (Densidad de población)
Cultivos permanentes	Independiente	Depende del suelo y del clima.	0.38 (Migración neta)
Natalidad	Dependiente	Cambia con el nivel de desarrollo y educación.	0.85 (Mortalidad infantil)
Mortalidad	Dependiente	Depende de la edad de la población y de la salud.	0.66 (Mortalidad infantil)
Agricultura	Dependiente	Su peso disminuye al crecer la economía.	0.71 (Mortalidad infantil)
Servicios	Dependiente	Su peso aumenta al crecer la economía.	0.67 (Teléfonos)

Las cuatro variables que clasificamos como independientes tienen correlaciones máximas bajas (entre 0.36 y 0.52), lo que es coherente con que no las determine el resto. Las dependientes forman el bloque con correlaciones de 0.66 a 0.85. La correlación no demuestra causalidad, de modo que la clasificación debe leerse como una hipótesis razonable: por ejemplo, el PIB y los teléfonos pueden influirse mutuamente. Si más adelante se quisiera ajustar un modelo, buenas variables respuesta serían el PIB per cápita o la mortalidad infantil, explicadas con las condiciones geográficas y demográficas.

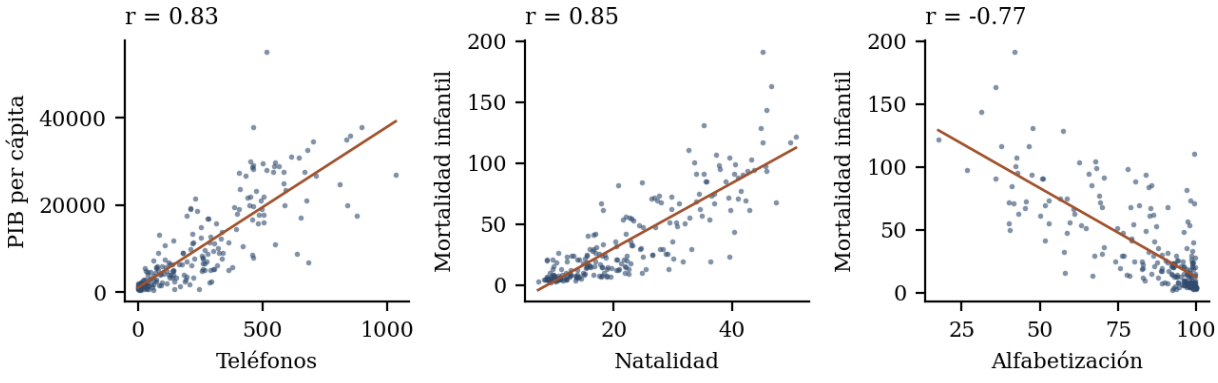


Figura 26. Tres relaciones entre variables dependientes, con su recta de ajuste y su coeficiente de correlación.

3.5 Componentes principales (PCA)

3.5.1 Qué ventaja ofrece el PCA

Con 13 variables y una estructura de correlación como la de la sección 3.4, trabajar variable por variable es redundante. El PCA construye combinaciones lineales de las variables (las componentes principales, CP) que están ordenadas por la varianza que explican y no están correlacionadas entre sí. Las ventajas concretas para estos datos son:

Primero, la reducción: veremos que 4 componentes conservan alrededor de 77 % de la información de las 13 variables. Segundo, la eliminación de redundancia: las componentes son ortogonales, y lo verificamos numéricamente, pues la mayor covarianza entre dos componentes es 2.2e-15, es decir, cero salvo error de redondeo. Tercero, la visualización: las dos primeras componentes (57.8 % de la varianza) permiten dibujar a los países en un plano. A cambio, perdemos parte de la información (lo que queda fuera de las componentes elegidas) y las componentes tienden a ser más difíciles de interpretar que las variables originales.

3.5.2 Cómo se calculan

El procedimiento es el siguiente. Se centran los datos restando la media de cada variable; se calcula la matriz de covarianza; se obtienen sus valores propios λ y vectores propios; cada vector propio da los coeficientes de una componente y su valor propio es la varianza de esa componente. La proporción de varianza explicada por la componente *i* es $\lambda_i / \Sigma\lambda$, donde λ_i es el valor propio de la componente *i* y Σλ es la suma de todos los valores propios (la varianza total). Las componentes principales se obtienen multiplicando los datos centrados por los vectores propios.

Calculamos el PCA de dos formas: con la matriz de covarianza de los datos sin estandarizar y con la de los datos estandarizados (cada variable dividida entre su desviación estándar). La matriz de covarianza de los datos estandarizados es igual a la matriz de correlación de los datos originales. Lo demostramos desarrollando los dos procedimientos para un par cualquiera de variables X_j y X_k, donde x_{ij} es el valor de la variable *j* en el país *i*, $\bar{x}_j$ su media, s_j su desviación estándar y *n* el número de países.

Procedimiento 1: covarianza de los datos estandarizados. Cada valor se estandariza como $z_{ij} = (x_{ij} - \bar{x}_j)/s_j$. La media de una variable estandarizada es cero, porque la suma de los valores es *n* veces su media:

$$\bar{z}_j = \frac{1}{n}\sum_{i=1}^{n}\frac{x_{ij}-\bar{x}_j}{s_j} = \frac{1}{n\,s_j}\left(\sum_{i=1}^{n}x_{ij} - n\bar{x}_j\right) = \frac{1}{n\,s_j}(n\bar{x}_j - n\bar{x}_j) = 0$$

Por lo tanto, en la covarianza de Z_j y Z_k las medias valen cero y, al sustituir la definición de *z*, se obtiene:

$$\mathrm{Cov}(Z_j, Z_k) = \frac{1}{n-1}\sum_{i=1}^{n} z_{ij}\,z_{ik} = \frac{1}{n-1}\sum_{i=1}^{n}\frac{x_{ij}-\bar{x}_j}{s_j}\cdot\frac{x_{ik}-\bar{x}_k}{s_k} = \frac{\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k)}{(n-1)\,s_j\,s_k}$$

Procedimiento 2: correlación de Pearson de los datos originales. Al sustituir la definición de covarianza (sección 1.4.1) en la de correlación (sección 1.4.2):

$$r(X_j, X_k) = \frac{\mathrm{Cov}(X_j, X_k)}{s_j\, s_k} = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k)}{s_j\, s_k} = \frac{\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(x_{ik}-\bar{x}_k)}{(n-1)\, s_j\, s_k}$$

Las dos expresiones finales son idénticas, así que $\mathrm{Cov}(Z_j, Z_k) = r(X_j, X_k)$ para todo par de variables. En la diagonal, $\mathrm{Var}(Z_j) = \mathrm{Cov}(Z_j, Z_j) = s_j^2 / s_j^2 = 1$, que coincide con $r(X_j, X_j) = 1$. En forma matricial, si X_c es la matriz de datos centrados, S su matriz de covarianza y $D = \mathrm{diag}(s_1, \ldots, s_p)$ la matriz diagonal de desviaciones estándar, entonces $Z = X_c D^{-1}$ y, como D es simétrica:

$$S_Z = \frac{Z^\top Z}{n-1} = \frac{(X_c D^{-1})^\top (X_c D^{-1})}{n-1} = D^{-1}\frac{X_c^\top X_c}{n-1} D^{-1} = D^{-1} S D^{-1} = R$$

Por ejemplo, para natalidad y mortalidad infantil, Cov = 333.29, s = 11.14 y s = 35.38. Por el procedimiento 2, r = 333.29 / (11.14 × 35.38) = 0.846, y la covarianza de las dos variables ya estandarizadas (procedimiento 1) da el mismo valor, 0.846.

```
X = trans[VARS].to_numpy(float)
Xc = X - X.mean(axis=0)                    # datos centrados
S = np.cov(Xc, rowvar=False)               # covarianza sin estandarizar
Z = Xc / X.std(axis=0, ddof=1)             # datos estandarizados
R = np.cov(Z, rowvar=False)                # covarianza de los estandarizados (= matriz de correlación)


def pca_manual(M):
    valores, vectores = np.linalg.eigh(M)
    orden = np.argsort(valores)[::-1]
    valores, vectores = valores[orden], vectores[:, orden]
    for j in range(vectores.shape[1]):     # signo: CP1 con PIB positivo; en las demás, la mayor carga
        positiva
        ref = VARS.index("GDP ($ per capita)") if j == 0 else np.abs(vectores[:, j]).argmax()
        if vectores[ref, j] < 0:
            vectores[:, j] *= -1
    return valores, vectores


val_s, vec_s = pca_manual(S)               # sin estandarizar
val_z, vec_z = pca_manual(R)               # estandarizados
```

3.5.3 Por qué elegimos cuatro componentes

Para elegir el número de componentes aplicamos el criterio de Kaiser descrito en la sección 1.4.6 al caso estandarizado, que es el que tiene sentido interpretar (la sección 3.6 lo justifica): se conservan las componentes cuyo valor propio es mayor que 1. La Figura 27 muestra los valores propios junto a ese umbral y la Tabla 11 los seis primeros con su porcentaje de varianza.

```
p = len(VARS)
prop_z = val_z / val_z.sum()               # proporción de varianza de cada componente
acum_z = np.cumsum(prop_z)                 # proporción acumulada
k_kaiser = int((val_z > 1).sum())          # criterio de Kaiser: valores propios mayores que 1
k = k_kaiser
print("Kaiser:", k_kaiser, "componentes")
print(np.round(val_z, 2)); print(np.round(100 * acum_z, 1))
```

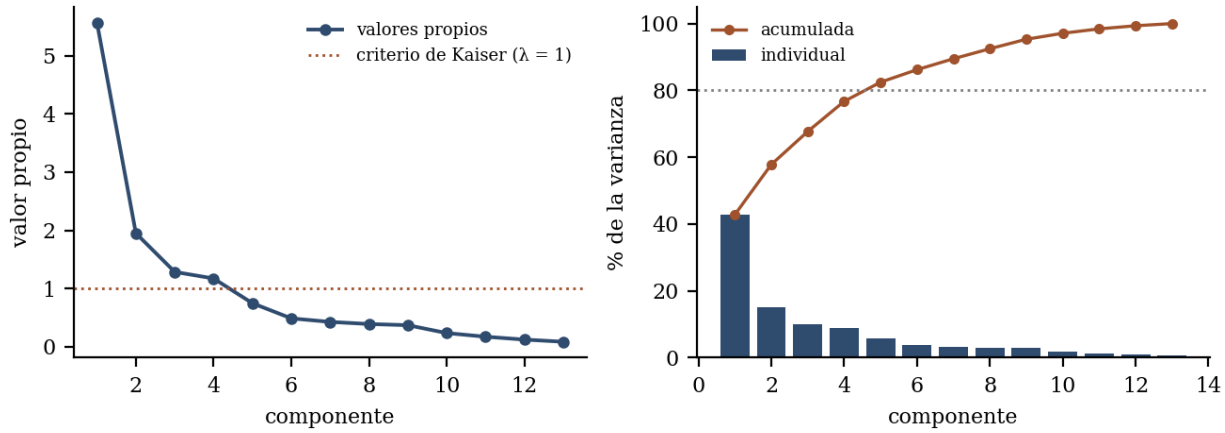


Figura 27. Izquierda: valores propios y umbral del criterio de Kaiser (λ = 1). Derecha: varianza explicada individual y acumulada.

Tabla 11. Valores propios de la matriz de correlación (primeras seis componentes).

Componente	Valor propio	% de varianza	% acumulado	¿λ > 1?
CP1	5.57	42.8	42.8	Sí
CP2	1.95	15.0	57.8	Sí
CP3	1.29	9.9	67.7	Sí
CP4	1.17	9.0	76.7	Sí
CP5	0.75	5.7	82.5	No
CP6	0.49	3.7	86.2	No

Hay 4 valores propios mayores que 1, así que el criterio de Kaiser conserva 4 componentes. La CP1 (5.57) y la CP2 (1.95) quedan muy por encima del umbral; la CP3 y la CP4 (1.29 y 1.17) lo superan con menor margen y juntas aportan 18.9 % de la varianza. Con 4 componentes se explica 76.7 % de la varianza, mucho más que el 57.8 % de dos componentes, y, como se ve en la siguiente subsección, la CP3 y la CP4 tienen una interpretación geográfica clara. La CP5 (0.75) queda por debajo de 1 y no se incluye.

3.5.4 Interpretación de las componentes

Los coeficientes de cada componente se interpretan mejor como cargas, es decir, como la correlación entre cada variable original y la componente. Una carga grande en valor absoluto indica que esa variable pesa mucho en la componente.

```
cargas = vec_z * np.sqrt(val_z)              # correlación entre variable y componente
CP = [f"CP{i}" for i in range(1, p + 1)]
tabla_cargas = pd.DataFrame(cargas, index=[NOMBRES[v] for v in VARS], columns=CP)
scores_z = Z @ vec_z
off = np.abs(np.cov(scores_z, rowvar=False) - np.diag(val_z)).max()
print(tabla_cargas.iloc[:, :k + 1].round(2))
print("covarianza entre componentes (máx. fuera de la diagonal):", f"{off:.1e}")
```

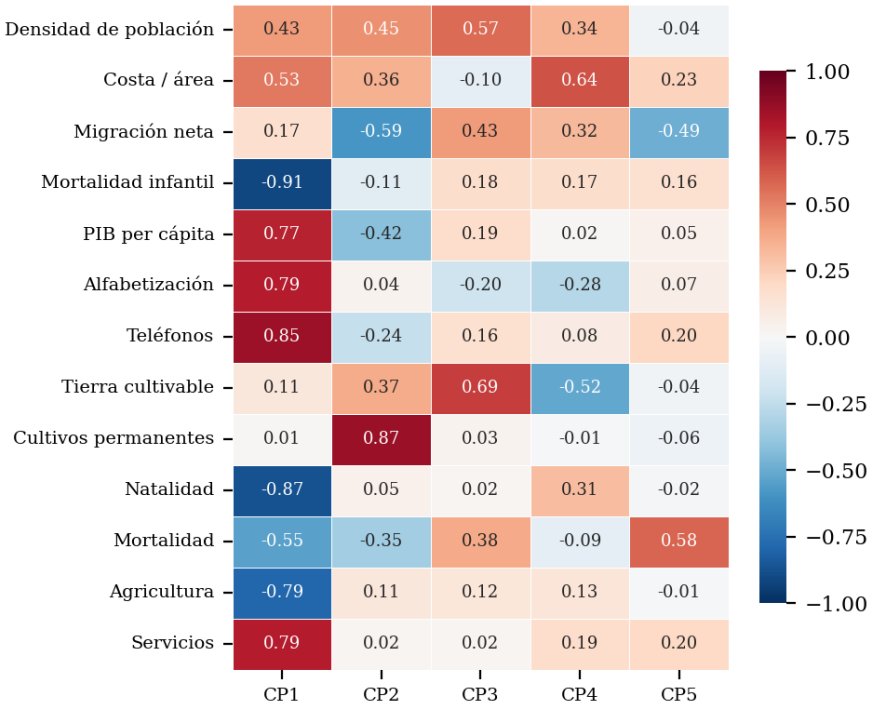


Figura 28. Cargas de las variables en las primeras cinco componentes (rojo: positivas; azul: negativas).

La CP1 (42.8 % de la varianza) separa a los países por nivel de desarrollo: pesan a favor el PIB per cápita (0.77), los teléfonos (0.85), la alfabetización (0.79) y los servicios (0.79), y en contra la mortalidad infantil (−0.91), la natalidad (−0.87), la agricultura (−0.79) y la mortalidad (−0.55). Una puntuación alta indica un país con ingreso, infraestructura y educación altos y una población con baja natalidad.

La CP2 (15.0 %) está dominada por los cultivos permanentes (0.87), con aportes de la migración neta (−0.59), la densidad (0.45), el PIB (−0.42) y la costa/área (0.36). Describe un perfil de territorios pequeños, con mucha costa y densidad, cultivos permanentes y emigración, típico de islas. Esta lectura es nuestra interpretación y no algo que los datos afirmen por sí mismos.

La CP3 (9.9 %) mezcla tierra cultivable (0.69) y densidad (0.57), con migración neta y mortalidad: la intensidad del uso agrícola del territorio y su relación con la población. La CP4 (9.0 %) contrapone la razón costa/área (0.64) con la tierra cultivable (−0.52): geografía costera frente a tierra de cultivo.

3.5.5 Los países en el plano de las dos primeras componentes

```
grupos = trans["Region"].map(GRUPO)
fig, ax = plt.subplots(figsize=(6.4, 4.8))
for g, c in COLORES.items():
    m = (grupos == g).to_numpy()
    ax.scatter(scores_z[m, 0], scores_z[m, 1], s=14, color=c, alpha=.75, linewidths=0, label=g)
esc = 0.85 * np.abs(scores_z[:, :2]).max() / np.abs(cargas[:, :2]).max()
for i, v in enumerate(VARS):
    ax.arrow(0, 0, esc * cargas[i, 0], esc * cargas[i, 1], color="black", lw=.6, head_width=.08)
    ax.text(esc * cargas[i, 0] * 1.07, esc * cargas[i, 1] * 1.07, NOMBRES[v], fontsize=6.2)
ax.axhline(0, color="gray", lw=.4); ax.axvline(0, color="gray", lw=.4)
ax.set_xlabel(f"CP1 ({100 * prop_z[0]:.1f} % de la varianza)")
ax.set_ylabel(f"CP2 ({100 * prop_z[1]:.1f} % de la varianza)")
ax.legend(frameon=False, fontsize=6.5, loc="lower left")
fig.tight_layout(); fig.savefig(FIG / "fig_biplot.png")
```

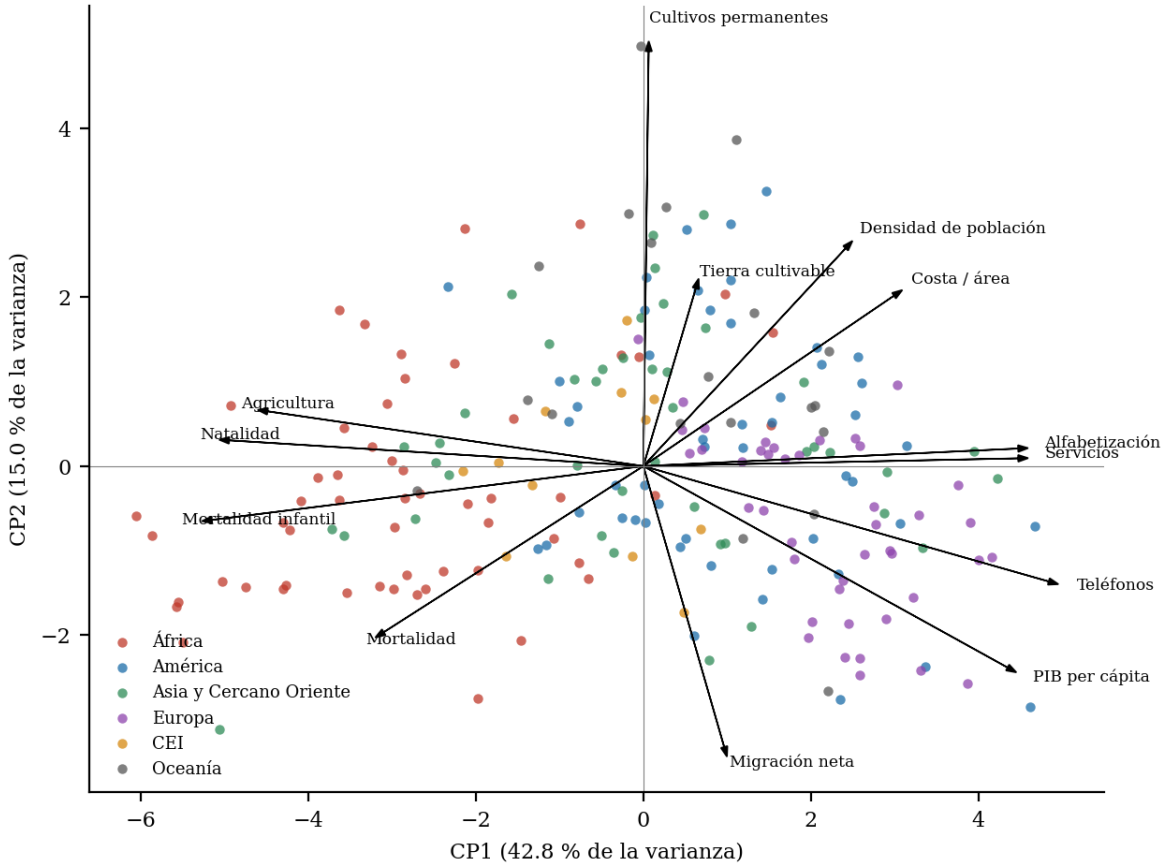


Figura 29. Países en el plano de CP1 y CP2, coloreados por grupo de regiones; las flechas son las cargas de las variables.

Las regiones se ordenan sobre la CP1 como cabría esperar. Las puntuaciones medias son: Europa 2.21, América 1.05, Oceanía 0.61, Asia y Cercano Oriente -0.06, CEI -0.61 y África -2.73. Los puntos más altos en la CP1 son Bermuda, Cayman Islands, Hong Kong, y los más bajos Liberia, Sierra Leone, Somalia. Que una variable construida solo con números reproduzca la geografía del desarrollo es una señal de que las componentes recogen estructura real y no ruido.

3.5.6 Regresar a la matriz original: reconstrucción con k componentes

Una forma de juzgar la reducción es volver de las componentes a la matriz de datos y comparar con la original. Reconstruimos la matriz estandarizada con las primeras *k* componentes, deshacemos la estandarización y el logaritmo y medimos el error. Con las 13 componentes se recupera exactamente la matriz original (lo verificamos numéricamente), así que toda la pérdida viene de las componentes que se descartan.

```
media, desv = X.mean(axis=0), X.std(axis=0, ddof=1)


def reconstruir(kk):
    Zk = scores_z[:, :kk] @ vec_z[:, :kk].T        # aproximación de Z con kk componentes
    Xk = Zk * desv + media                         # se deshace la estandarización
    for j, v in enumerate(VARS):
        if v in a_log:
            Xk[:, j] = 10 ** Xk[:, j] - 1          # se deshace log10(x + 1)
    return Zk, Xk

original = datos[VARS].to_numpy(float)
```

```
sst = ((original - original.mean(axis=0)) ** 2).sum(axis=0)
err_rel, r2_var = [], {}
for kk in range(1, p + 1):
    Zk, Xk = reconstruir(kk)
    err_rel.append(np.linalg.norm(Z - Zk) / np.linalg.norm(Z))
    r2_var[kk] = 1 - ((original - Xk) ** 2).sum(axis=0) / sst
err_rel = np.array(err_rel)
print("con k = p se recupera la matriz original:", np.allclose(reconstruir(p)[1], original))
print("error^2 = varianza no explicada:", np.allclose(err_rel ** 2, 1 - acum_z))
print("error relativo con k componentes:", np.round(err_rel, 3))
```

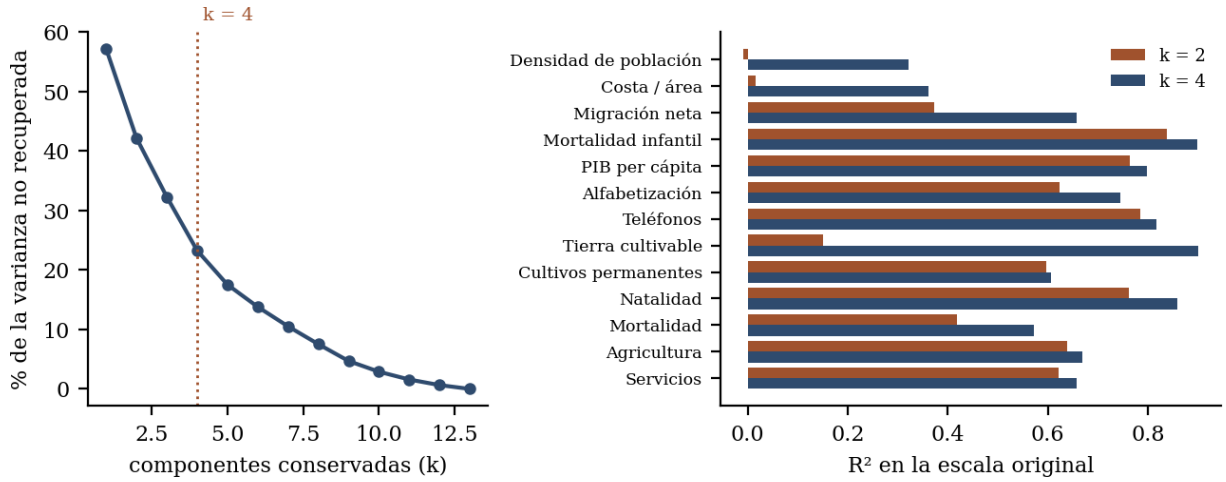


Figura 30. Izquierda: porcentaje de la varianza que no se recupera según el número de componentes conservadas. Derecha: R^2 de cada variable, en su escala original, al reconstruir con 2 y con 4 componentes.

El error relativo baja de 0.76 con una componente a 0.48 con cuatro. Su cuadrado es igual a 1 menos la varianza acumulada (también lo comprobamos), de modo que con cuatro componentes se deja de recuperar 23.3 % de la varianza, justo la que explicaban las componentes descartadas.

Variable por variable, con cuatro componentes se recuperan bien Tierra cultivable (0.90), Mortalidad infantil (0.90), Natalidad (0.86), Teléfonos (0.82) y PIB per cápita (0.80). Se recuperan peor Mortalidad (0.57), Costa / área (0.36) y Densidad de población (0.32): son variables con colas muy largas, en las que unos pocos territorios (Monaco, Macau, islas pequeñas) concentran la varianza, y el R^2 se mide en la escala original, donde esos casos pesan mucho. Con solo dos componentes, la tierra cultivable y la densidad casi no se recuperan, lo que coincide con que su información está en la CP3 y la CP4.

Tabla 12. Valores originales y reconstruidos con 2 y 4 componentes para tres países (escala original).

País	Variable	Original	k = 2	k = 4
México	PIB per cápita	9,000.0	11,110	9,288.1
	Mortalidad infantil	20.91	24.72	14.42
	Teléfonos	181.6	282.4	235.8
	Natalidad	20.69	19.19	16.50
Alemania	PIB per cápita	27,600	22,395	25,106
	Mortalidad infantil	4.16	-1.87	0.933
	Teléfonos	667.9	517.1	553.3
	Natalidad	8.25	9.46	5.80
Níger	PIB per cápita	800.0	-3,513.3	-2,416.8
	Mortalidad infantil	121.7	115.4	125.7
	Teléfonos	1.90	-156.2	-117.3
	Natalidad	50.73	44.11	48.25

La reconstrucción de México con cuatro componentes es razonable (PIB per cápita de 9,288 contra 9,000 reales). Los extremos muestran el límite del método: para Alemania, la mortalidad infantil reconstruida con dos componentes es negativa, y para Níger el PIB per cápita sale negativo con dos y con cuatro componentes. El PCA es lineal y no sabe que estas variables no pueden ser negativas, por lo que en países muy alejados del promedio la reconstrucción puede dar valores imposibles. Es un aviso para no interpretar la matriz reconstruida como datos, sino como una aproximación.

3.6 Estandarización: con y sin

3.6.1 Por qué importa la escala

El PCA maximiza la varianza, y la varianza depende de las unidades. Si una variable está en miles de dólares y otra en fracciones entre 0 y 1, la primera aporta varianza varios órdenes de magnitud mayor solo por su escala. La Tabla 13 muestra el rango y la varianza de cada variable en la base transformada.

Tabla 13. Rango y varianza de cada variable antes de estandarizar (base transformada).

Variable	Mínimo	Máximo	Rango	Varianza
Densidad de población	0	4.21	4.21	0.448
Costa / área	0	2.94	2.94	0.493
Migración neta	-20.99	23.06	44.05	23.70
Mortalidad infantil	2.29	191.2	188.9	1,251.5
PIB per cápita	500.0	55,100	54,600	101,501,163
Alfabetización	17.60	100.0	82.40	370.6
Teléfonos	0.200	1,035.6	1,035.4	51,670
Tierra cultivable	0	62.11	62.11	169.6
Cultivos permanentes	0	1.71	1.71	0.199
Natalidad	7.29	50.73	43.44	124.0
Mortalidad	2.29	29.74	27.45	24.84
Agricultura	0	0.769	0.769	0.021
Servicios	0.062	0.954	0.892	0.027

La varianza del PIB per cápita es 101,501,163, y la de agricultura es 0.021. El PIB aporta 99.95 % de la varianza total de las 13 variables. Si no se estandariza, el PCA solo "ve" al PIB.

3.6.2 Qué ocurre sin estandarizar y estandarizando

```
prop_s = val_s / val_s.sum()
scores_s = Xc @ vec_s
cargas_s = vec_s * np.sqrt(val_s)
r_cp1 = np.corrcoef(scores_s[:, 0], scores_z[:, 0])[0, 1]
print("varianza de CP1 sin estandarizar: %.2f %%" % (100 * prop_s[0]))
print("varianza de CP1 estandarizando:   %.2f %%" % (100 * prop_z[0]))
print("carga de CP1 (sin estandarizar) sobre el PIB:", round(vec_s[VARS.index("GDP ($ per capita)"),
      0], 4))
print("correlación entre las puntuaciones de CP1 de ambos casos:", round(r_cp1, 3))
```

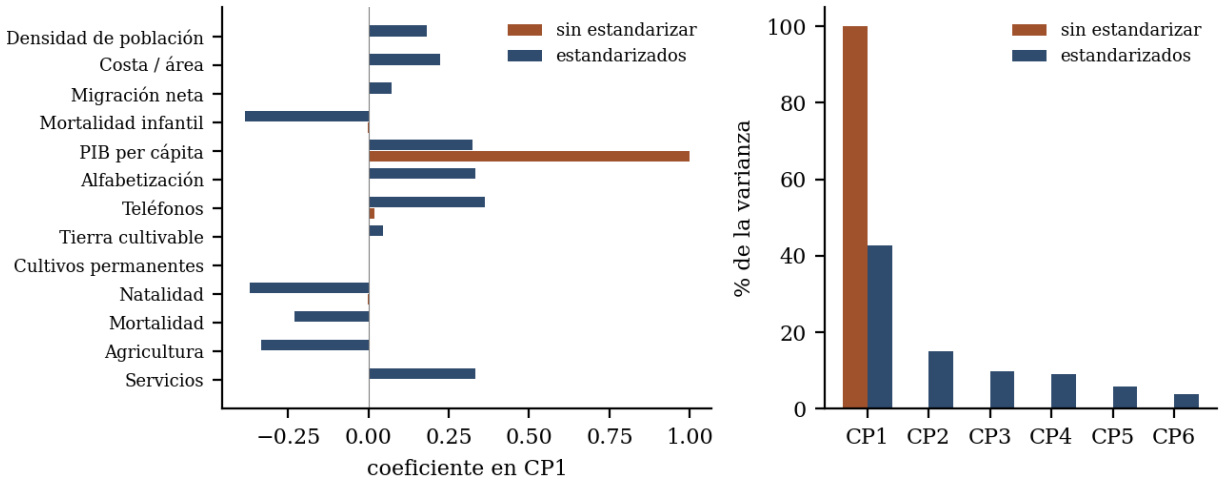


Figura 31. Izquierda: coeficientes de la CP1 en ambos casos. Derecha: varianza explicada por las primeras seis componentes.

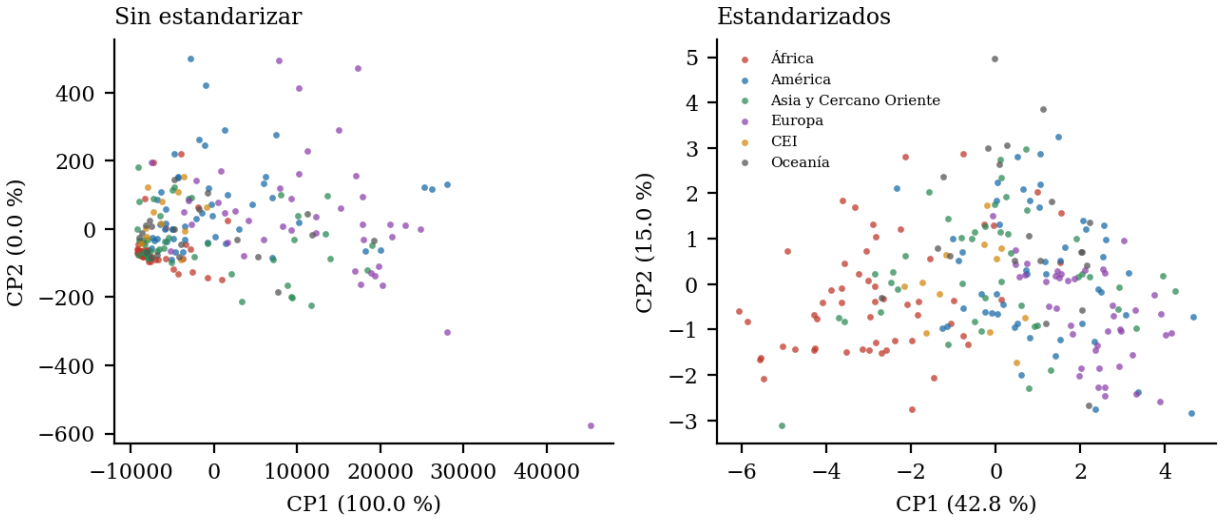


Figura 32. Países en el plano CP1–CP2 sin estandarizar (izquierda) y estandarizando (derecha).

Tabla 14. Comparación del PCA con y sin estandarización.

Aspecto	Sin estandarizar	Estandarizados
Matriz usada	Covarianza	Correlación (covarianza de los datos estandarizados)
Varianza explicada por la CP1	99.98 %	42.8 %
Componentes para llegar a 80 %	1	5
Variables con peso importante en la CP1	1 (PIB per cápita, coeficiente 1.00)	9 ($\|carga\| \geq 0.5$)
Qué representa la CP1	El PIB per cápita casi por sí solo	Un eje de desarrollo con muchas variables

Sin estandarizar, la CP1 explica 99.98 % de la varianza y su vector propio vale 0.9998 en el PIB per cápita y casi cero en las demás variables. La componente es, en la práctica, el PIB con otro nombre, y el PCA no reduce nada: ordena a los países por ingreso e ignora la mortalidad infantil, la natalidad o la alfabetización. El 99.98 % es un artefacto de la escala, no una señal de que la información esté concentrada.

Al estandarizar, cada variable tiene varianza 1 y la información se reparte: la CP1 explica 42.8 % y recibe peso de 9 variables, las cuatro primeras componentes suman 76.7 %. Las puntuaciones de la CP1 de ambos casos tienen correlación de 0.77: ordenan de forma parecida a los países, porque el PIB también forma parte del eje de desarrollo, pero la versión estandarizada incorpora la información social y demográfica que la otra descarta.

3.6.3 Conclusión sobre la estandarización

Las variables de este conjunto están en unidades distintas (dólares, porcentajes, fracciones, razones), así que estandarizar es la decisión adecuada y la que usamos para elegir componentes en la sección 3.5. Solo tendría sentido no estandarizar si todas las variables estuvieran en la misma unidad y la diferencia de varianzas fuera información que se quiere conservar. Aquí no es el caso.

4. Discusión

4.1 Comparación con las hipótesis

H1 (las variables miden desarrollo y se pueden resumir). Se cumple en lo esencial. 23 de los 78 pares de variables tienen $|r| \geq 0.5$ y se forma un bloque claro de desarrollo; la primera componente (42.8 %) ordena a las regiones de África a Europa. La comparación de la sección 3.4.4 lo muestra de forma directa: las cuatro variables más correlacionadas (natalidad, mortalidad infantil, agricultura y alfabetización) se condensan en la CP1, mientras que tierra cultivable y migración neta, las menos correlacionadas, solo aparecen en componentes posteriores. Sin embargo, la reducción es moderada: hacen falta cuatro componentes para llegar a 76.7 %. Es decir, los 13 indicadores no se reducen a una sola dimensión, porque las variables geográficas (tierra cultivable, cultivos permanentes, costa) aportan estructura propia.

H2 (la estandarización es necesaria). Se cumple de forma contundente: sin estandarizar, la CP1 explica 99.98 % de la varianza y es prácticamente el PIB per cápita; estandarizando, explica 42.8 % y recibe peso de 9 variables.

4.2 Limitaciones

Las principales limitaciones del análisis son: (1) en migración neta, 62 países tienen exactamente cero, y es probable que algunos de esos ceros sean datos no disponibles, lo que debilita su correlación con las demás variables; (2) la imputación con la mediana regional reduce algo la varianza de las variables más afectadas (alfabetización, con 16 de 224 países imputados); (3) los datos son de mediados de la década de 2000, de modo que las conclusiones describen ese periodo; (4) la interpretación de la CP2, CP3 y CP4 es nuestra lectura de las cargas; (5) la clasificación en variables independientes y dependientes se apoya en correlaciones, que no prueban causalidad; (6) la selección de las variables más y menos correlacionadas usa la correlación de Pearson, que no capta relaciones no lineales como la saturación de la alfabetización; y (7) al regresar a la matriz original con cuatro componentes algunas variables se recuperan mal y, en países extremos como Níger, aparecen valores imposibles (negativos), porque el PCA es lineal y no sabe que el PIB o la densidad no pueden ser negativos.

4.3 Cómo se podría mejorar el análisis

Con más tiempo se podría: tratar los ceros de migración neta como faltantes y repetir el análisis; comparar la imputación con la mediana regional contra otros métodos de imputación; repetir el PCA sin los territorios muy pequeños (Monaco, Macau, Singapore) para ver si cambian las componentes; complementar la correlación de Pearson con la de Spearman, que capta relaciones monótonas no lineales; actualizar los datos con fuentes más recientes; y usar las componentes como variables explicativas en un modelo para el PIB per cápita o la mortalidad infantil.

5. Conclusiones

Partimos de 227 países y 19 variables. Después de la depuración quedaron 224 países y 13 variables numéricas; descartamos las variables categóricas y las redundantes (otros usos del suelo, industria) con razones explícitas, y transformamos con logaritmo las tres variables de asimetría extrema.

Las correlaciones muestran un bloque de variables que describe el nivel de desarrollo (mortalidad infantil, natalidad, alfabetización, PIB per cápita, teléfonos, agricultura y servicios), mientras que las condiciones geográficas (tierra cultivable, cultivos permanentes, costa) se relacionan poco con él. Las cuatro variables más correlacionadas (natalidad, mortalidad infantil, agricultura y alfabetización, con |r| promedio de 0.73) son casi redundantes y se resumen en la primera componente; las dos menos correlacionadas (tierra cultivable y migración neta) aportan información propia. Por eso clasificamos las condiciones geográficas como independientes y el bloque como dependiente, aclarando que se trata de una hipótesis y no de una prueba de causalidad.

Con datos estandarizados, cuatro componentes explican 76.7 % de la varianza. La primera (el 42.8 %) es un eje de desarrollo que ordena a las regiones de forma coherente.

Al regresar a la matriz original con cuatro componentes se recuperan razonablemente las variables de desarrollo (mortalidad infantil, natalidad, teléfonos, PIB per cápita), pero no las geográficas de colas largas (densidad de población y costa/área); la reconstrucción es una aproximación y puede dar valores imposibles en países extremos.

Sin estandarizar, el PCA se reduce al PIB por la diferencia de escalas y pierde su utilidad. Limitaciones: los datos son de mediados de los años 2000; imputamos con la mediana regional una parte pequeña de los

valores; y el cero de migración neta puede ser un dato faltante disfrazado. Una extensión natural sería ajustar un modelo para el PIB per cápita o la mortalidad infantil usando las componentes como predictores.

6. Bibliografía

[1] fernandol. *Countries of the World* [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/fernandol/countries-of-the-world

[2] Jolliffe, I. T. (2002). *Principal Component Analysis* (2.ª ed.). Springer.

[3] Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.

[4] United Nations Development Programme (1990). *Human Development Report 1990*. Oxford University Press.

[5] McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 51–56.

[6] Harris, C. R. et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.

[7] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.

[8] Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

[9] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[10] Guttman, L. (1954). Some necessary conditions for common-factor analysis. *Psychometrika*, 19(2), 149–161.